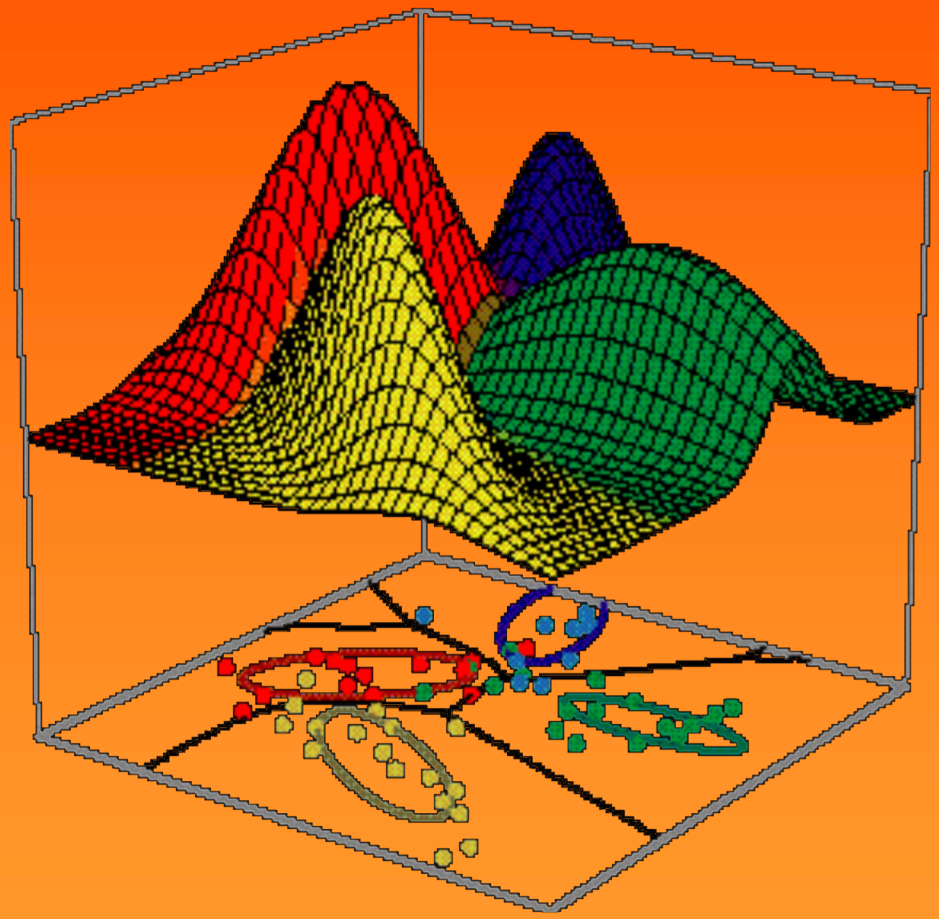


Pattern Classification

Materials in these slides were taken from Pattern Classification (2nd ed) by R. O. Duda, P. E. Hart and D. G. Stork, John Wiley & Sons, 2000 **with the permission of the authors and the publisher**

Rozdział 1: Wprowadzenie do Rozpoznawania Obrazów (Podrozdziały 1.1-1.6)

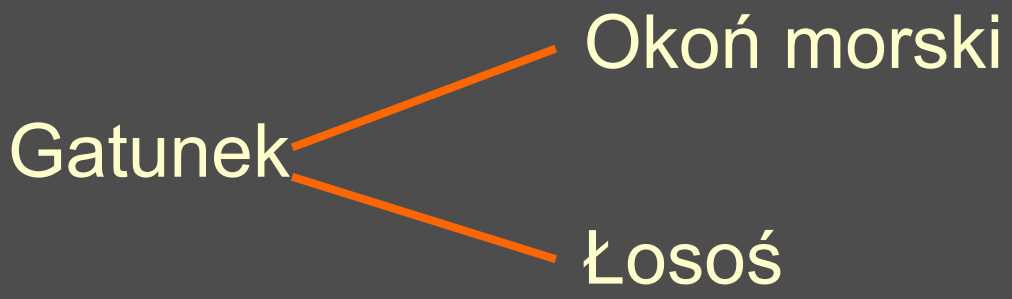
- Percepcja Maszynowa
- Przykład
- System rozpoznający
- Cykl projektowania systemu. rozp.
- Uczenie i Adaptacja
- Wnioski

Percepcja maszynowa

- Zadanie budowy sytemu rozpoznającego wzorce:
  - Rozpoznawanie mowy
  - Identyfikacja odcisków palców
  - OCR (Optical Character Recognition)
  - Identyfikacja sekwencji DNA
  - inne

Przykład

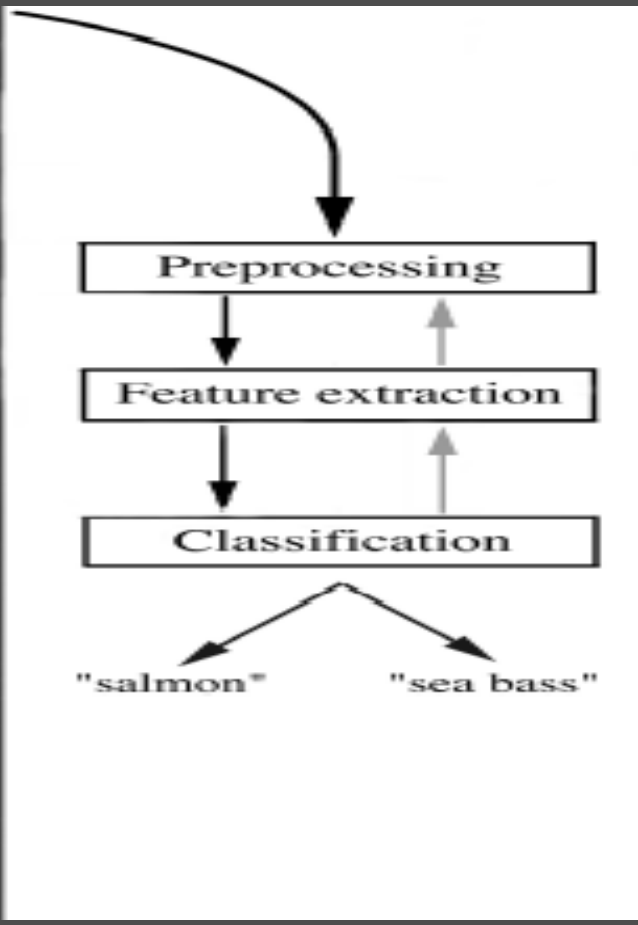
- “Sortowanie ryb na taśmociągu ze względu na ich gatunek przy użyciu informacji wizyjnej”



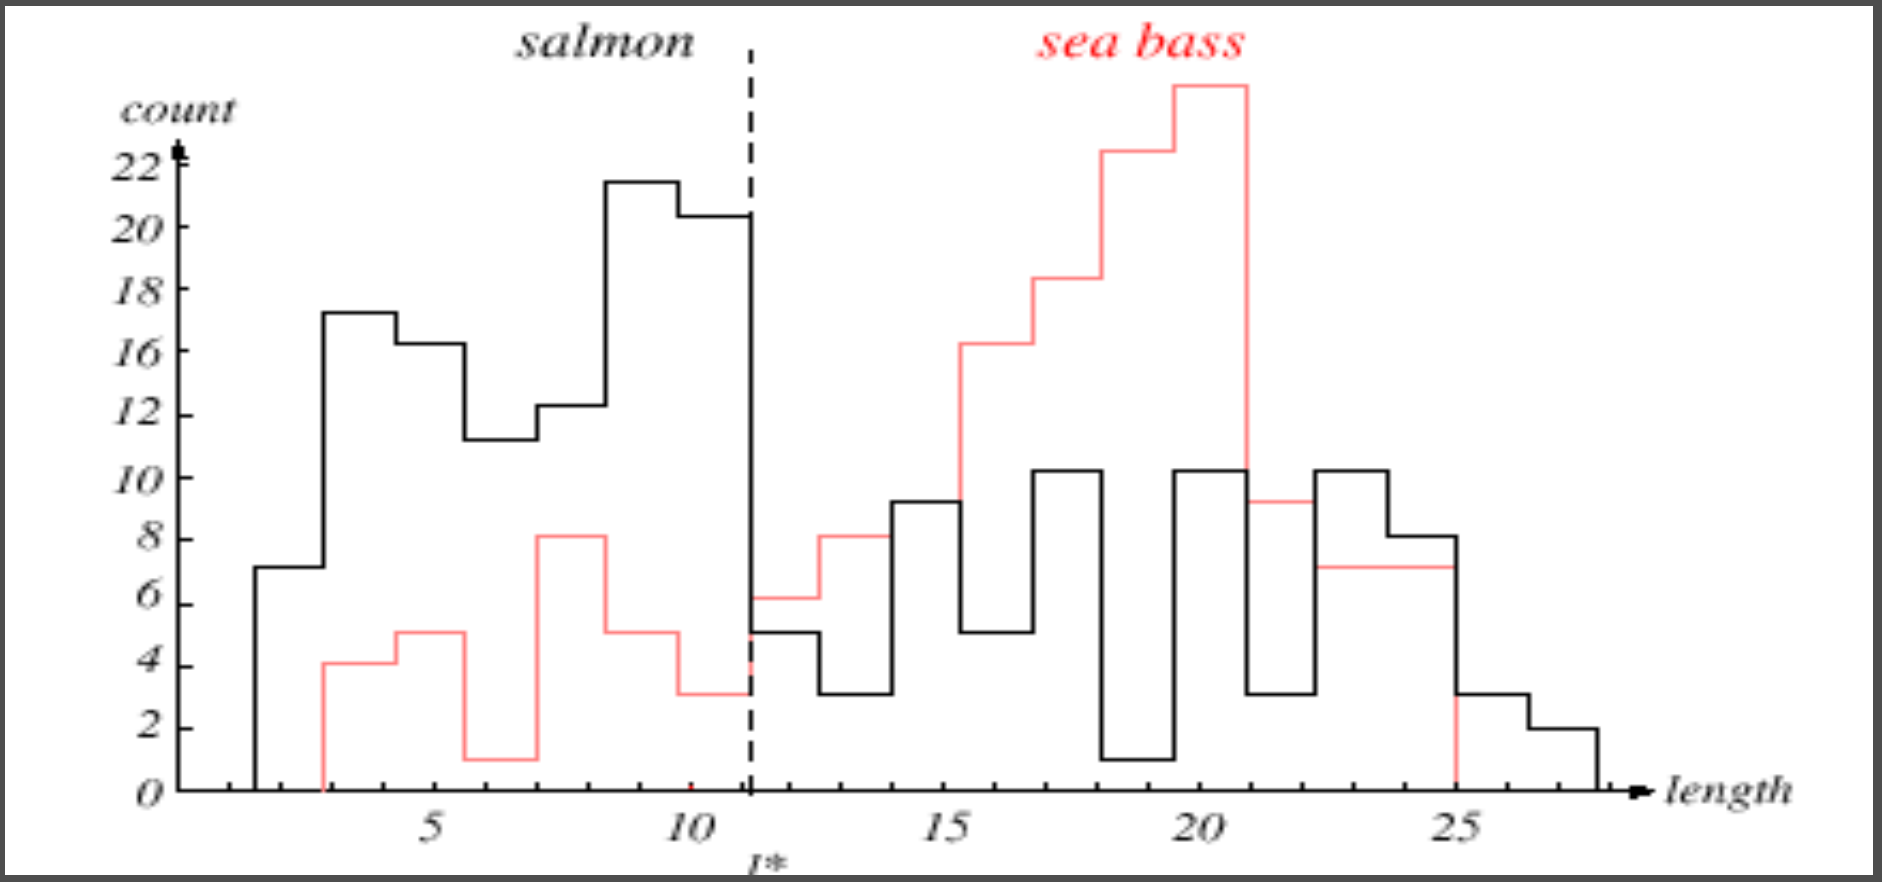
- Analiza problemu
  - Zbuduj system wizyjny, pozyskaj przykładowe obrazy i wyznacz ich „cechy”
    - Długość
    - Jasność
    - Szerokość
    - Liczba i kształt płetw
    - Umiejscowienie otworu gębowego, itp.
    - To jest zbiór wszystkich cech proponowanych do użycia podczas budowy klasyfikatora

- Przetwarzanie wstępne (preprocessing)
  - Dokonaj segmentacji obrazu aby wyodrębnić ryby spośród innych ryb i z tła
- Wykorzystaj wysegmentowany obraz do ekstrakcji cech w celu redukcji analizowanych danych
- Wyznaczone cechy trafiają na wejście klasyfikatora



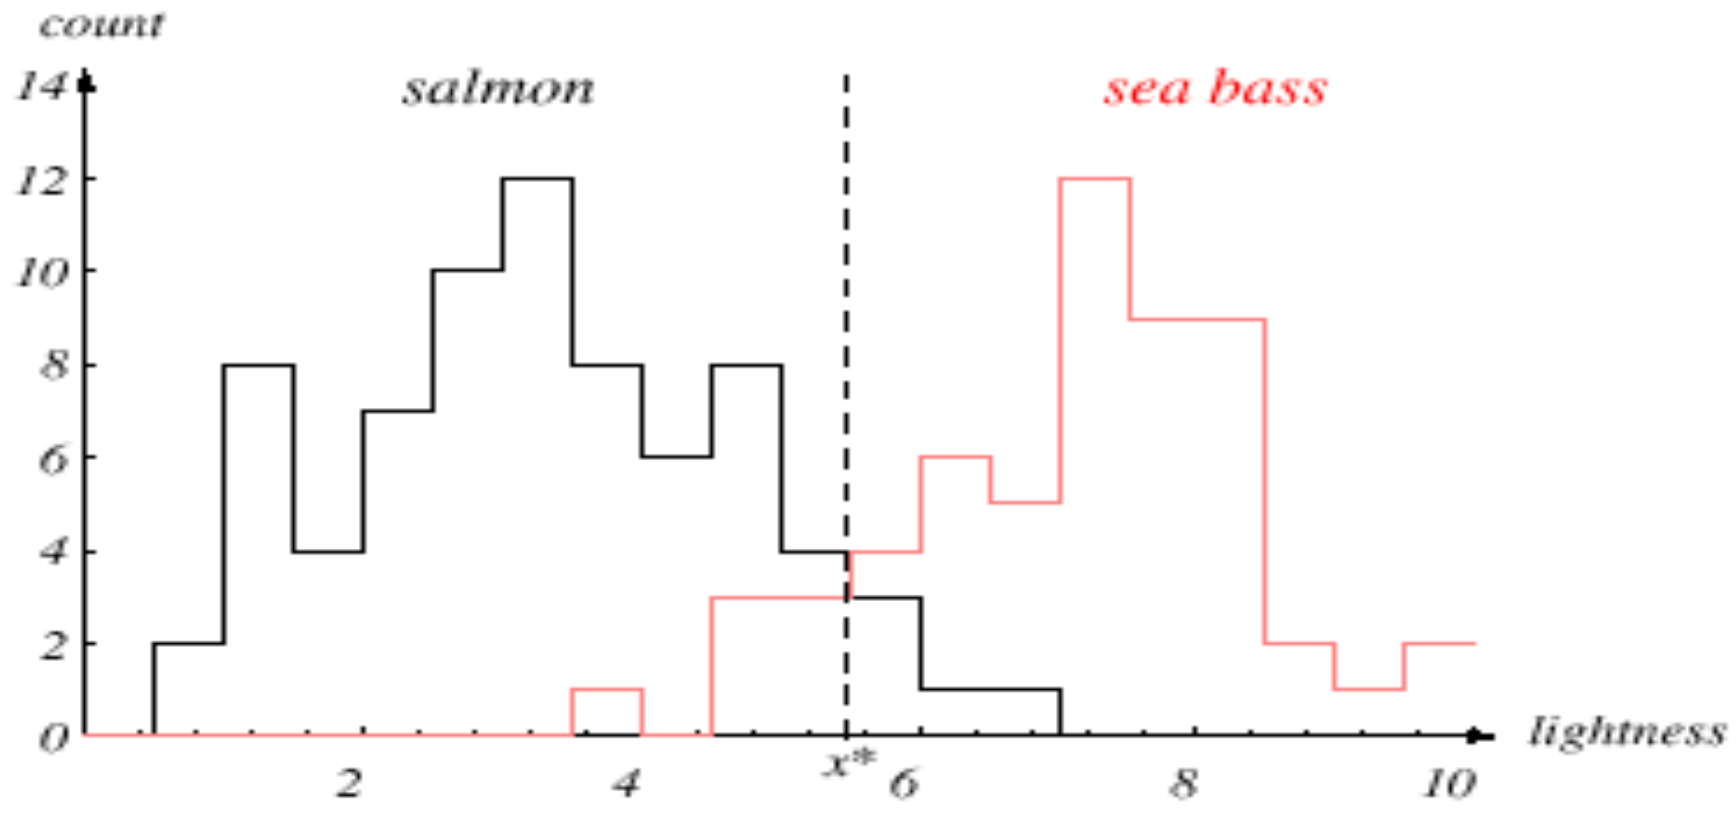

Preprocessing
Feature extraction
Classification
"salmon"
"sea bass"

- Klasyfikacja
  - Wybierz długość ryby jako cechę podczas klasyfikacji (dyskryminacji)


salmon
sea bass
count
22
20
18
16
12
10
8
6
4
2
0
5
10
15
20
25
length
l*

Długość ma słabe własności dyskryminacyjne jeśli jest używana jako jedyna cecha

Przetestuj jasność jako cechę wykorzystywaną podczas klasyfikacji


count
14
12
10
8
6
4
2
0
salmon
sea bass
lightness
2
4
x*
6
8
10

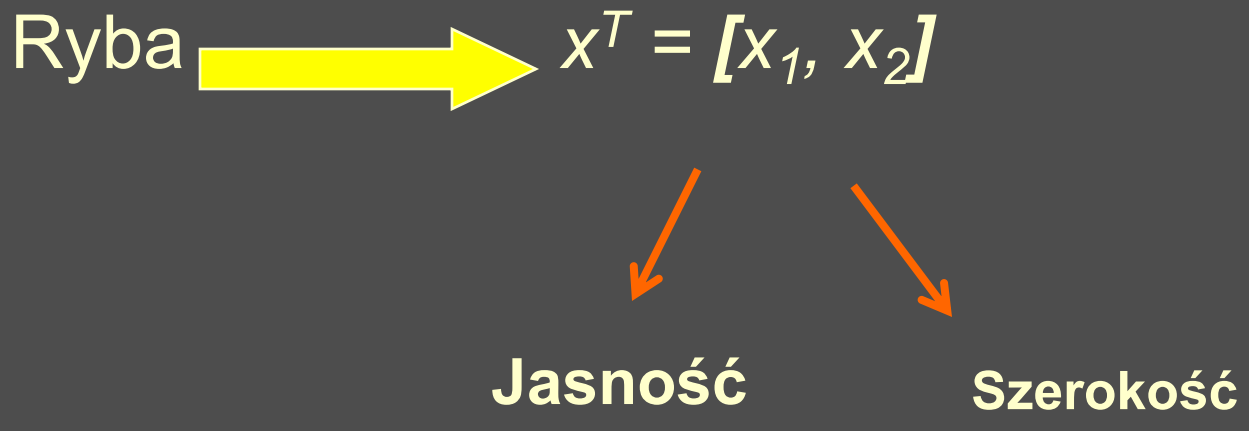
- Wartość progowa i związany z tym koszt

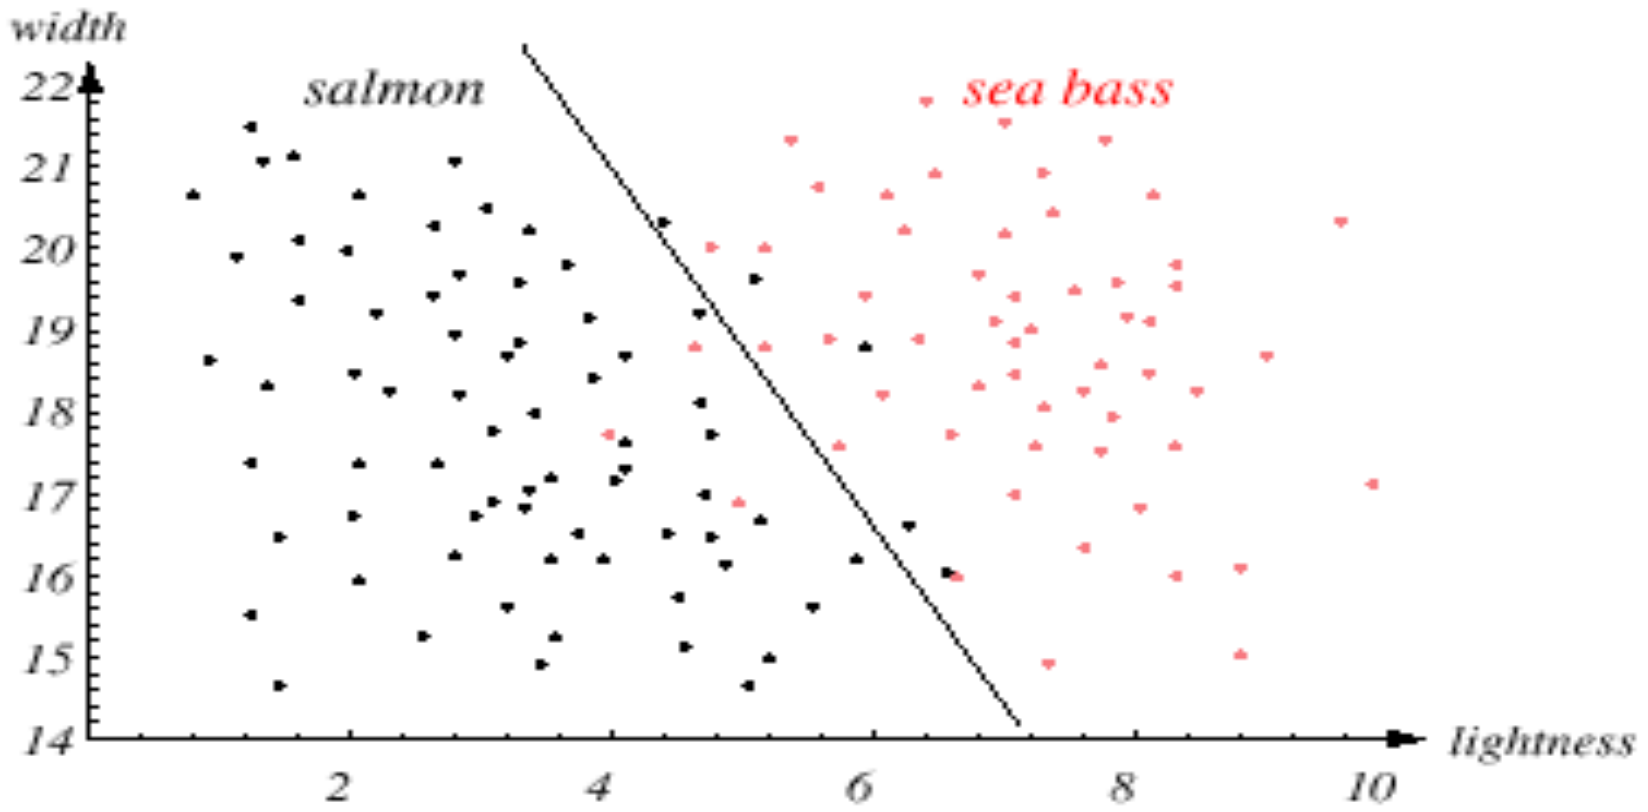
  - Zmniejsz wartość progową aby zminimalizować koszt/zmaksymalizować zysk (zmniejszenie liczby okoni morskich klasyfikowanych jako łososie)



Zagadnienie teorii decyzji

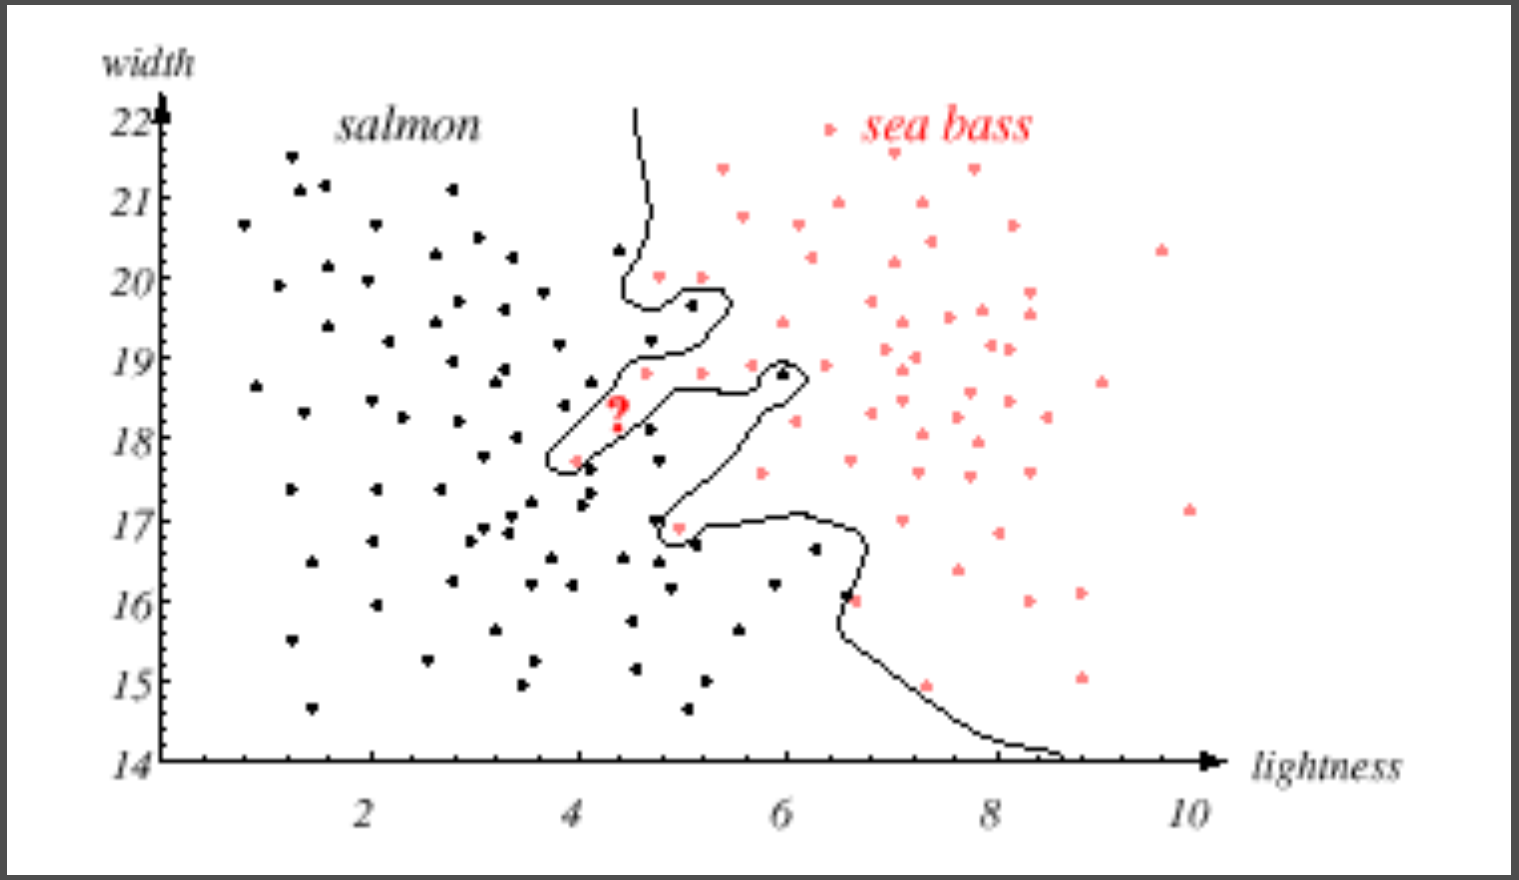
- Wykorzystaj jasność oraz szerokość ryby jako cechy




width
22
21
20
19
18
17
16
15
14
salmon
sea bass
2
4
6
8
10
lightness

- Możemy dodać inne cechy, które nie są skorelowane z cechami już wybranymi. Jednak należy zachować ostrożność by nie pogorszyć jakości klasyfikatora poprzez wybranie „cech zaszumionych”

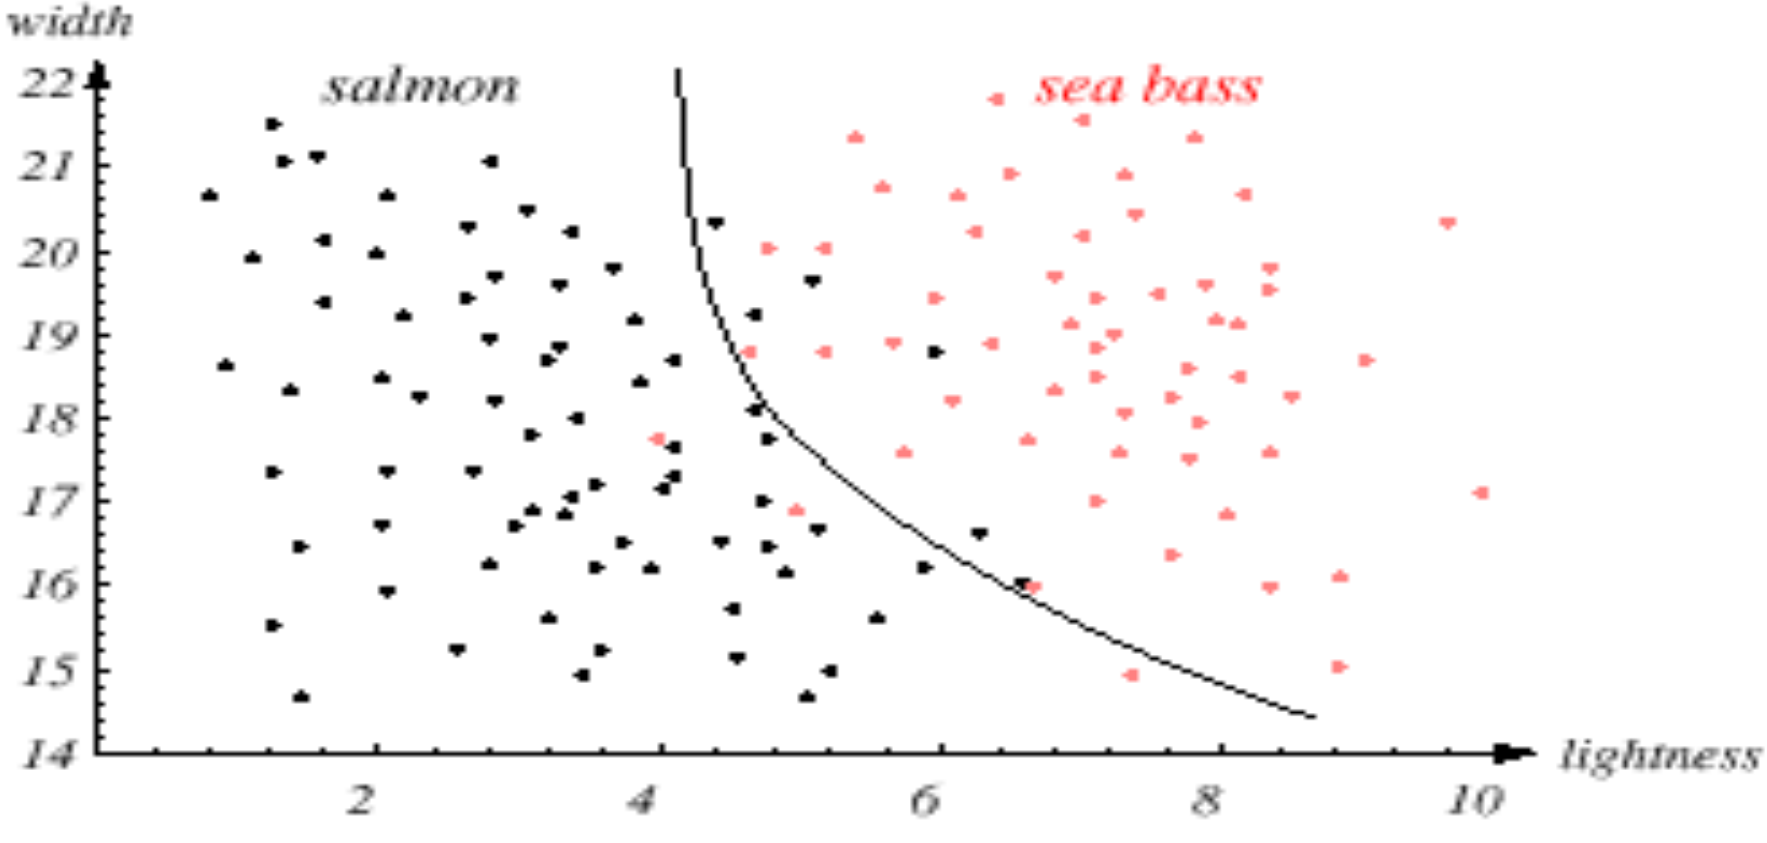
- Z punktu widzenia jakości klasyfikacji zbioru uczącego, najlepsza powierzchnia seperująca byłaby taka jak zaznaczono na następującym rysunku:


width
salmon
sea bass
?
lightness
22
21
20
19
18
17
16
15
14
2
4
6
8
10

- Jednak, nasza radość jest przedwczesna, ponieważ głównym zadaniem tworzonego systemu klasyfikującego jest klasyfikacja „nowych” danych

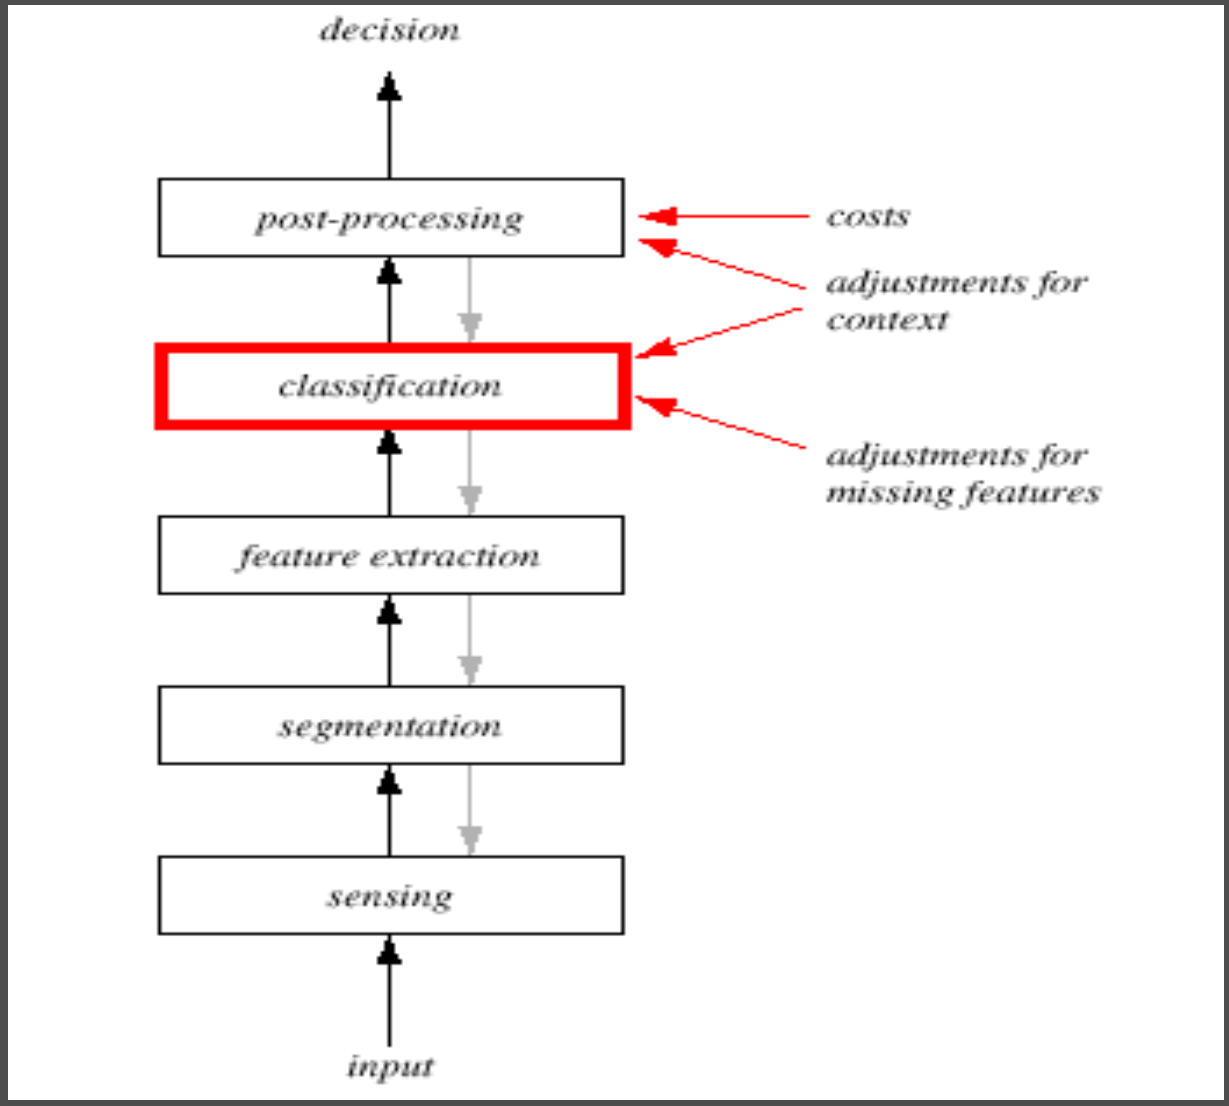


Pojęcie generalizacji!


width
22
21
20
19
18
17
16
15
14
salmon
sea bass
lightness
2
4
6
8
10

Systemy rozpoznające

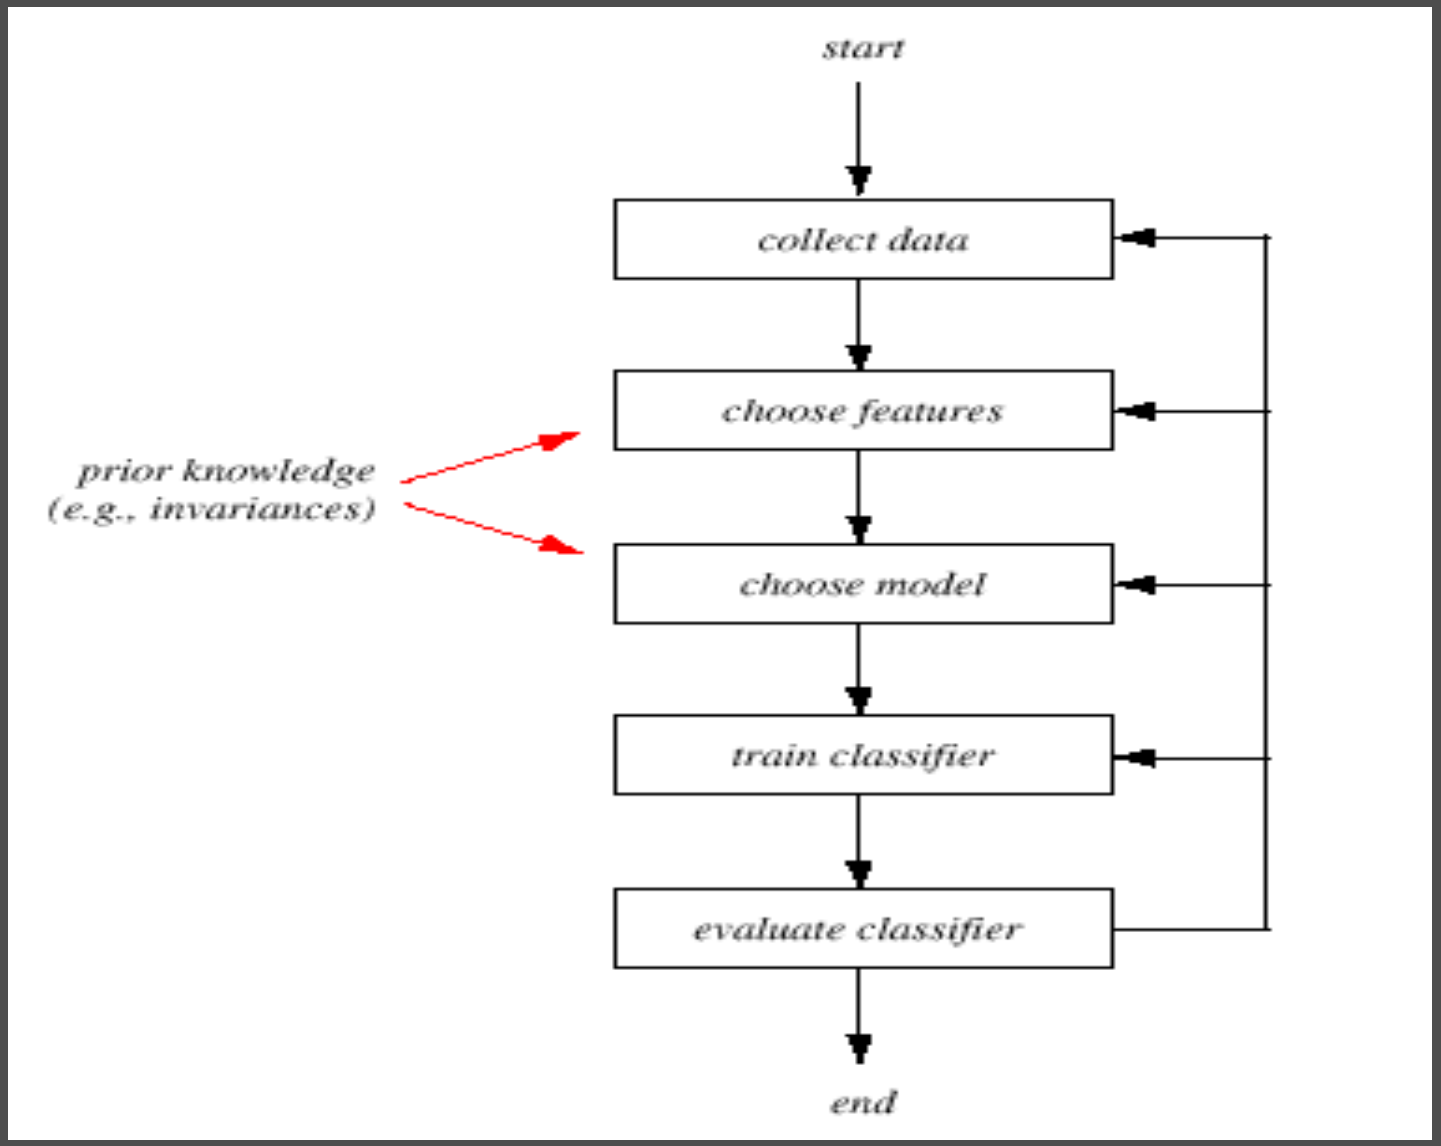
- Pomiary
  - Użyj urządzenia pomiarowego, czujnika (kamera, mikrofon, itp.)
  - Działanie systemu rozpoznającego będzie zależeć od parametrów czujnika, pasma przenoszenia, zniekształceń, itp.
- Segmentacja i grupowanie
  - Obiekty powinny być odseparowane i nie powinny się pokrywać


decision
post-processing
costs
adjustments for context
classification
adjustments for missing features
feature extraction
segmentation
sensing
input

- Ekstrakcja cech
  - Cechy dyskryminujące
  - Cechy niezmiennicze względem obrotów, przesunięcia i zmiany skali.
- Klasyfikacja
  - Wykorzystanie wyznaczonego wektora cech do określenia klasy (kategorii) rozpoznawanego obiektu
- Post Processing
  - Wykorzystanie informacji kontekstowej, innej niż pochodzącej z aktualnie rozpoznawanego wzorca, w celu poprawy wydajności klasyfikatora.

Cykl projektowania systemu

- Zebranie danych
- Wybór cech
- Wybór modelu
- Uczenie
- Walidacja modelu
- Testowanie modelu
- Złożoność obliczeniowa


start
collect data
choose features
prior knowledge
(e.g., invariances)
choose model
train classifier
evaluate classifier
end

- Gromadzenie danych
  - Czy zebranych danych są wystarczająco dużo i czy są reprezentatywne dla przeprowadzenia zadań uczenia i testowania systemu?

- Wybór cech, ekstrakcja i selekcja

  - Zależy od charakterystyki rozwiązywanego problemu. Cechy powinny być łatwe do wyznaczenia, niezależne od występujących transformacji i niewrażliwe na zakłócenia.

- Wybór modelu
  - Jeśli jesteśmy nieusatysfakcjonowani wydajnością zbudowanego systemu rozpoznającego, wybieramy inny model (inną klasę modeli)

- Uczenie (trenowanie)
  - Wykorzystanie danych do doboru parametrów klasyfikatora. Istnieje wiele różnych klasyfikatorów i algorytmów ich uczenia.

- Walidacja modeli (modelu)

  - Porównanie jakości klasyfikacji dla różnych zestawów cech, różnych modeli, różnych struktur modeli i parametrów algorytmów uczących. Potrzebny jest niezależny zbiór danych (walidujących) lub wykorzystanie tych samych danych stosując odpowiedni schemat walidacji. Wybierane jest najlepsze podejście (zestaw cech, struktura modelu etc.).

- Testowanie modelu

  - Finalna ocena jakości klasyfikacji dla wybranego zestawu cech, modelu, jego struktury i parametrów algorytmu uczącego. Ponownie potrzebny jest niezależny zbiór danych (testowych) lub (podobnie jak wcześniej) wykorzystanie tych samych danych stosując odpowiedni schemat testowania.
  - Testowanie modelu jest czymś innym niż jego walidacja, inny jest jego cel; aczkolwiek stosowane bardzo często te same wskaźniki i techniki (schematy) walidacji/testowania.

- Złożoność obliczeniowa

  - Jaki jest kompromis pomiędzy prostotą klasyfikatora i łatwością obliczeń a wydajnością systemu klasyfikatora?

  - Jak nakład obliczeń zależy od liczby cech, liczby obserwacji (wzorców) i liczby klas (kategorii)?

Rodzaje uczenia

- Uczenia nadzorowane (z nauczycielem)
  - Nauczyciel dostarcza informacji o klasie rozpoznawanego obiektu (lub ogólnie o zadanym wyjściu modelu)
- Uczenie nienadzorowane (bez nauczyciela)
  - Zadaniem systemu jest określenie „naturalnych” grup (skupisk, klastrów) zawierających „podobne” do siebie wzorce

Przykłady innych danych (Hastie, et al.)

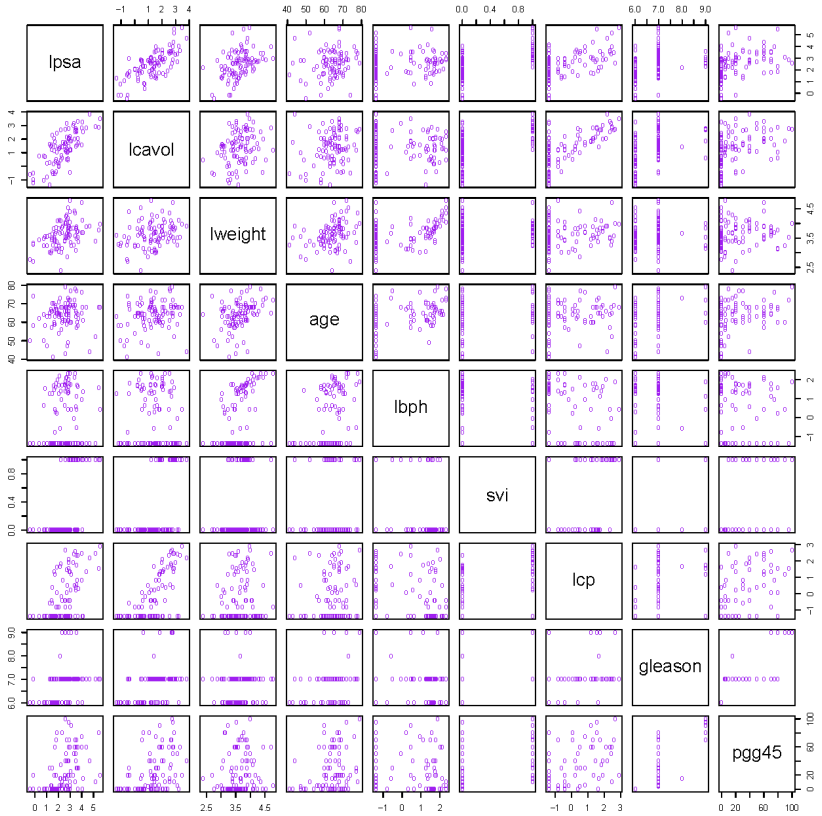


FIGURE 1.1. *Scatterplot matrix of the prostate cancer data. The first row shows the response against each of the predictors in turn. Two of the predictors,* `svi` *and* `gleason`*, are categorical.*

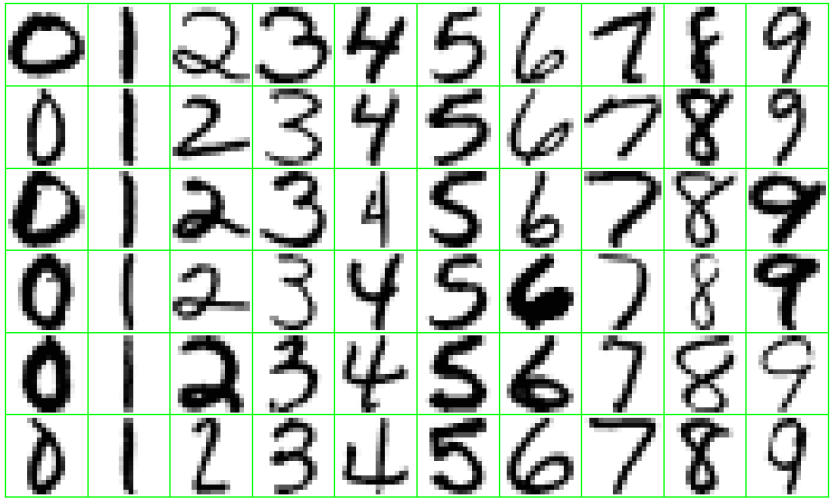


FIGURE 1.2. *Examples of handwritten digits from U.S. postal envelopes.*



FIGURE 1.3. *DNA microarray data: expression ma-*

Chapter 2 (Part 1): Bayesian Decision Theory (Sections 2.1-2.2)

- Wprowadzenie
- Bayesowska teoria decyzji – ciągłe cechy

Wprowadzenie

- Przykład okoń morski/łosoś
  - Klasa obiektu, prawdopodobieństwo a priori
    - Klasa obiektu jest zmienną losową
    - Złapanie okonia i łososia jest równie prawdopodobne
      - $P(\omega_1) = P(\omega_2)$ (równe pr. a priori)
      - $P(\omega_1) + P(\omega_2) = 1$ (pr. rozłączne i wyczerpujące)

- Reguła decyzyjna dla danej jedynie informacji a priori
  - Podejmij decyzję ω_1 jeśli $P(\omega_1) > P(\omega_2)$ w innym przypadku podejmij decyzję ω_2
- Wykorzystanie informacji zależnej od klasy
- $P(x \mid \omega_1)$ i $P(x \mid \omega_2)$ oznaczają różne rozkłady cechy jasność w klasach okoń i łosoś

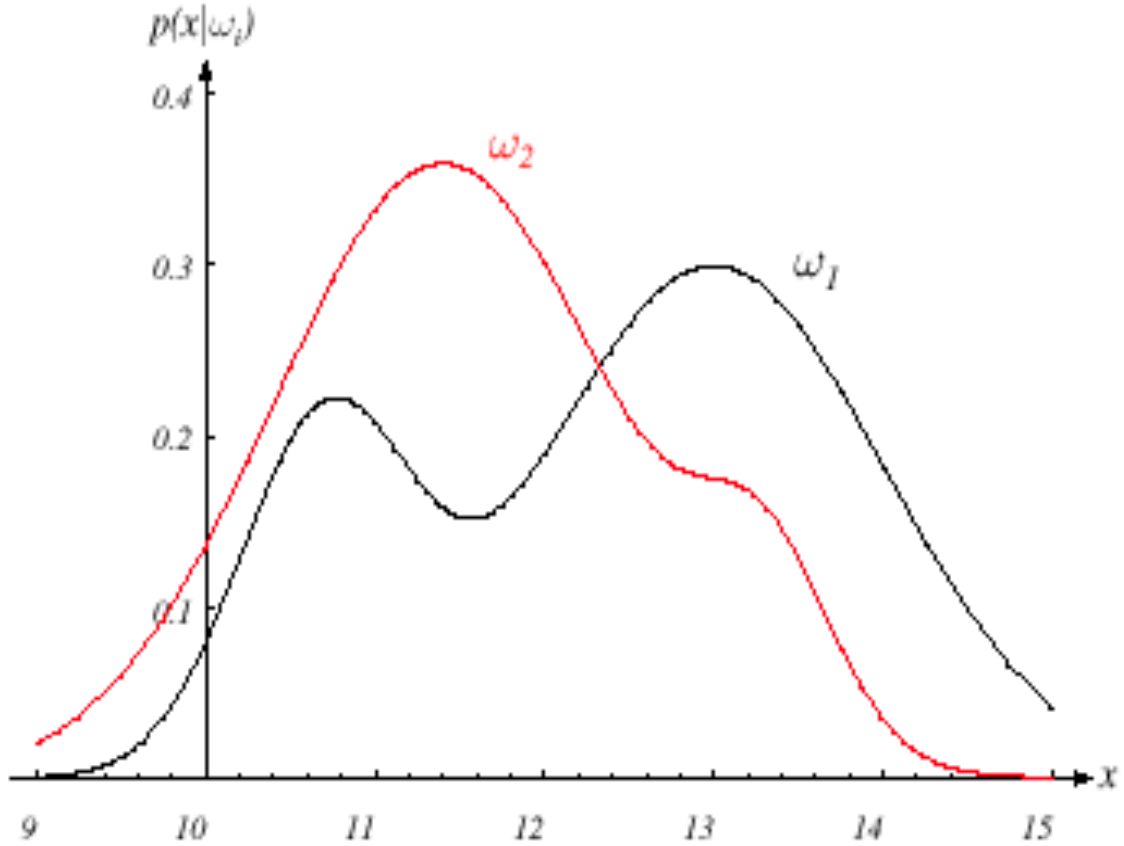


FIGURE 2.1. Hypothetical class-conditional probability density functions show the probability density of measuring a particular feature value x given the pattern is in category ω_j. If x represents the lightness of a fish, the two curves might describe the difference in lightness of populations of two types of fish. Density functions are normalized, and thus the area under each curve is 1.0. From: Richard O. Duda, Peter E. Hart, and David G. Stork, *Pattern Classification*. Copyright © 2001 by John Wiley & Sons, Inc.

- Twierdzenia Bayesa, (Posterior, likelihood, evidence)
  - $$P(\omega_j \mid x) = \frac{P(x \mid \omega_j) P(\omega_j)}{P(x)}$$
  - W przypadku dwóch klas

$$P(x) = \sum_{j=1}^{j=2} P(x \mid \omega_j) P(\omega_j)$$

  - Posterior = (Likelihood x Prior) / Evidence

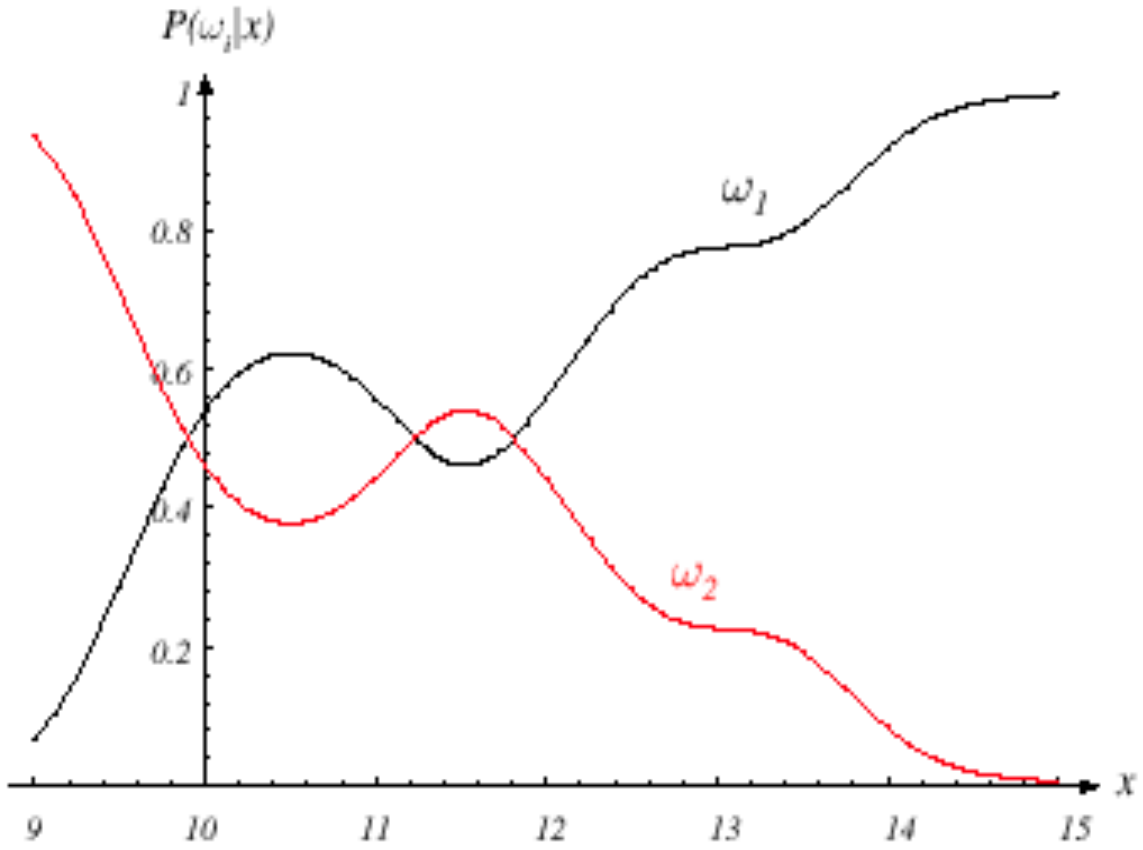


FIGURE 2.2. Posterior probabilities for the particular priors $P(\omega_1) = 2/3$ and $P(\omega_2) = 1/3$ for the class-conditional probability densities shown in Fig. 2.1. Thus in this case, given that a pattern is measured to have feature value $x = 14$, the probability it is in category ω_2 is roughly 0.08, and that it is in ω_1 is 0.92. At every x, the posteriors sum to 1.0. From: Richard O. Duda, Peter E. Hart, and David G. Stork, *Pattern Classification*. Copyright © 2001 by John Wiley & Sons, Inc.

- Decyzja podjęta na podstawie pr. a posteriori

  X - dana obserwacja (wartość cechy):

  Jeśli $P(\omega_1 \mid x) > P(\omega_2 \mid x)$ ⇒ Klasa obiektu = ω_1
  Jeśli $P(\omega_1 \mid x) < P(\omega_2 \mid x)$ ⇒ Klasa obiektu = ω_2

  Stąd można wyznaczyć prawdopodobieństwo złej decyzji:
  Jeśli zaobserwowaliśmy konkretne x wtedy prawdopodobieństwo błędu (error) wynosi:

  $P(error \mid x) = P(\omega_1 \mid x)$ *jeśli decydujemy* ω_2
  $P(error \mid x) = P(\omega_2 \mid x)$ *jeśli decydujemy* ω_1

- Minimalizacja prawdopodobieństwa popełnienia błędu

- Podejmij decyzję ω_1 *jeśli* $P(\omega_1 \mid x) > P(\omega_2 \mid x)$; w innym przypadku ω_2

  A więc:

$$P(error \mid x) = min\,[P(\omega_1 \mid x), P(\omega_2 \mid x)]$$

Bayesowska teoria decyzji – ciągłe cechy

- Uogólnienie poprzednich propozycji
  - Przypadek większej liczby cech
  - Przypadek większej liczby klas
  - Możliwość podjęcia różnych akcji a nie jedynie podjęcia decyzji co do klasy obiektu
  - Wprowadzenie funkcji strat, bardziej ogólnej niż prawdopodobieństwo popełnienia błędu

Stosunek prawdopodobieństw

Poprzednia reguła jest równoważna regule:

$$\text{jeśli } \frac{P(x\,|\,\omega_1)}{P(x\,|\,\omega_2)} > \frac{\lambda_{12}-\lambda_{22}}{\lambda_{21}-\lambda_{11}} \cdot \frac{P(\omega_2)}{P(\omega_1)}$$

wtedy podejmij akcję α_1 (zdecyduj ω_1)

w innym przypadku podejmij akcję α_2 (zdecyduj ω_2)

Postać ta jest wygodna ponieważ prawa strona nierówności jest liczbą (określoną a priori)

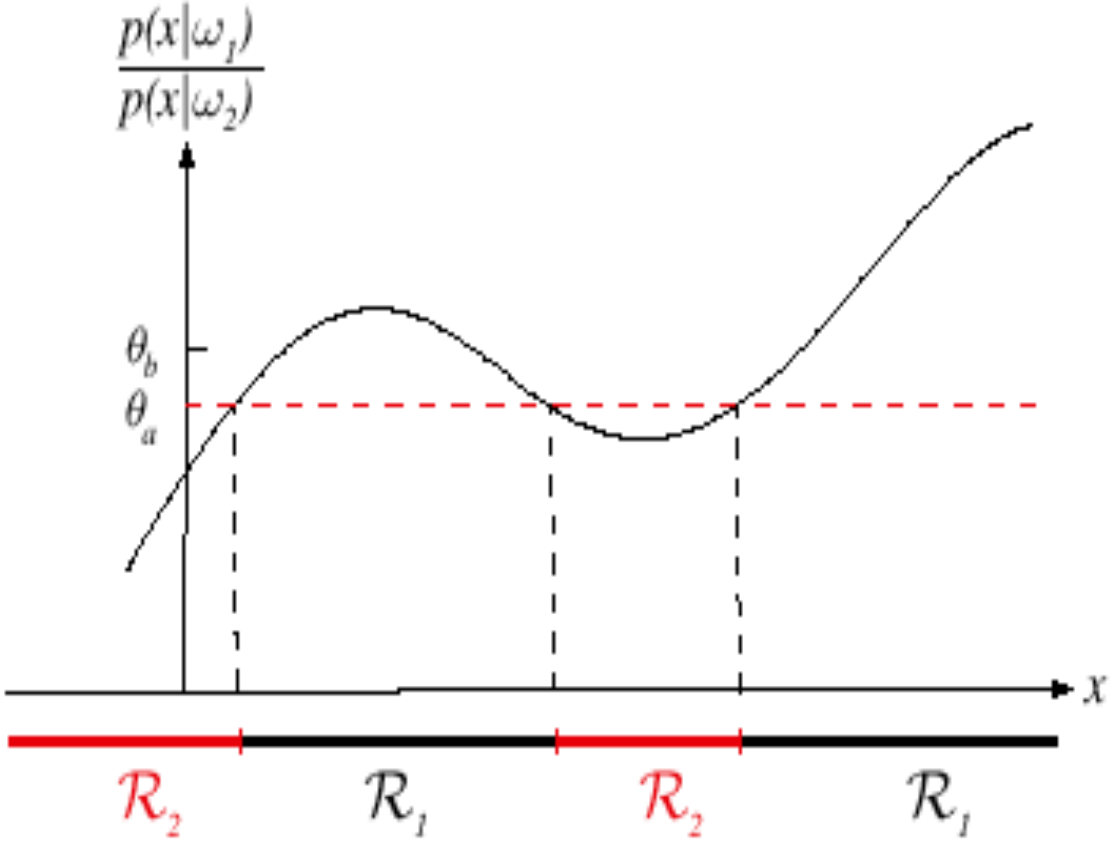


FIGURE 2.3. The likelihood ratio $p(x|\omega_1)/p(x|\omega_2)$ for the distributions shown in Fig. 2.1. If we employ a zero-one or classification loss, our decision boundaries are determined by the threshold θ_a. If our loss function penalizes miscategorizing ω_2 as ω_1 patterns more than the converse, we get the larger threshold θ_b, and hence $\mathcal{R}_1$ becomes smaller. From: Richard O. Duda, Peter E. Hart, and David G. Stork, *Pattern Classification*. Copyright © 2001 by John Wiley & Sons, Inc.

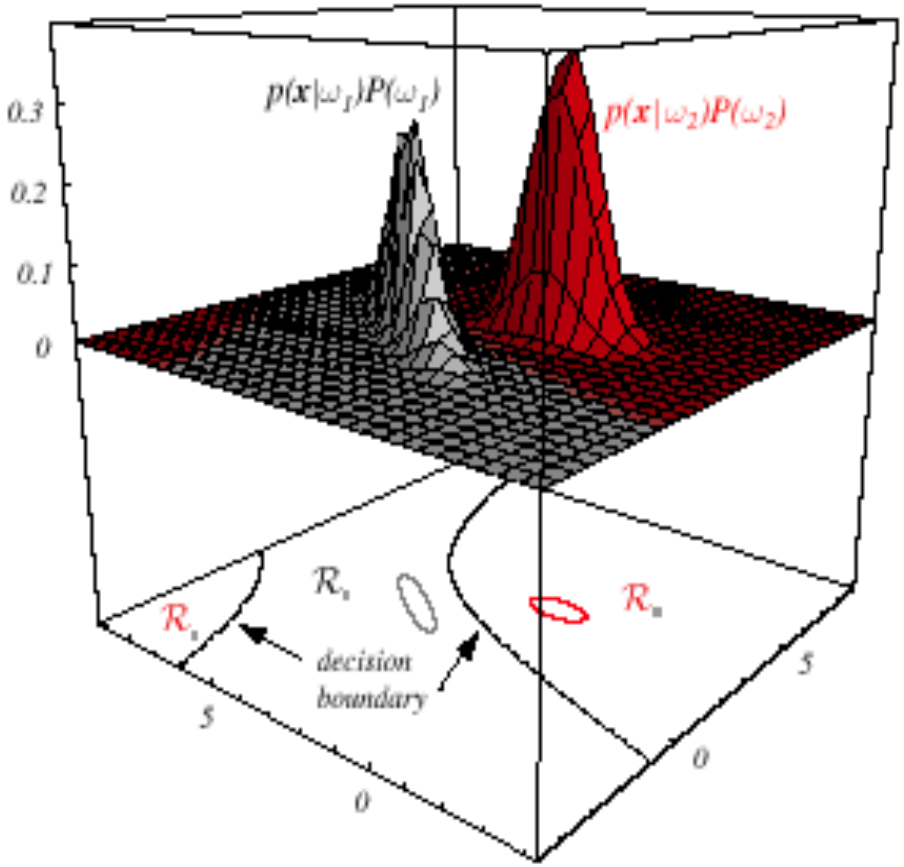


FIGURE 2.6. In this two-dimensional two-category classifier, the probability densities are Gaussian, the decision boundary consists of two hyperbolas, and thus the decision region $\mathcal{R}_2$ is not simply connected. The ellipses mark where the density is $1/e$ times that at the peak of the distribution. From: Richard O. Duda, Peter E. Hart, and David G. Stork, *Pattern Classification*. Copyright © 2001 by John Wiley & Sons, Inc.

Klasyfikacja Bayesowska - uwagi

- Klasyfikator Bayesa jest klasyfikatorem optymalnym
- Niestety jego konstrukcja wymaga znajomości rozkładów w klasach
- W praktyce prawie zawsze rozkłady te są nieznane i muszą być szacowane na podstawie próby (zbioru uczącego)
- Uproszczona wersja – Naiwny klasyfikator Bayesowski: podczas szacowania wielowymiarowego rozkładu w danej klasie zakłada się że cech są niezależne, co z kolei powoduje, że rozkład wielowymiarowy może być wyznaczony jako iloczyn rozkładów jednowymiarowych szacowanych osobno

Rozkład normalny

- Rozkład jednowymiarowy

$$P(x) = \frac{1}{\sqrt{2\pi}\,\sigma} exp\left[-\frac{1}{2}\left(\frac{x-\mu}{\sigma}\right)^2\right],$$

Gdzie:

μ = wartość oczekiwana x

σ^2 = wariancja

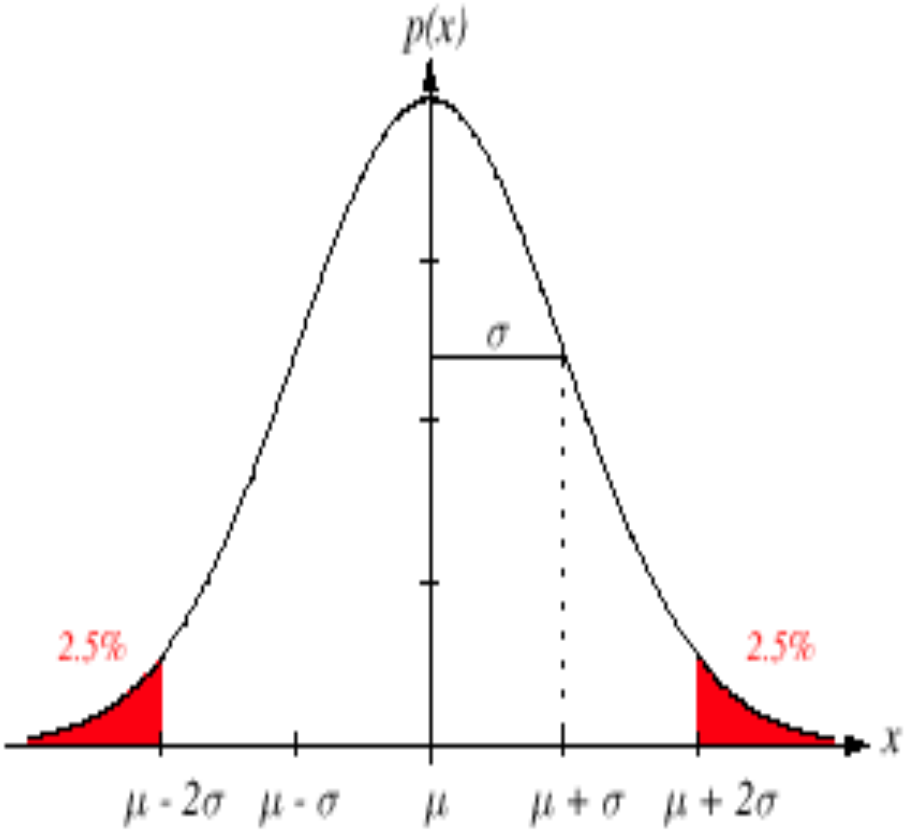


FIGURE 2.7. A univariate normal distribution has roughly 95% of its area in the range $|x - \mu| \leq 2\sigma$, as shown. The peak of the distribution has value $p(\mu) = 1/\sqrt{2\pi}\sigma$. From: Richard O. Duda, Peter E. Hart, and David G. Stork, *Pattern Classification*. Copyright © 2001 by John Wiley & Sons, Inc.

- Rozkład wielowymiarowy
  - Rozkład normalny w przestrzeni o wymiarze d:

$$P(x) = \frac{1}{(2\pi)^{d/2}|\Sigma|^{1/2}} exp\left[-\frac{1}{2}(x-\mu)^t \Sigma^{-1}(x-\mu)\right]$$

where:

$x = (x_1, x_2, \ldots, x_d)^T$ wektor cech

$\mu = (\mu_1, \mu_2, \ldots, \mu_d)^T$ wektor średnich rozkładu

Σ macierz kowariancji $d \times d$

$|\Sigma|$ and Σ^{-1} wyznacznik i macierz odwrotna

Chapter 2 (part 3)
Bayesian Decision Theory
(Sections 2-6)

- Funkcje klasyfikujące dla rozkładów normalnych

Funkcje klasyfikujące dla rozkładów normalnych

- Klasyfikacja typu minimum error-rate może być zrealizowana przy użyciu funkcji dyskryminujących

$g_i(x) = \ln P(x \mid \omega_i) + \ln P(\omega_i)$

- Case of multivariate normal

$$g_i(x) = -\frac{1}{2}(x-\mu_i)^t \Sigma_i^{-1}(x-\mu_i) - \frac{d}{2}\ln 2\pi - \frac{1}{2}\ln|\Sigma_i| + \ln P(\omega_i)$$

- Przypadek $\Sigma_i = \sigma^2.I$ (I – macierz jednostkowa)

Kwadratowy składnik jest taki sam we wszystkich funkcjach i może być pominięty

$$g_i(x) = w_i^t x + w_{i0} \text{ (liniowa funkcja klas.)}$$

gdzie:

$$w_i = \frac{\mu_i}{\sigma^2}; \quad w_{i0} = -\frac{1}{2\sigma^2}\mu_i^t \mu_i + \ln P(\omega_i)$$

(w_{i0} "próg" dla i-tej klasy)

- Klasyfikator wykorzystujący liniową f. klasyfikującą nazywany jest maszyną liniową

- Powierzchnia decyzyjna składa się z kawałków hiperpłaszczyzn określonych następująco:

$$g_i(x) = g_j(x)$$

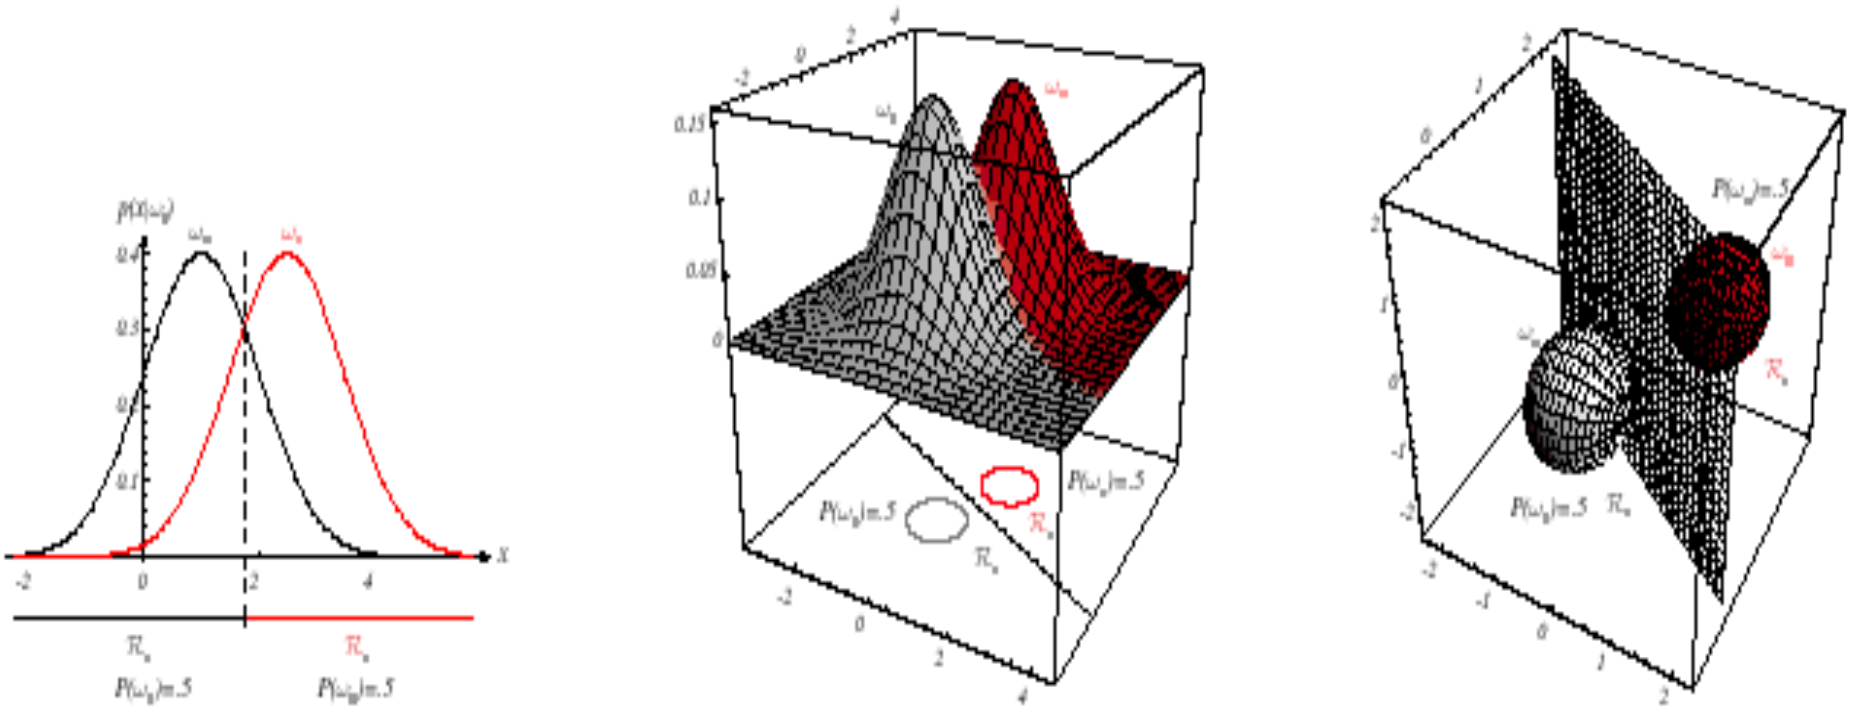


FIGURE 2.10. If the covariance matrices for two distributions are equal and proportional to the identity matrix, then the distributions are spherical in d dimensions, and the boundary is a generalized hyperplane of $d-1$ dimensions, perpendicular to the line separating the means. In these one-, two-, and three-dimensional examples, we indicate $p(\mathbf{x}|\omega_i)$ and the boundaries for the case $P(\omega_1) = P(\omega_2)$. In the three-dimensional case, the grid plane separates $\mathcal{R}_1$ from $\mathcal{R}_2$. From: Richard O. Duda, Peter E. Hart, and David G. Stork, *Pattern Classification*. Copyright © 2001 by John Wiley & Sons, Inc.

- Hiperpłaszczyzna rozdzielająca $\mathcal{R}_i$ i $\mathcal{R}_j$:

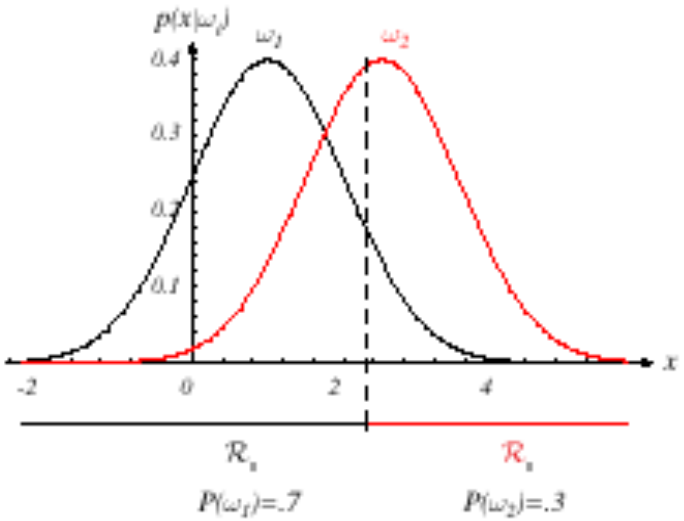
$$w^T(x - x_0 = 0)$$

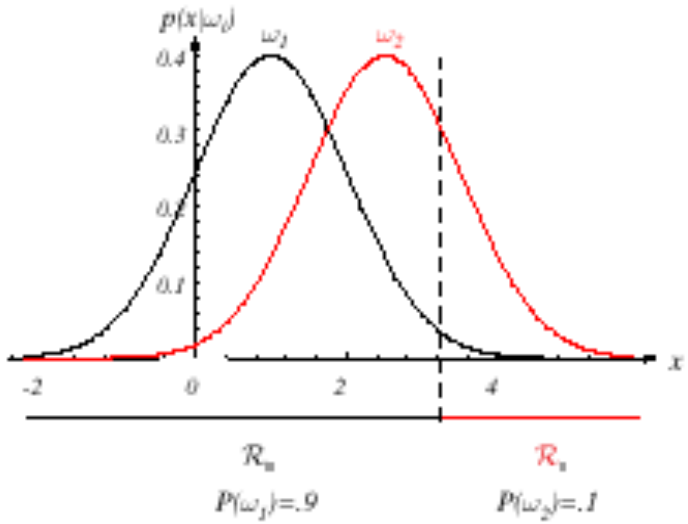
$$w = \mu_i - \mu_j$$

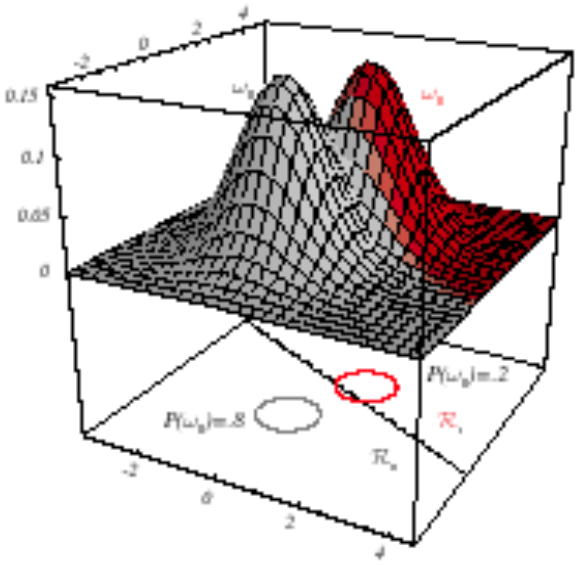
$$x_0 = \frac{1}{2}(\mu_i + \mu_j) - \frac{\sigma^2}{\|\mu_i - \mu_j\|^2} \ln \frac{P(\omega_i)}{P(\omega_j)}(\mu_i - \mu_j)$$

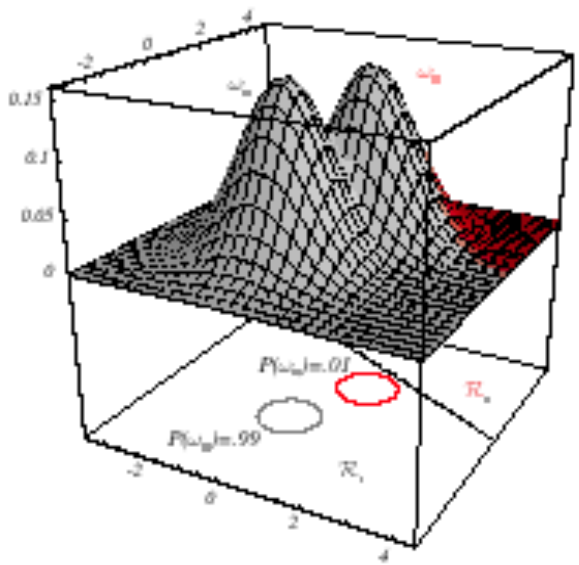
jest ortogonalna do linii łączącej średnie rozkładów!

$$\text{jeśli } P(\omega_i) = P(\omega_j) \text{ wtedy } x_0 = \frac{1}{2}(\mu_i + \mu_j)$$


p(x|ωj)
ω1
ω2
0.4
0.3
0.2
0.1
x
-2
0
2
4
P(ω1)=.7
P(ω2)=.3


p(x|ωj)
ω1
ω2
0.4
0.3
0.2
0.1
x
-2
0
2
4
P(ω1)=.9
P(ω2)=.1


0.15
0.1
0.05
0
P(ω2)=.2
P(ω1)=.8


0.15
0.1
0.05
0
P(ω2)=.01
P(ω1)=.99

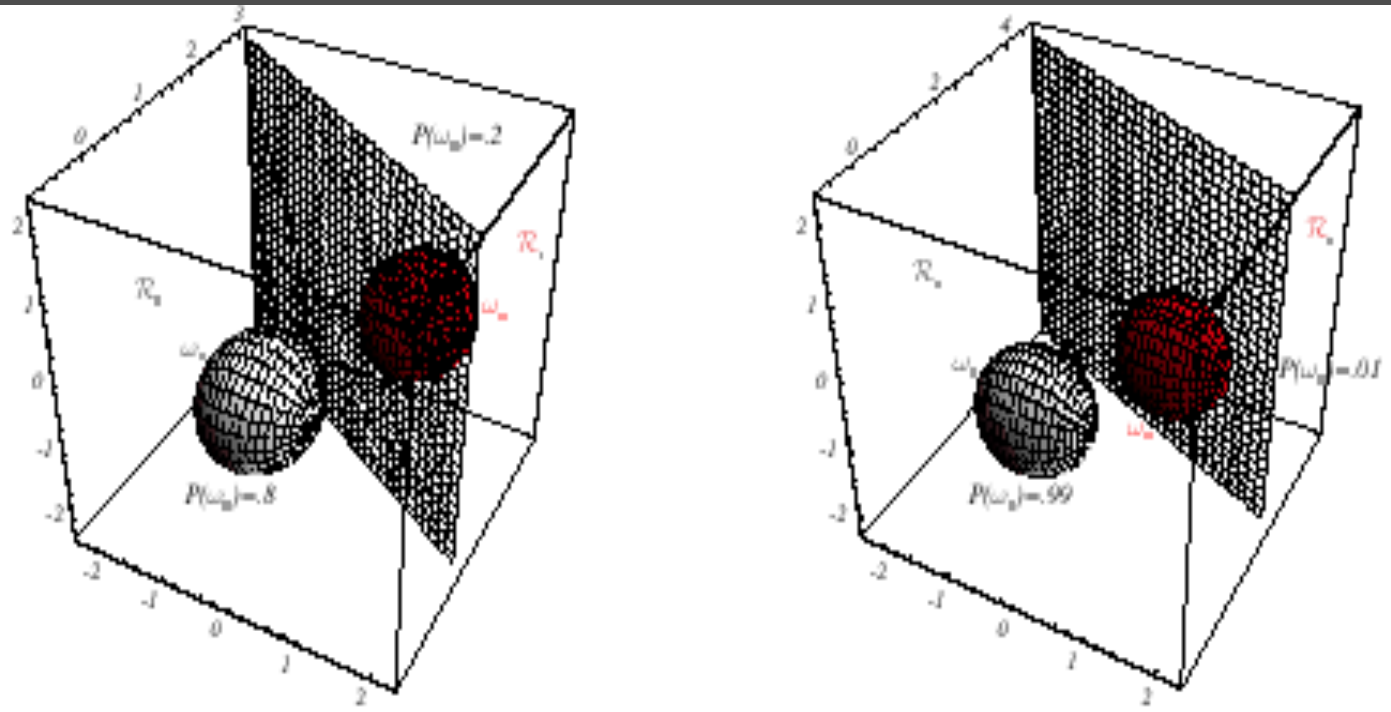


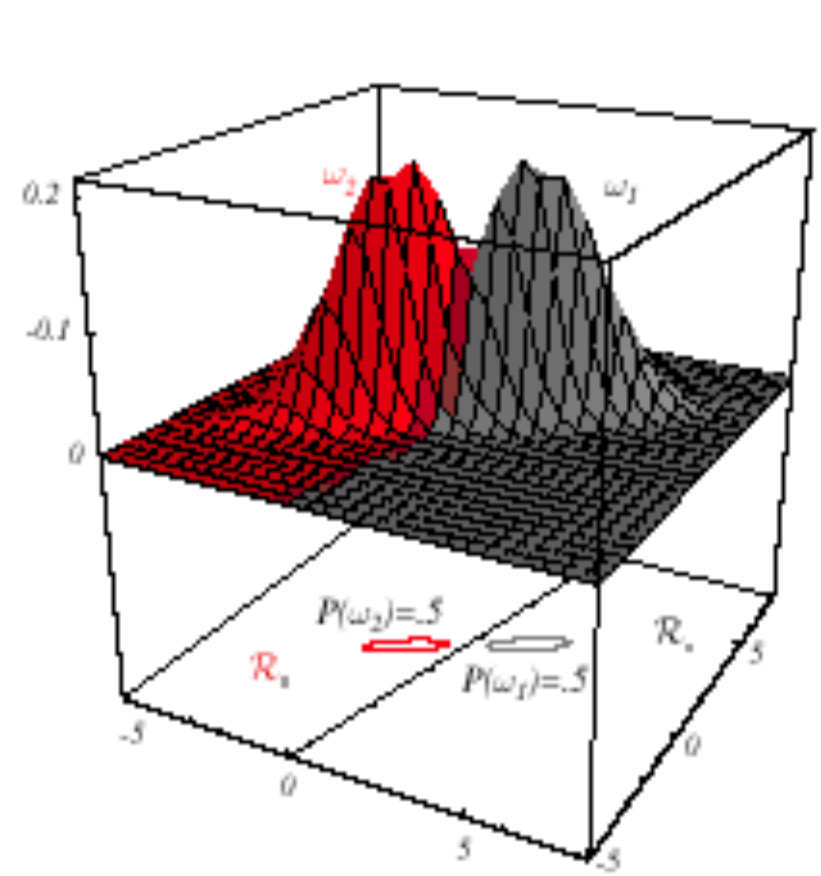
FIGURE 2.11. As the priors are changed, the decision boundary shifts; for sufficiently disparate priors the boundary will not lie between the means of these one-, two- and three-dimensional spherical Gaussian distributions. From: Richard O. Duda, Peter E. Hart, and David G. Stork, *Pattern Classification*. Copyright © 2001 by John Wiley & Sons, Inc.

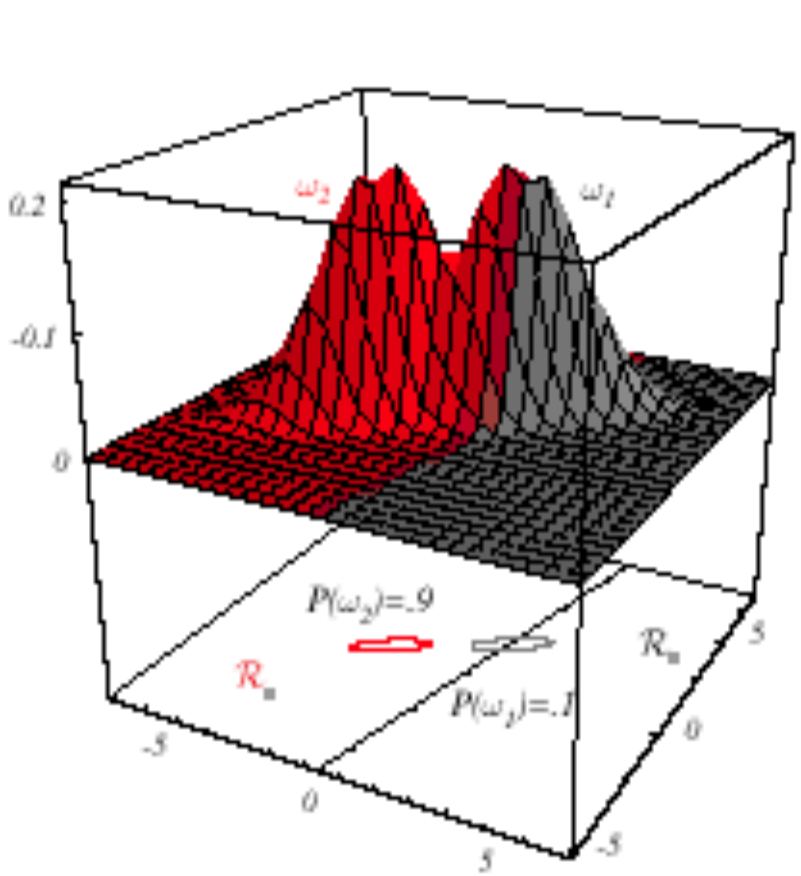
- Case $\Sigma_i = \Sigma$ (macierze kowariancji klas są jednakowe ale dowolne)

  - Hiperpłaszczyzny $\mathcal{R}_i$ i $\mathcal{R}_j$

$$x_0 = \frac{1}{2}(\mu_i + \mu_j) - \frac{ln\left[P(\omega_i)/P(\omega_j)\right]}{(\mu_i - \mu_j)^t \Sigma^{-1}(\mu_i - \mu_j)} \cdot (\mu_i - \mu_j)$$

(hiperpłaszczyzna rozdzielająca obszary $\mathcal{R}_i$ and $\mathcal{R}_j$ w ogólnym przypadku nie jest ortogonalna do odcinka łączącego średnie rozkładów)


0.2
-0.1
0
ω_2
ω_1
$P(\omega_2)=.5$
$P(\omega_1)=.5$
$\mathcal{R}_2$
$\mathcal{R}_1$
-5
0
5
-5
0
5


0.2
-0.1
0
ω_2
ω_1
$P(\omega_2)=.9$
$P(\omega_1)=.1$
$\mathcal{R}_2$
$\mathcal{R}_1$
-5
0
5
-5
0
5

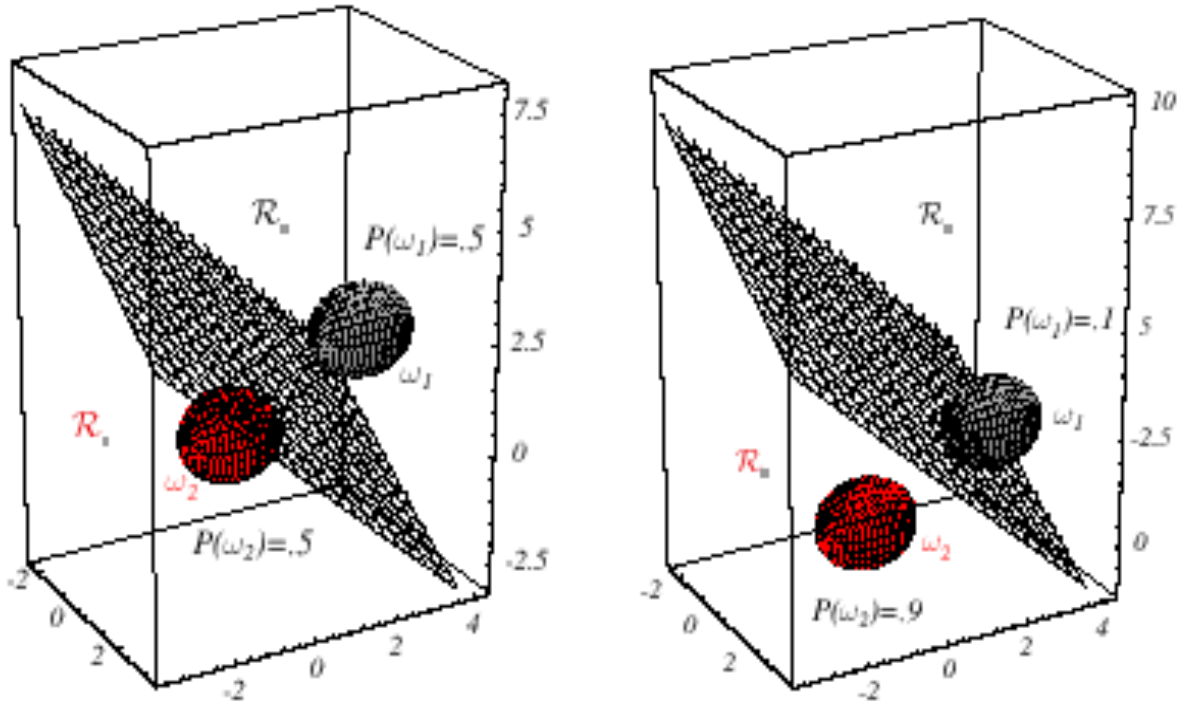


FIGURE 2.12. Probability densities (indicated by the surfaces in two dimensions and ellipsoidal surfaces in three dimensions) and decision regions for equal but asymmetric Gaussian distributions. The decision hyperplanes need not be perpendicular to the line connecting the means. From: Richard O. Duda, Peter E. Hart, and David G. Stork, *Pattern Classification*. Copyright © 2001 by John Wiley & Sons, Inc.

- Przypadek Σ_i = dowolne

$$g_i(x) = x^t W_i x + w_i^t x = w_{i0}$$

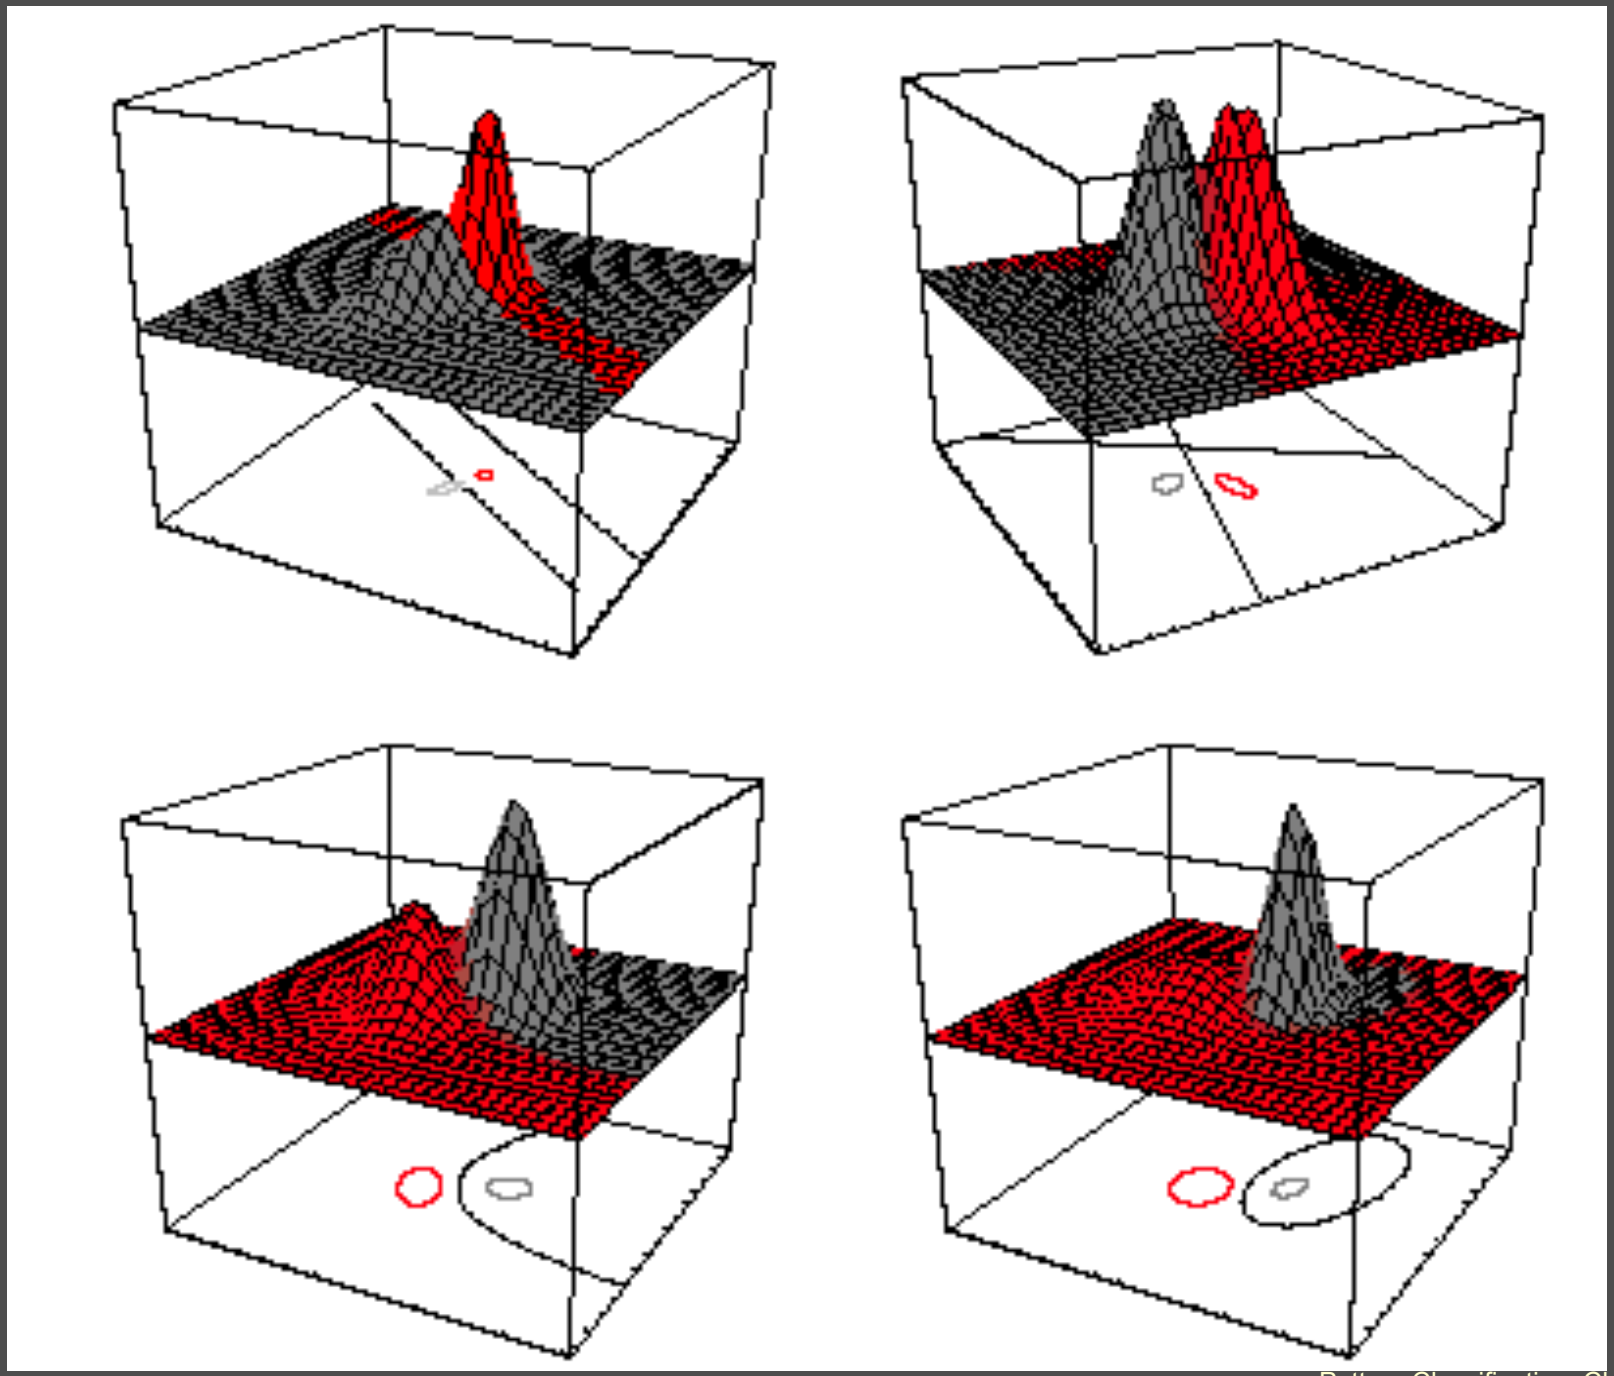
$$gdzie:$$

$$\mathrm{W_i} = -\frac{1}{2}\Sigma_i^{-1}$$

$$\mathrm{w_i} = \Sigma_i^{-1}\mu_i$$

$$\mathrm{w}_{i0} = -\frac{1}{2}\mu_i^t\Sigma_i^{-1}\mu_i - \frac{1}{2}\ln|\Sigma_i| + \ln P(\omega_i)$$

(Hyperquadrics which are: hyperplanes, pairs of hyperplanes, hyperspheres, hyperellipsoids, hyperparaboloids, hyperhyperboloids)



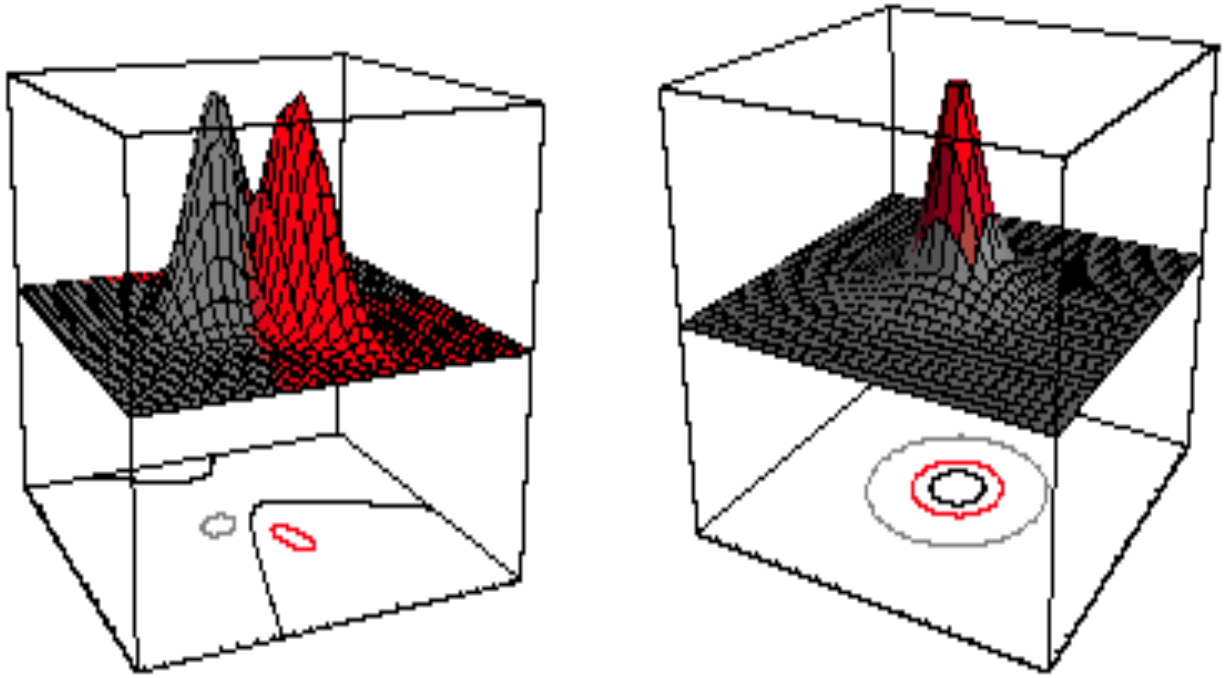


FIGURE 2.14. Arbitrary Gaussian distributions lead to Bayes decision boundaries that are general hyperquadrics. Conversely, given any hyperquadric, one can find two Gaussian distributions whose Bayes decision boundary is that hyperquadric. These variances are indicated by the contours of constant probability density. From: Richard O. Duda, Peter E. Hart, and David G. Stork, *Pattern Classification*. Copyright © 2001 by John Wiley & Sons, Inc.

Naiwny klasyfikator Baesowski

- Konstrukcja klasyfikatora Bayesa wymaga znajomości warunkowych rozkładów w klasach

$$P(x \mid \omega_i);\ i=1,2,\ldots,c$$

- Zazwyczaj rozkłady te nie są znane a jedyna informacja o badanej populacji zawarta jest w skończonym zbiorze uczącym
- Podejście Bayesa do klasyfikacji wymaga zatem estymacji warunkowych rozkładów w klasach
- Zadanie to nie jest trywialne, szczególnie dla dużej liczby cech

Naiwny klasyfikator Baesowski

- Naiwny klasyfikator Baesowski (ang. Naive Bayes Classifier, Idiot's Bayes) zakłada, że poszczególne cechy są wzajemnie niezależne
- Dzięki powyższemu założeniu warunkowy rozkład w *i*-tej klasie $P(x \mid \omega_i)$ może być wyrażony jako iloczyn jednowymiarowych rozkładów estymowanych osobno dla poszczególnych cech

$$P(x \mid \omega_i) = \prod_{j=1}^{d} P(x_j \mid \omega_i)$$

- Mimo naiwności czynionego założenia naiwny klasyfikator Bayesowski często daje bardzo dobre rezultaty