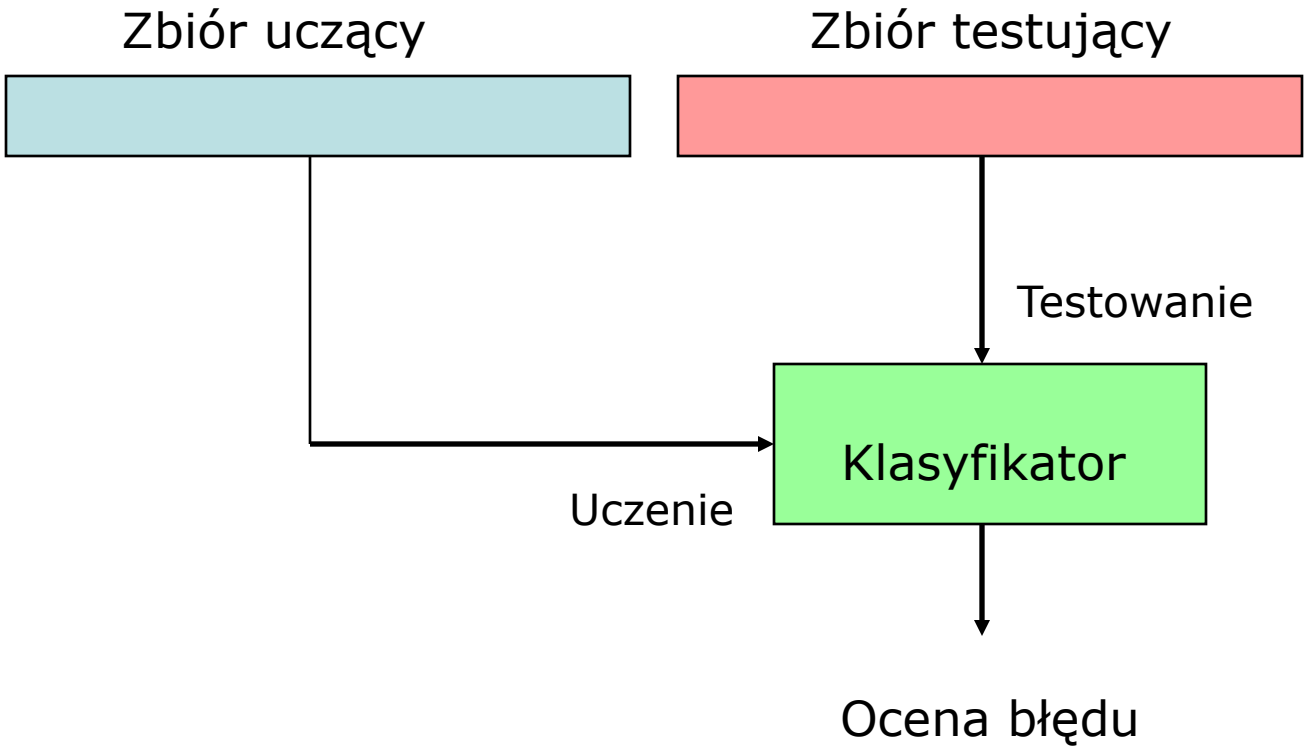
Metody oceny skuteczności systemów rozpoznających c.d.

Krzysztof Fujarewicz

Schematy walidacji

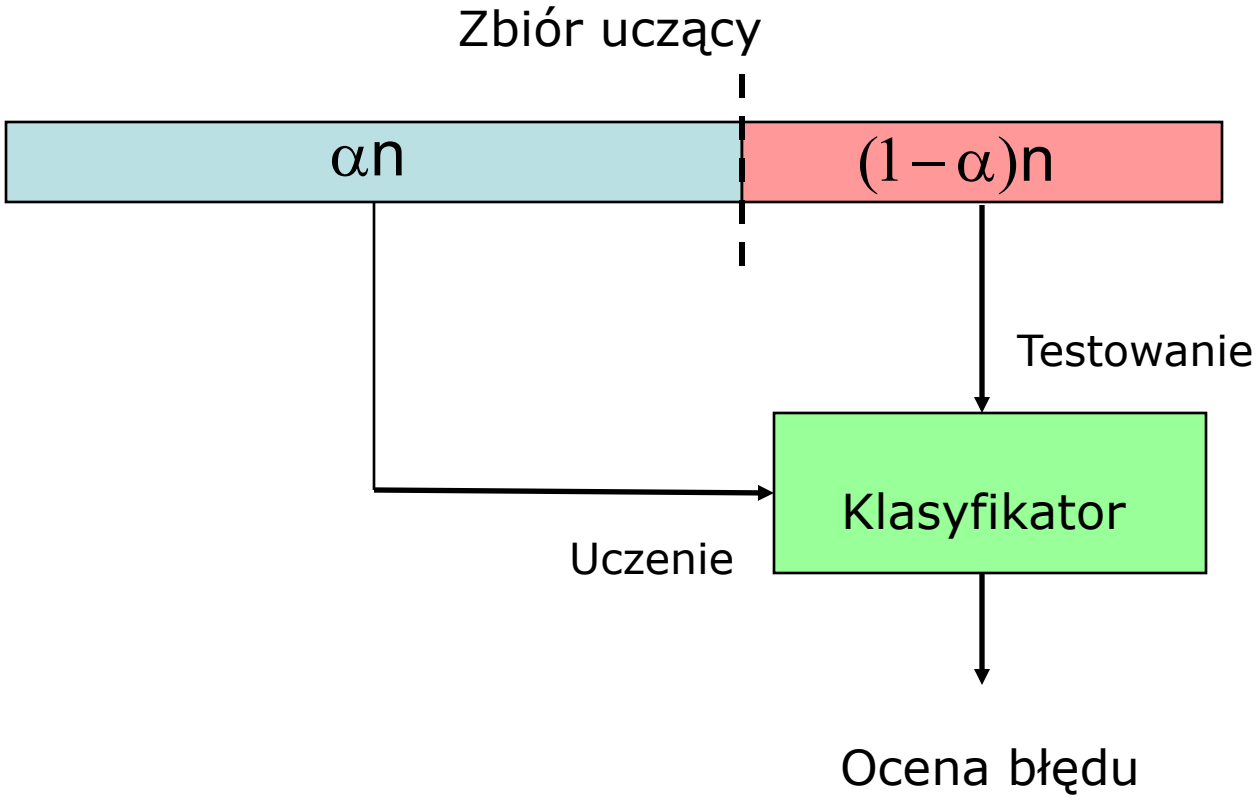
Gdy dysponujemy dwoma zbiorami



Schematy walidacji

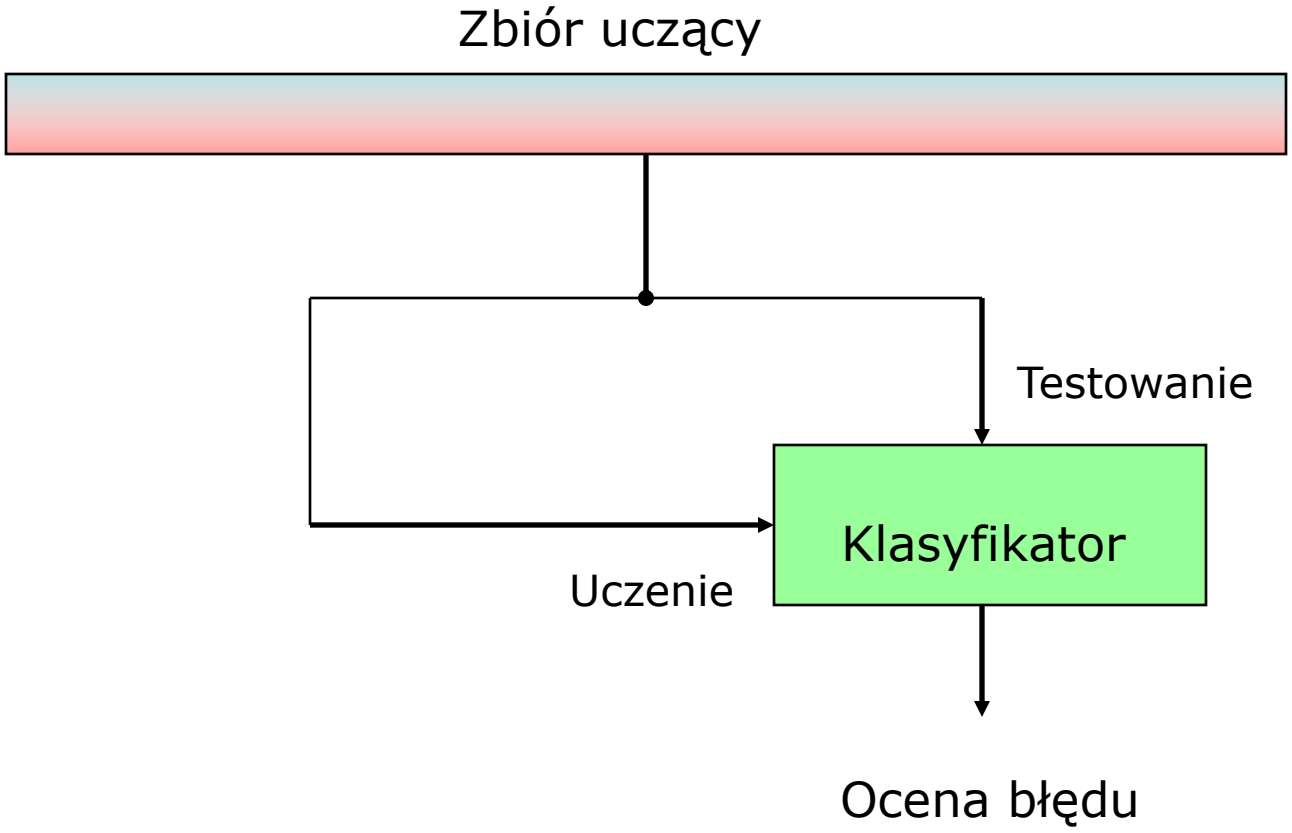
Zazwyczaj dysponujemy jednym zbiorem

Hold-out



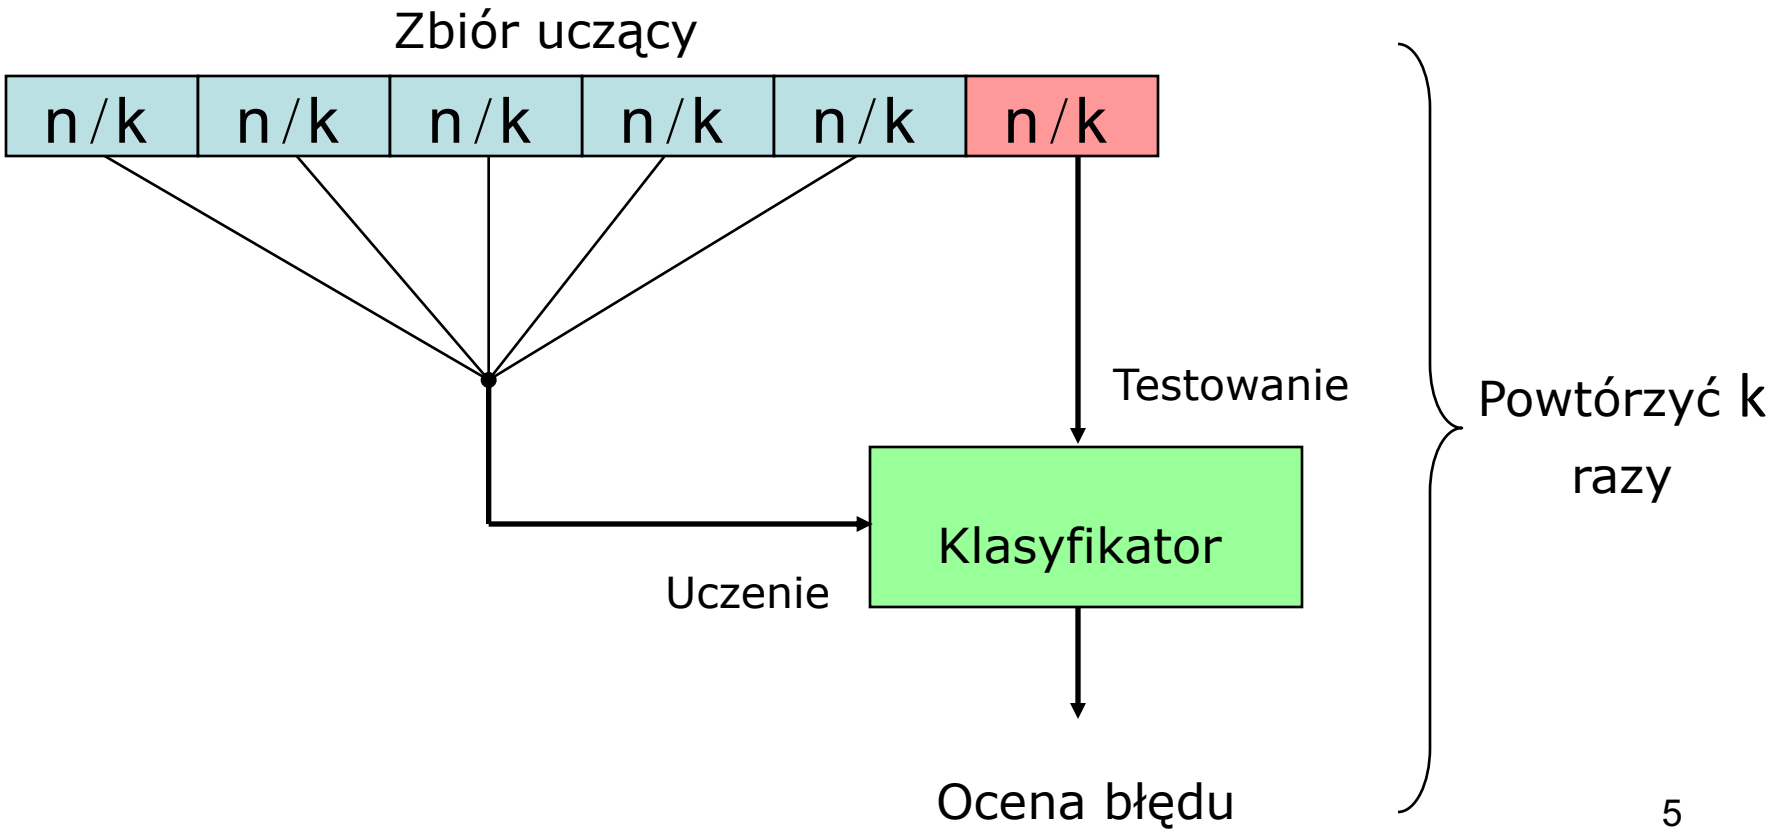
Schematy walidacji

Resubstytucja



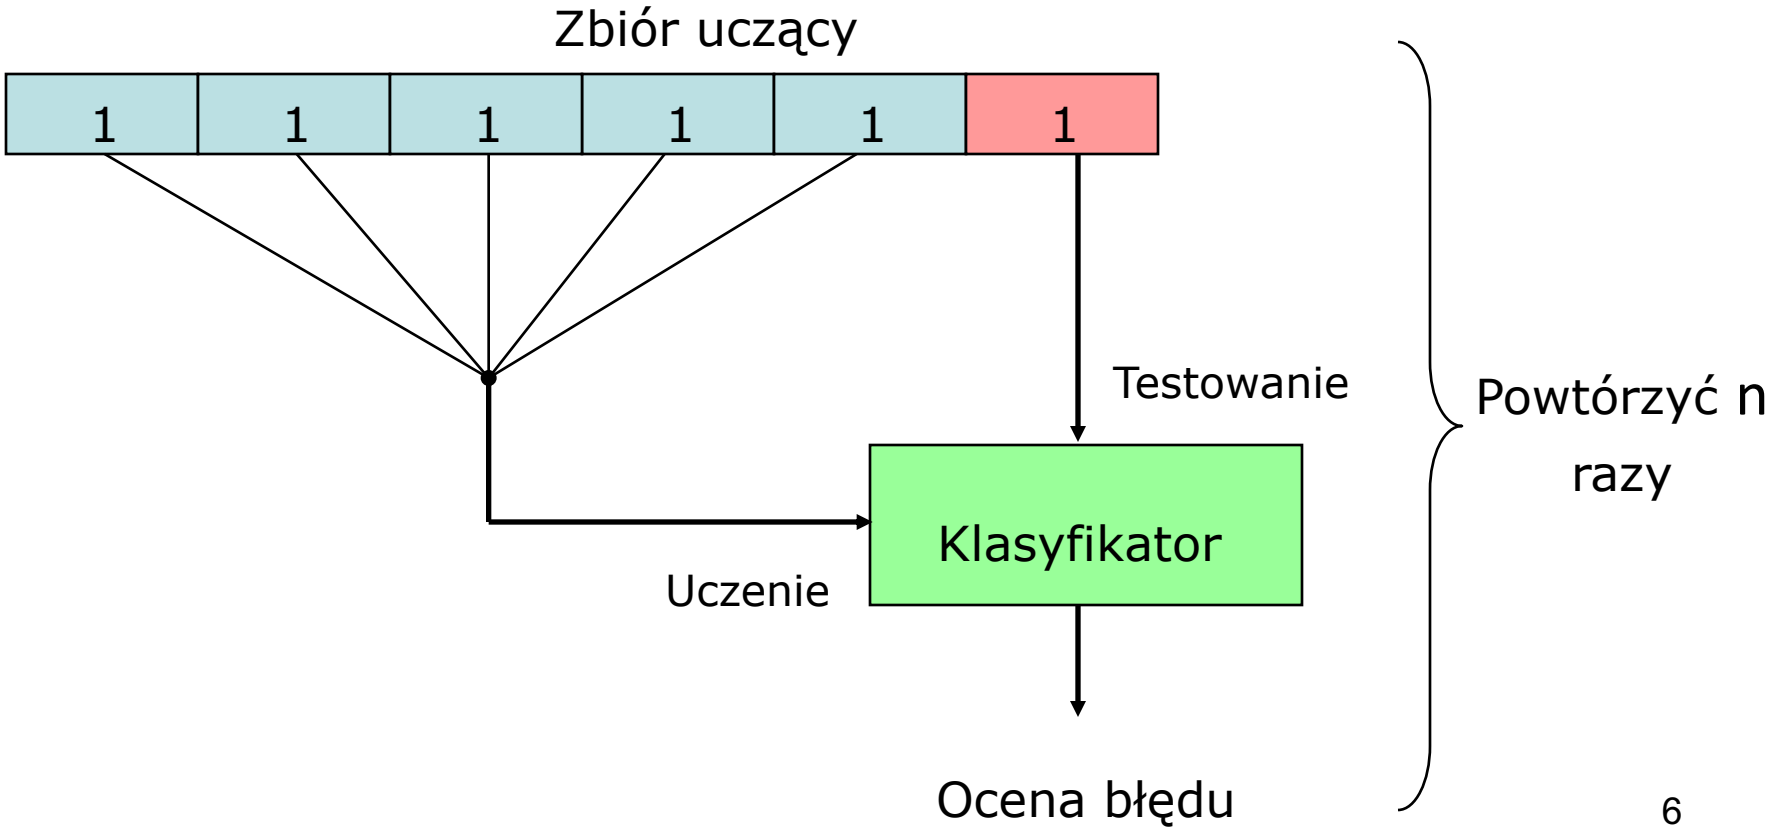
Schematy walidacji

k-krotna kroswalidacja



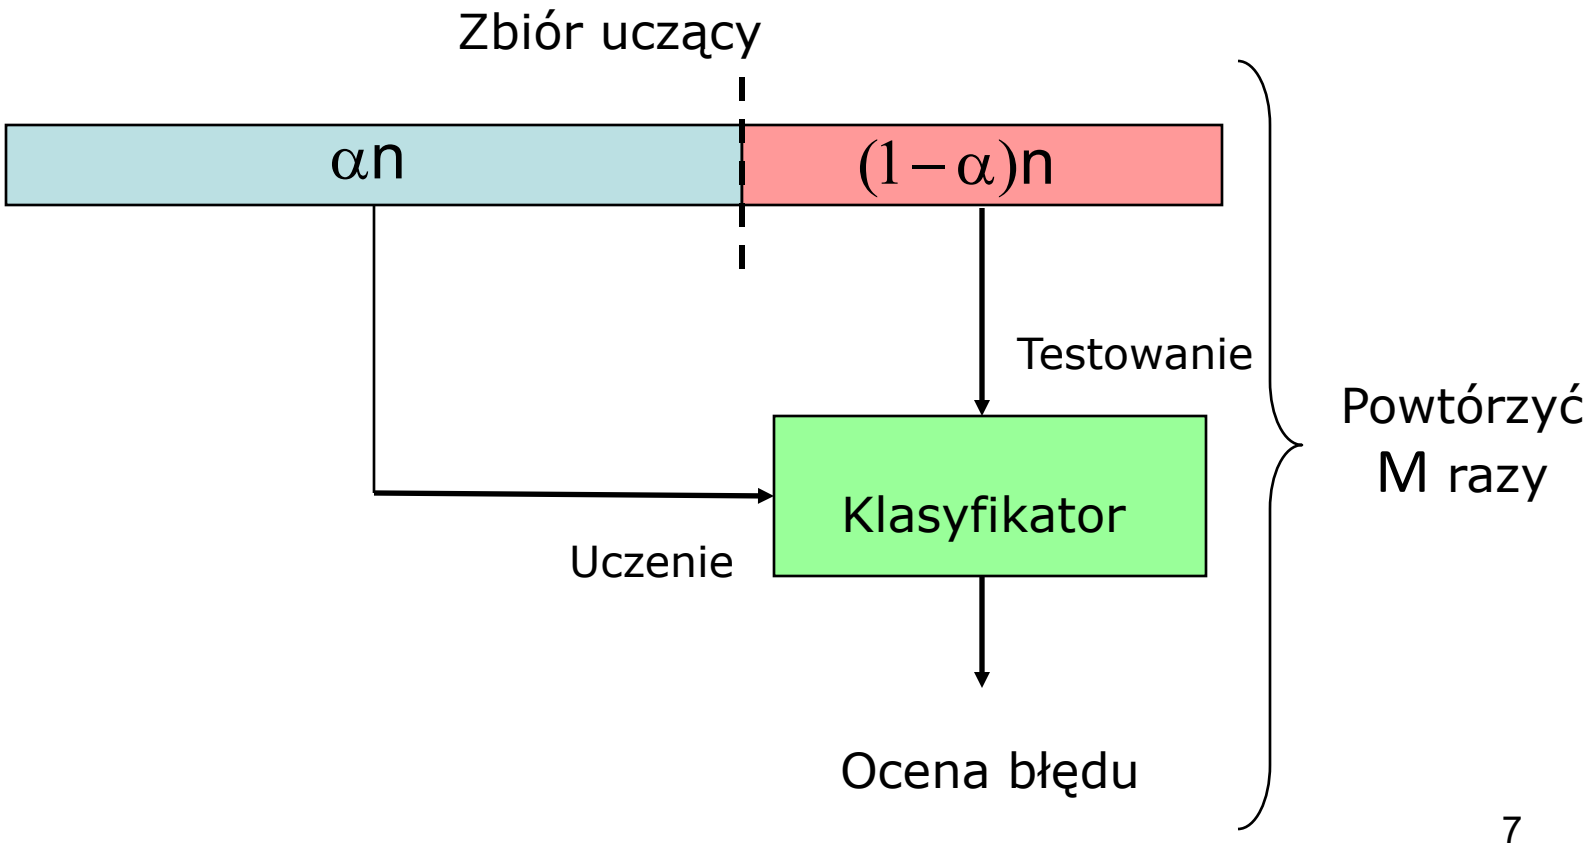
Schematy walidacji

Leave-one-out kroswalidacja



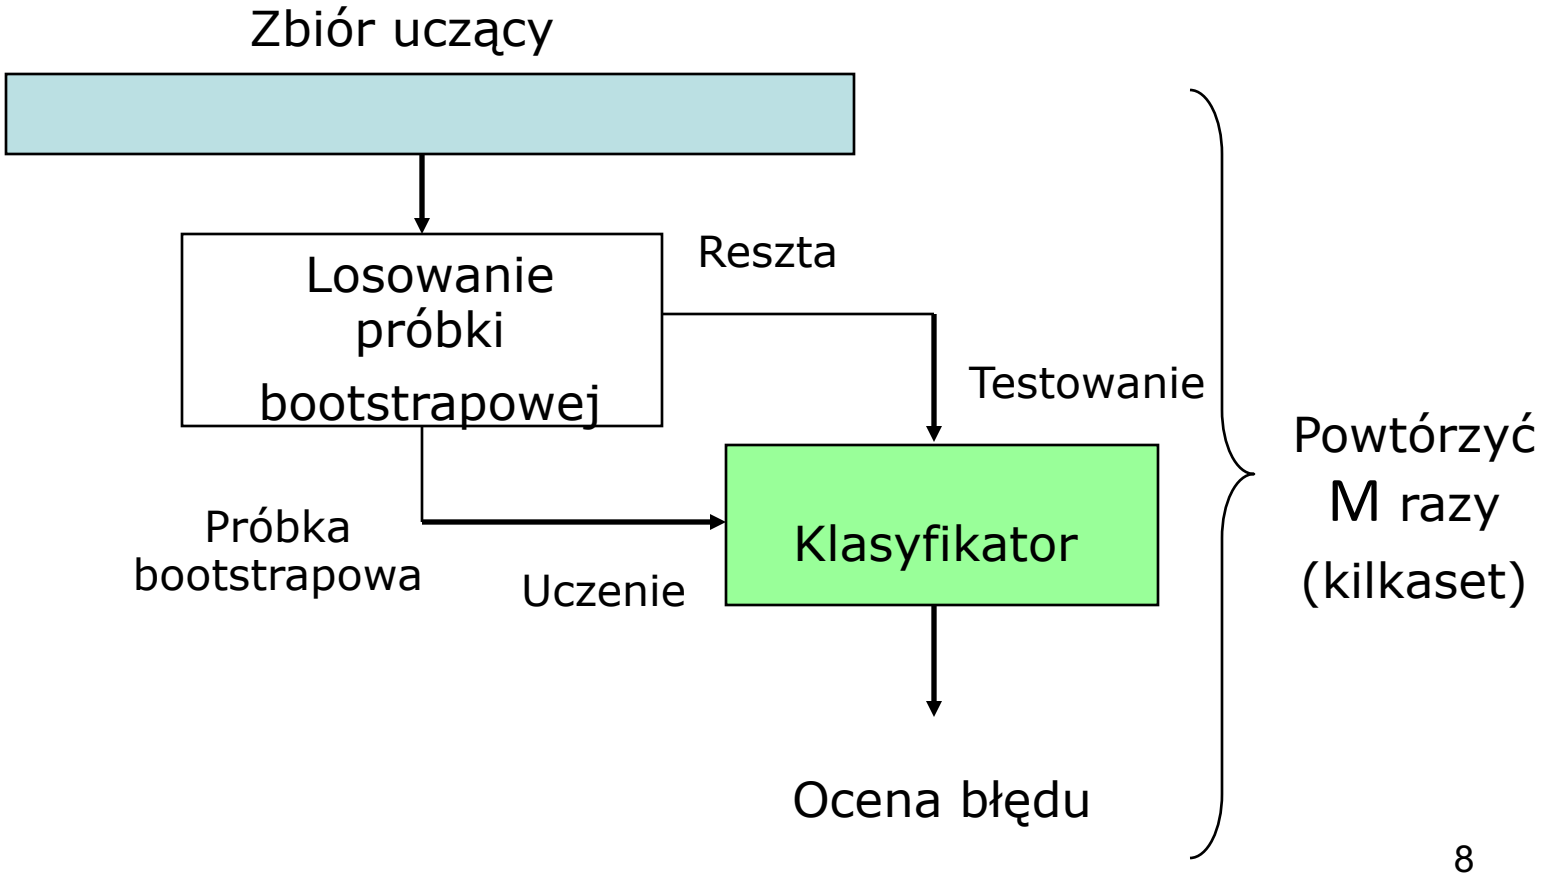
Schematy walidacji

Kroswalidacja Monte-Carlo (MCCV)



Schematy walidacji

Bootstrap



Schematy walidacji - porównanie

Obciążenie estymatorów błędów

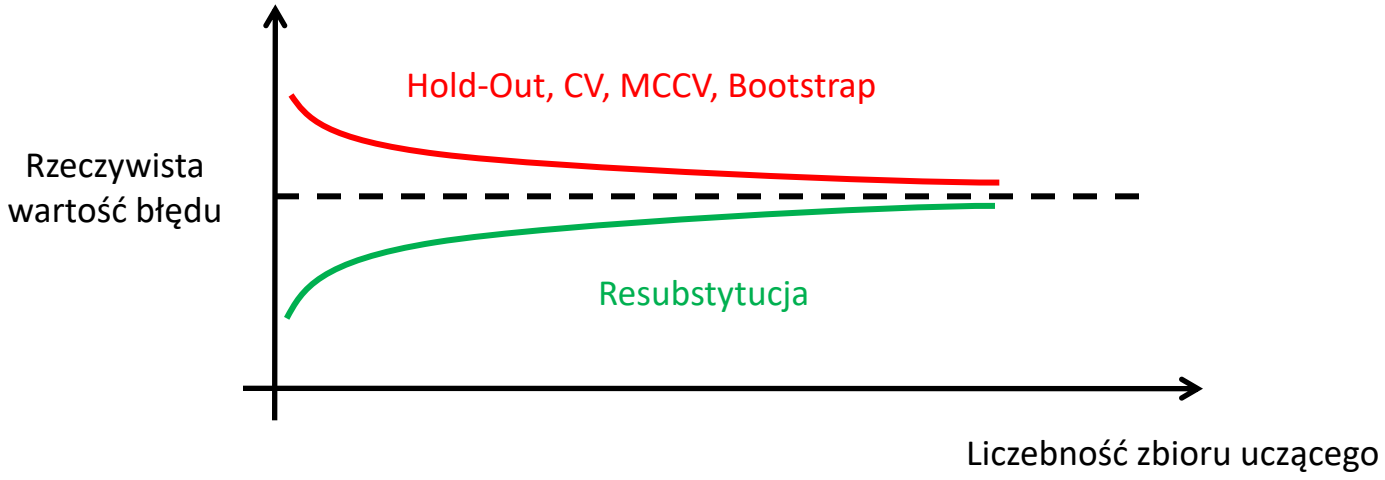
- „Optymistyczne” – Resubstytucja
- „Pesymistyczne” – pozostałe wymienione: Hold-Out, CV, MCCV, Bootstrap

Schematy walidacji - porównanie

Obciążenie estymatorów błędów

- „Optymistyczne” – Resubstytucja
- „Pesymistyczne” – pozostałe wymienione: Hold-Out, CV, MCCV, Bootstrap

Zależność obciążenia od liczebności próby



Redukcja obciążenia

Bootstrap 632

Można pokazać, że próbka bootstrapowa zawiera średnio

$$e^{-1} \cdot n = 0.632 \cdot n$$

elementów zbioru uczącego (niektóre mogą się powtarzać).

Wprowadza się modyfikację:

$$\varepsilon_{632} = 0.632 \cdot \varepsilon_{boot} + (1 - 0.632) \cdot \varepsilon_{resub}$$

Efron, B. (1983), Estimating the error rate of the prediction rule: improvement on cross-validation, J. Am. Stat. Assoc., vol. 78, 316-331.

Redukcja obciążenia

Bootstrap 632

Można pokazać, że próbka bootstrapowa zawiera średnio

$$e^{-1} \cdot n = 0.632 \cdot n$$

elementów zbioru uczącego (niektóre mogą się powtarzać).

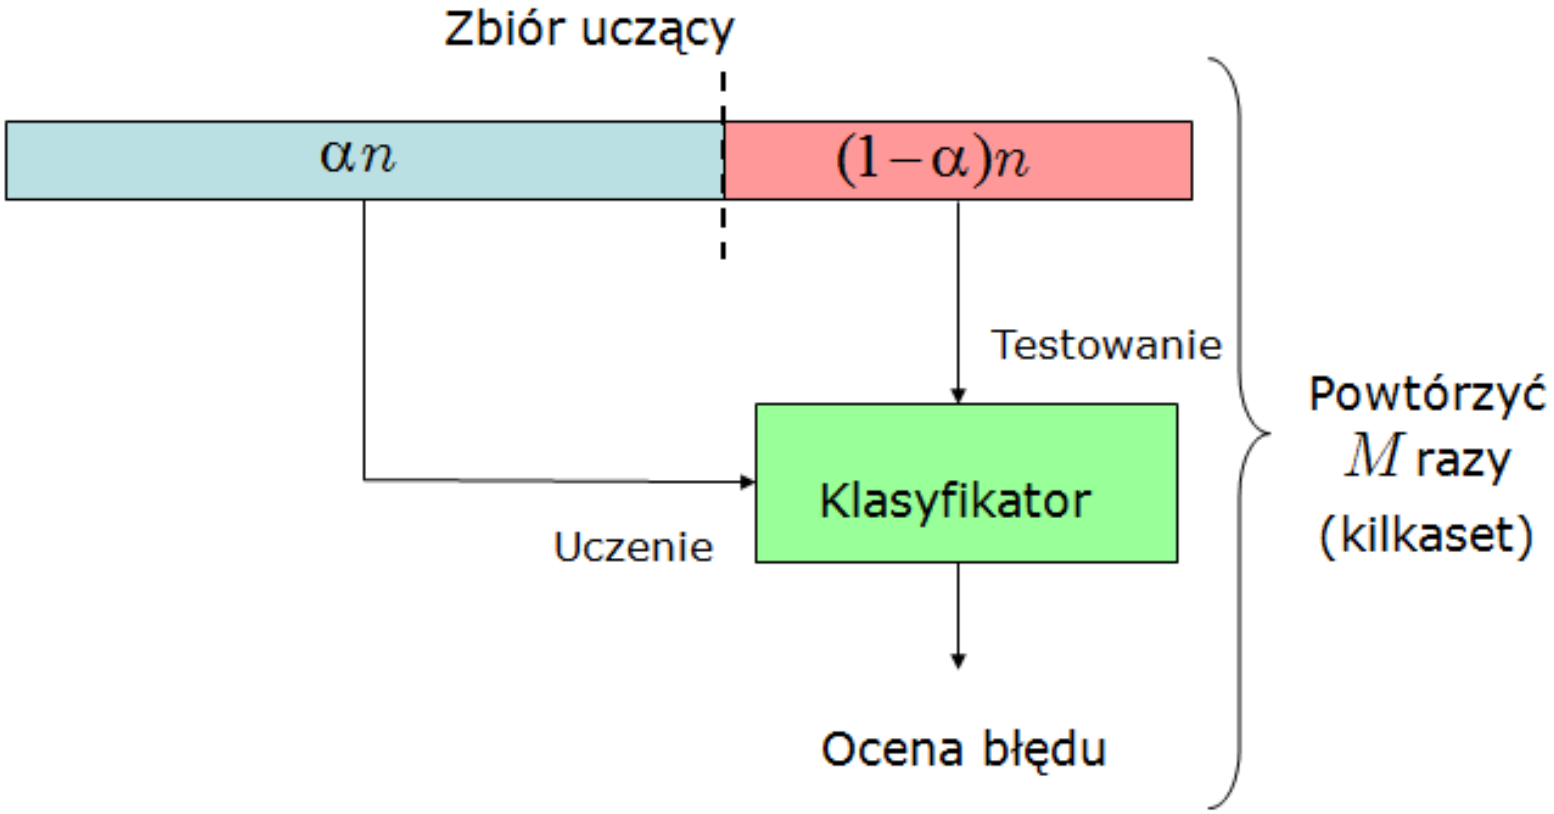
Wprowadza się modyfikację:

$$\varepsilon_{632} = 0.632 \cdot \varepsilon_{boot} + (1 - 0.632) \cdot \varepsilon_{resub}$$

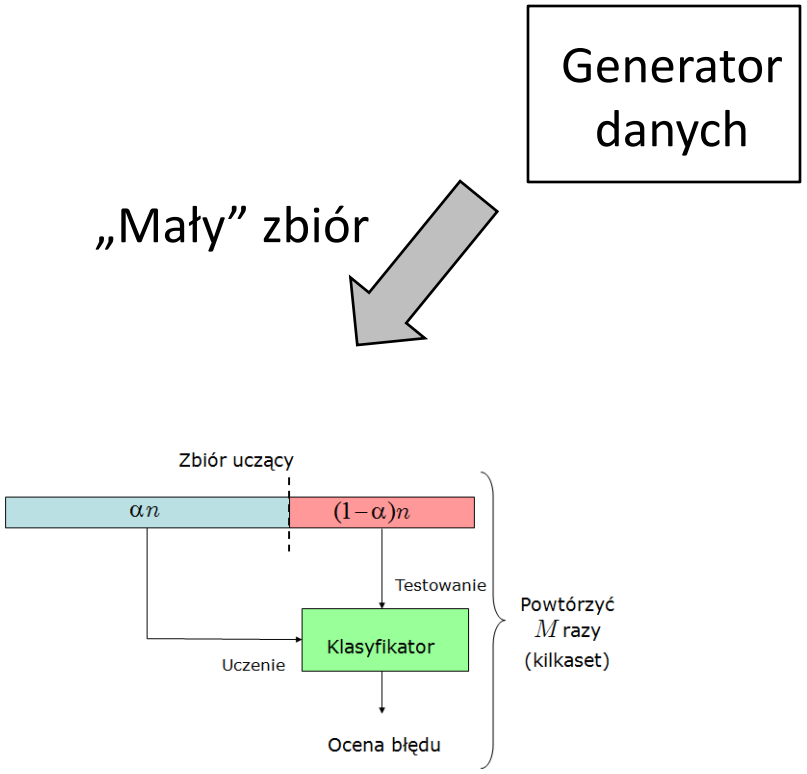
Efron, B. (1983), Estimating the error rate of the prediction rule: improvement on cross-validation, J. Am. Stat. Assoc., vol. 78, 316-331.

Inny wariant: Bootstrap 632+

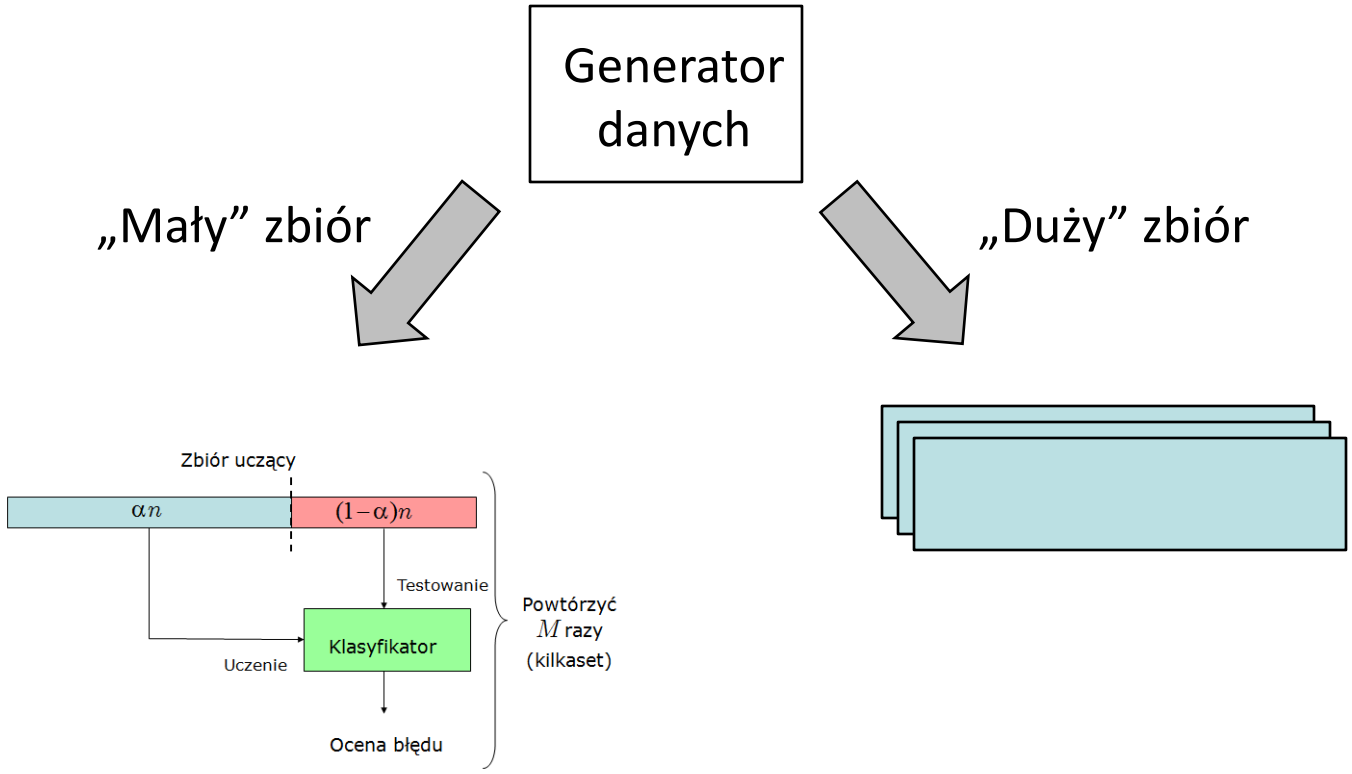
Badanie własności estymatora błędu



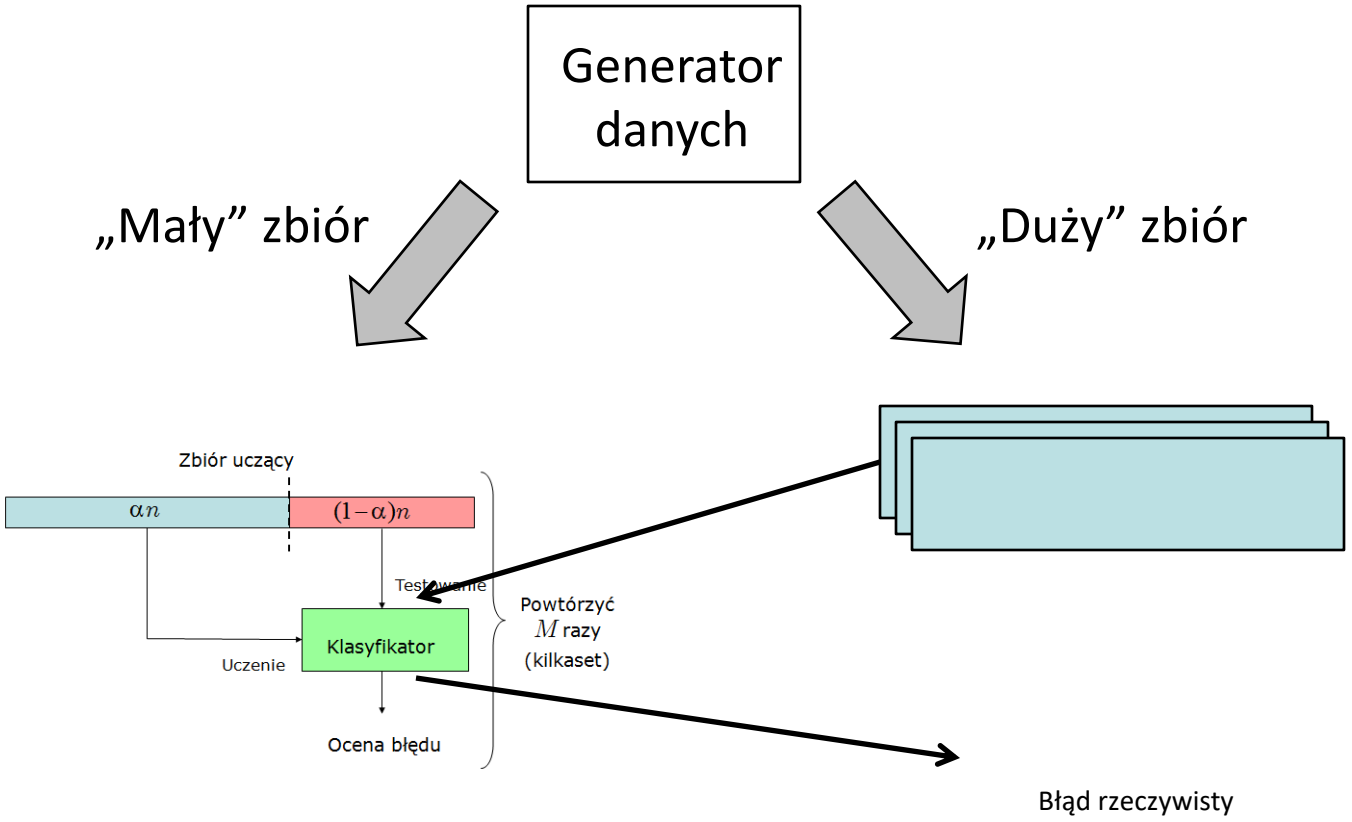
Badanie własności estymatora błędu



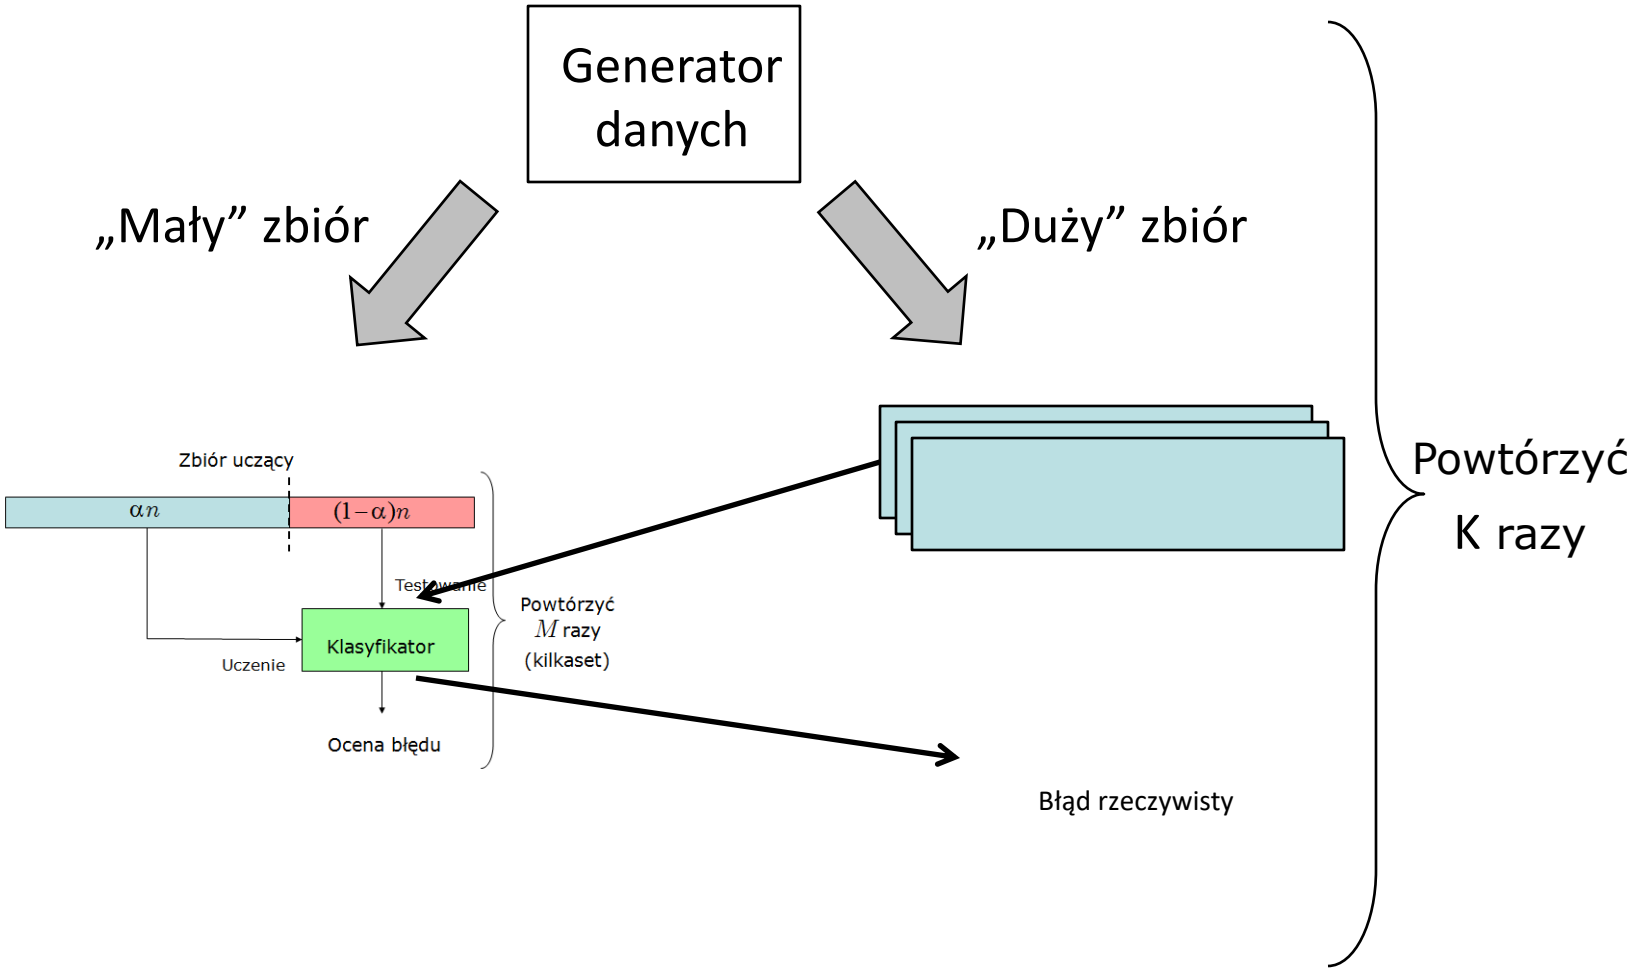
Badanie własności estymatora błędu



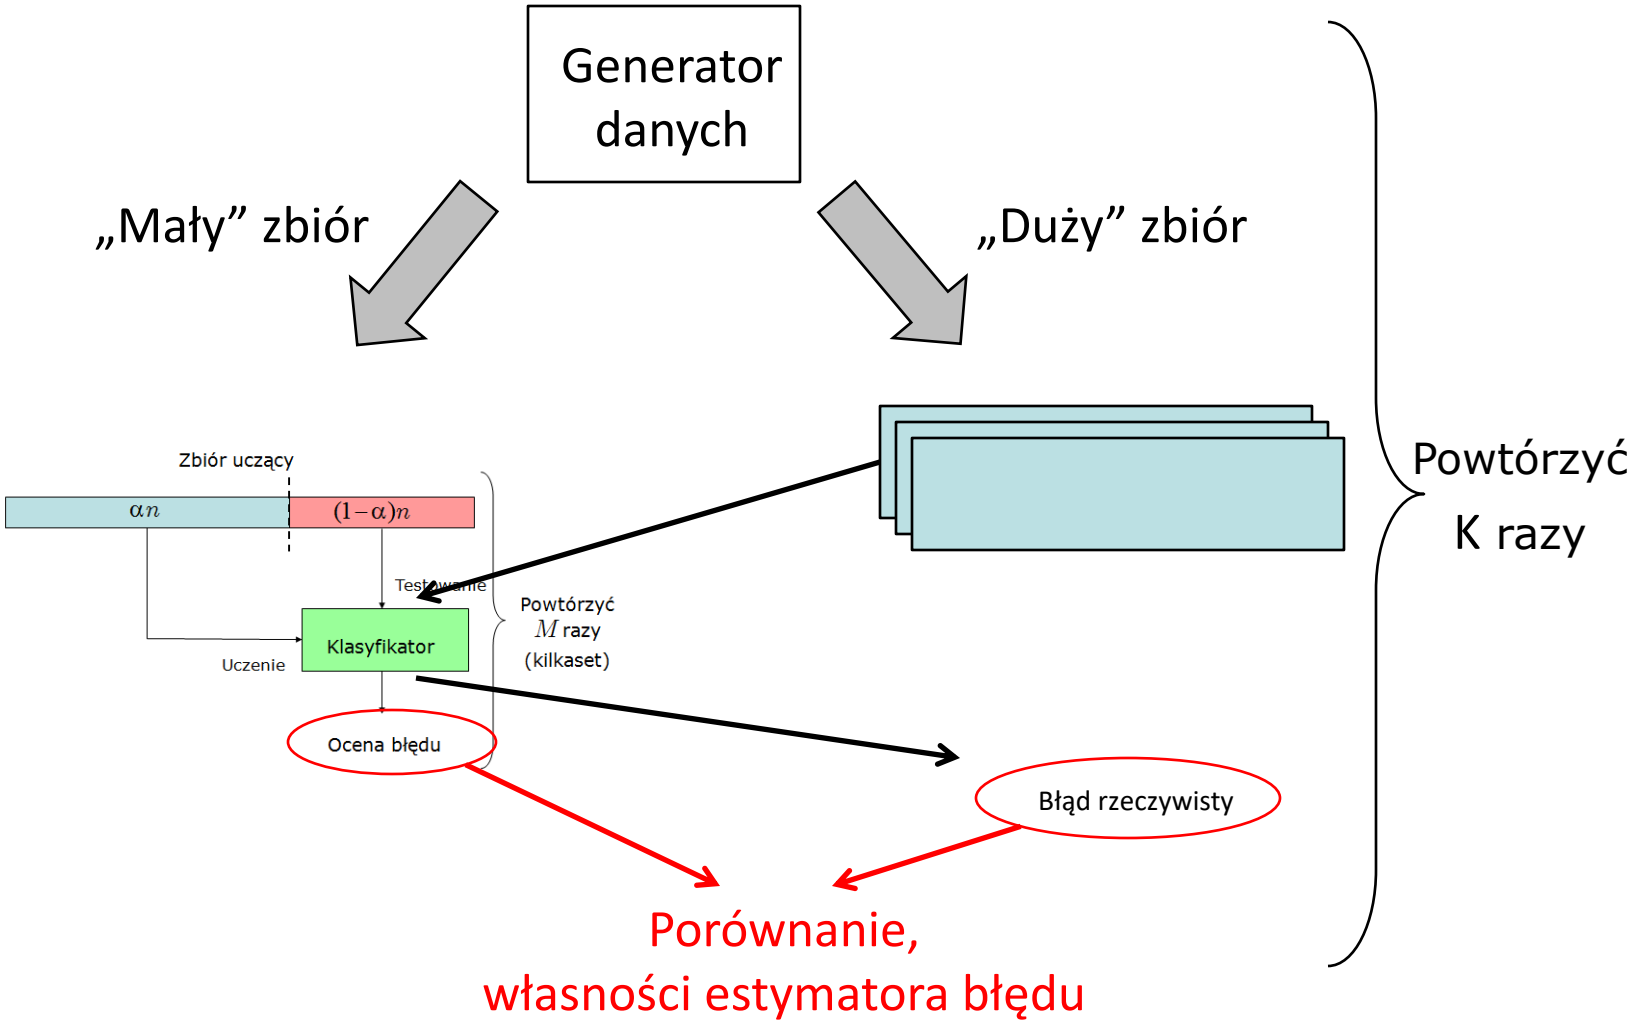
Badanie własności estymatora błędu



Badanie własności estymatora błędu



Badanie własności estymatora błędu

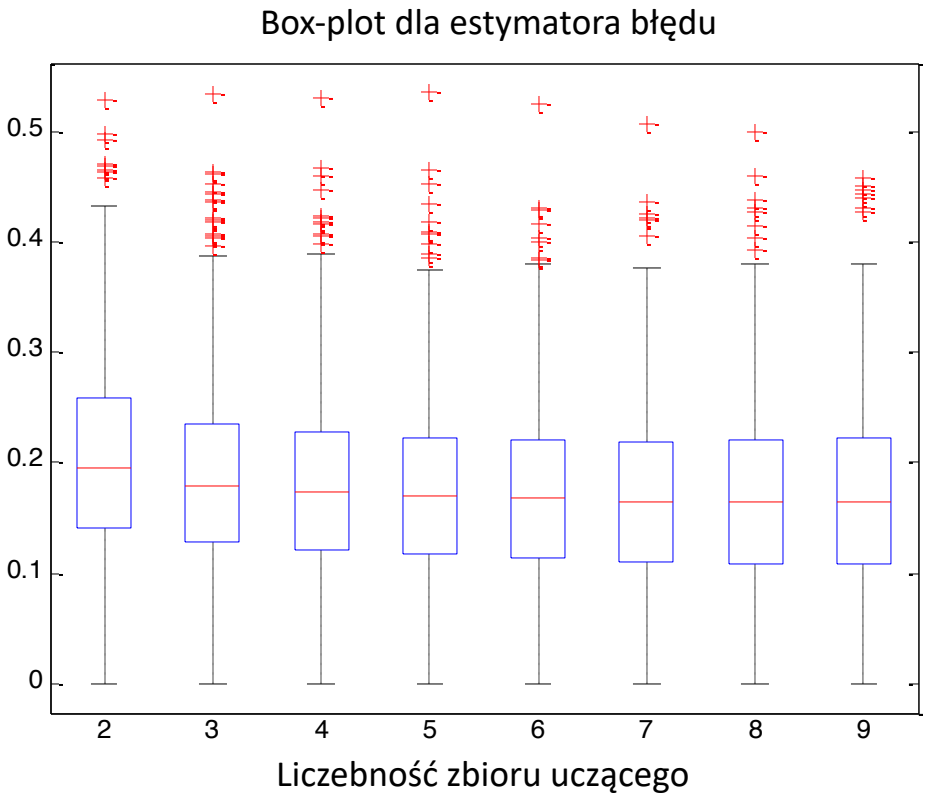


Wpływ liczebności zb. uczącego na własności estymatora błędu

Eksperyment numeryczny

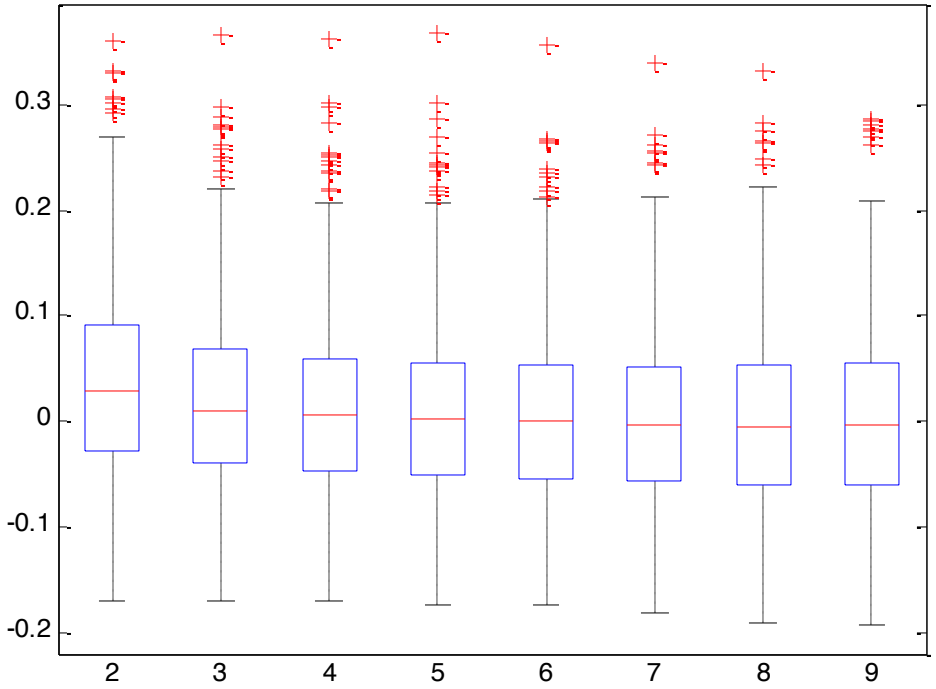
- Przestrzeń cech jednowymiarowa
- Dwie klasy – o rozkładach N(0,1) i N(1,1)
- Klasyfikator LDA
- Metoda oceny MC-CV, liczba iteracji M=100
- „Mały” zbiór (10+10) wzorców
- „Duży” zbiór” (10000+10000) wzorców
- Zmienna liczebność zbioru uczącego (2+2) … (9+9)
- Losowanie danych powtórzono K=1000 razy

Wpływ liczebności zb. uczącego na własności estymatora błędu

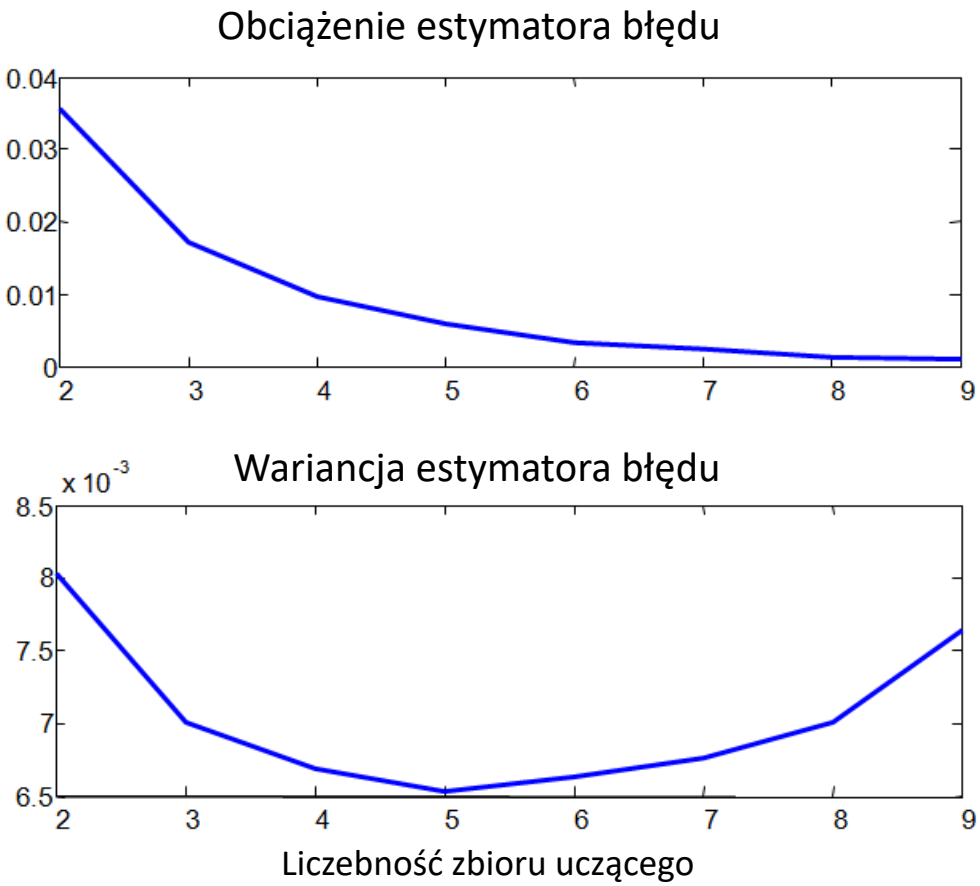


Wpływ liczebności zb. uczącego na własności estymatora błędu

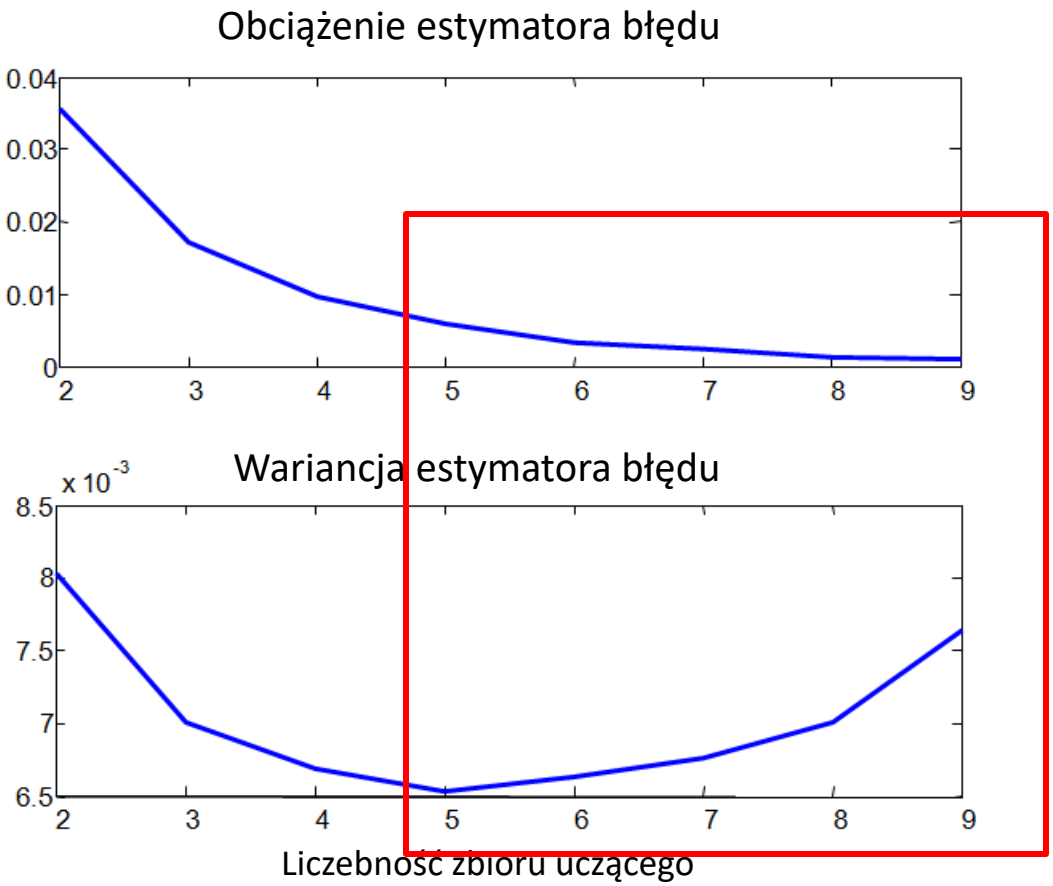
Box-plot dla różnic pomiędzy estymatorem błędu i wartością rzeczywistą



Wpływ liczebności zb. uczącego na własności estymatora błędu



Wpływ liczebności zb. uczącego na własności estymatora błędu



Przykład Kompromisu Bias/Variance

Wybór modelu

- Przykład aproksymacji nieliniowej funkcji
- Kompromis Bias-Variance
- Generalizacja i sposoby jej poprawy
- Regularyzacja

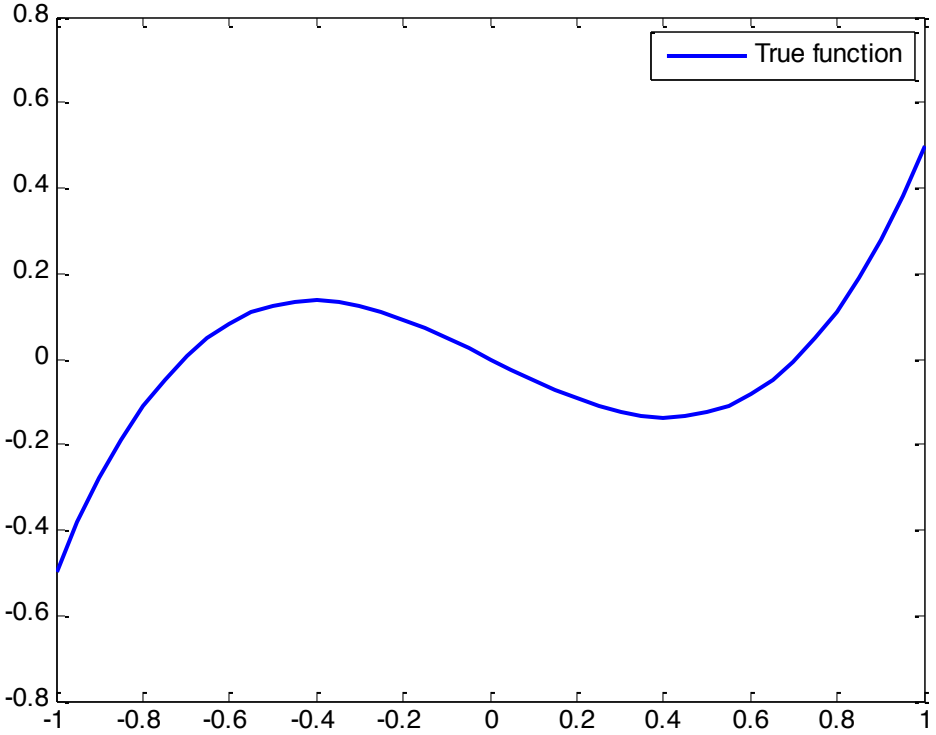
Zadanie aproksymacji funkcji

Znalezienie funkcji z zadanej klasy funkcji najlepiej dopasowanej (w sensie przyjętego kryterium) do posiadanych danych

Przykład aproksymacji

Klasa funkcji: wielomiany n-tego stopnia

Kryterium dopasowania: błąd średniokwadratowy



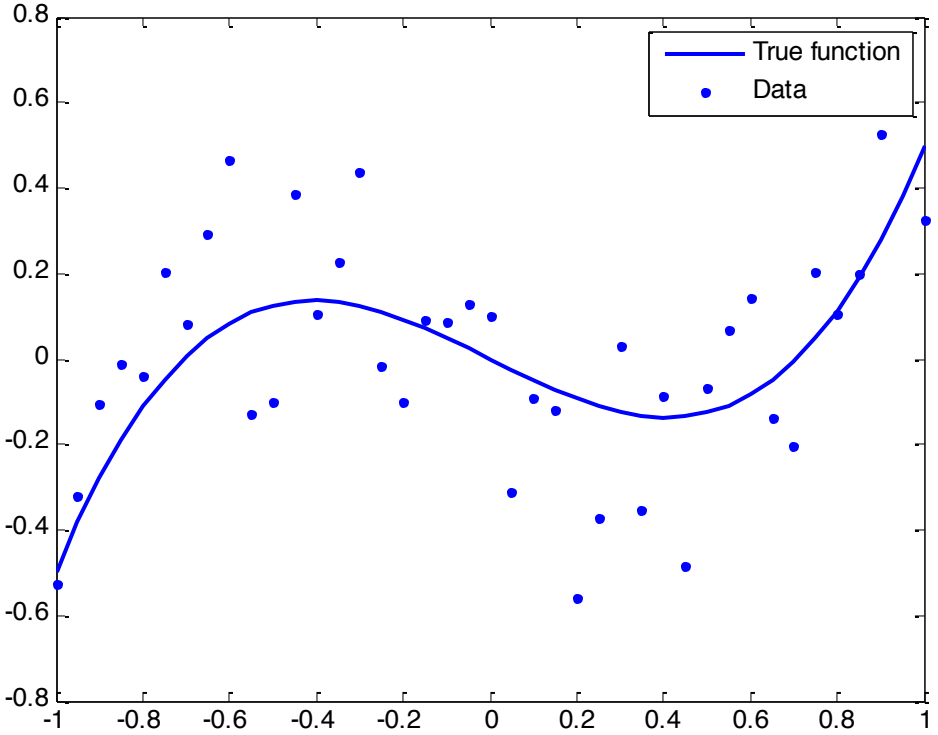
Zadanie aproksymacji funkcji

Znalezienie funkcji z zadanej klasy funkcji najlepiej dopasowanej (w sensie przyjętego kryterium) do posiadanych danych

Przykład aproksymacji

Klasa funkcji: wielomiany n-tego stopnia

Kryterium dopasowania: błąd średniokwadratowy



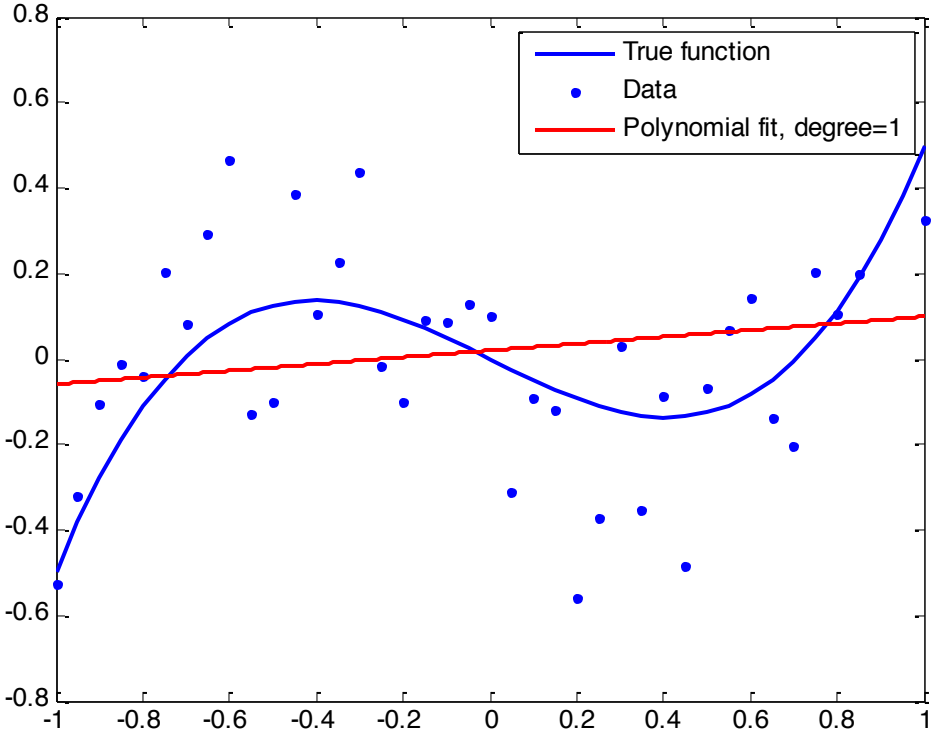
Zadanie aproksymacji funkcji

Znalezienie funkcji z zadanej klasy funkcji najlepiej dopasowanej (w sensie przyjętego kryterium) do posiadanych danych

Przykład aproksymacji

Klasa funkcji: wielomiany n-tego stopnia

Kryterium dopasowania: błąd średniokwadratowy



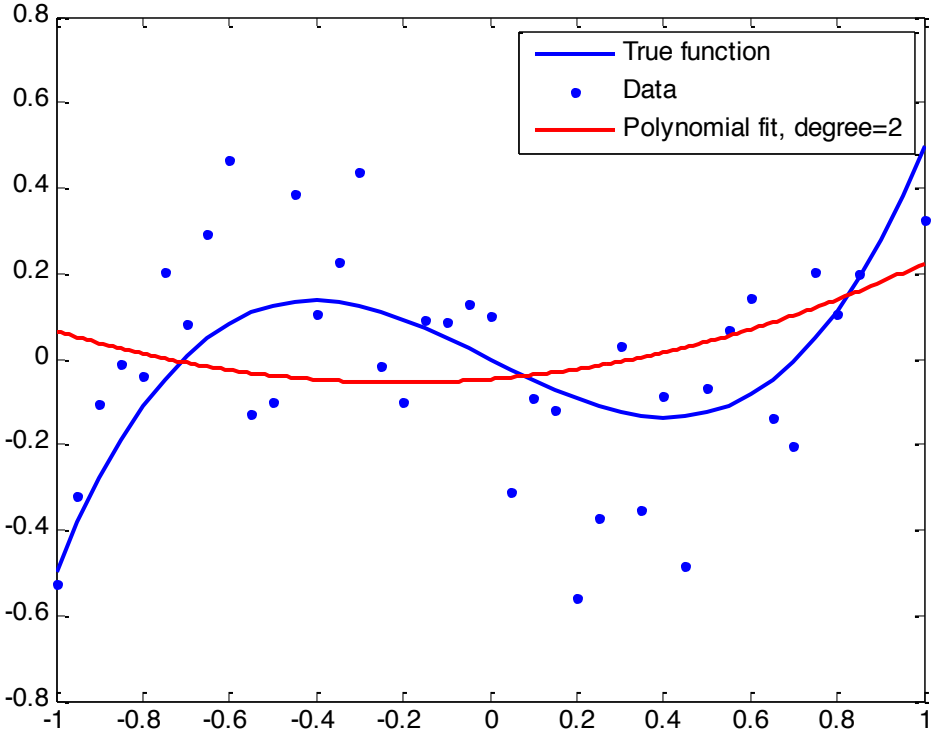
Zadanie aproksymacji funkcji

Znalezienie funkcji z zadanej klasy funkcji najlepiej dopasowanej (w sensie przyjętego kryterium) do posiadanych danych

Przykład aproksymacji

Klasa funkcji: wielomiany n-tego stopnia

Kryterium dopasowania: błąd średniokwadratowy



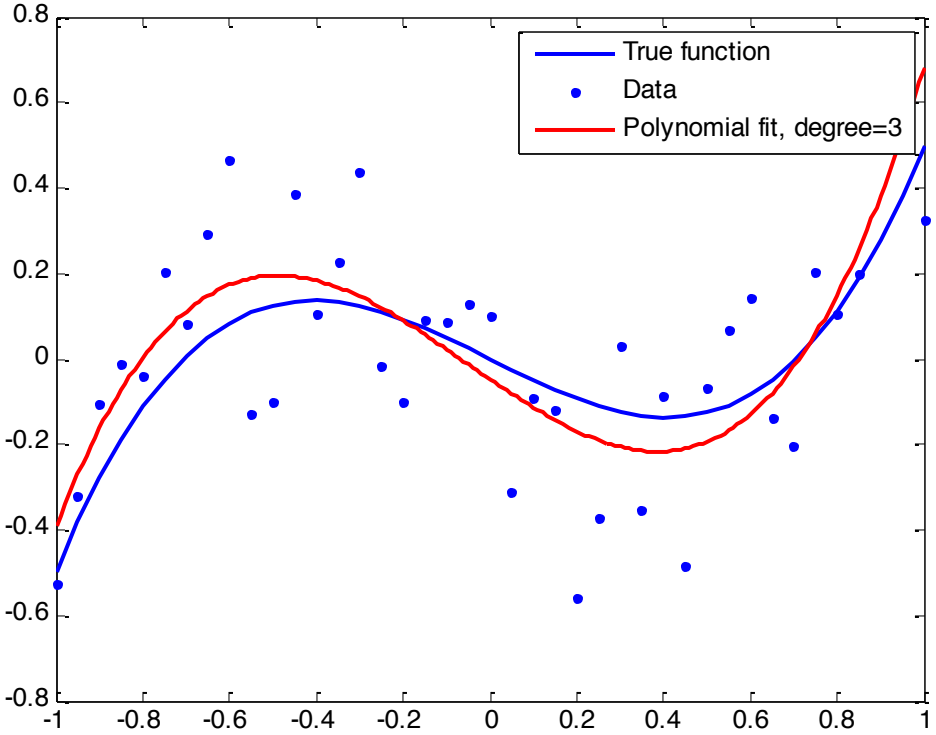
Zadanie aproksymacji funkcji

Znalezienie funkcji z zadanej klasy funkcji najlepiej dopasowanej (w sensie przyjętego kryterium) do posiadanych danych

Przykład aproksymacji

Klasa funkcji: wielomiany n-tego stopnia

Kryterium dopasowania: błąd średniokwadratowy



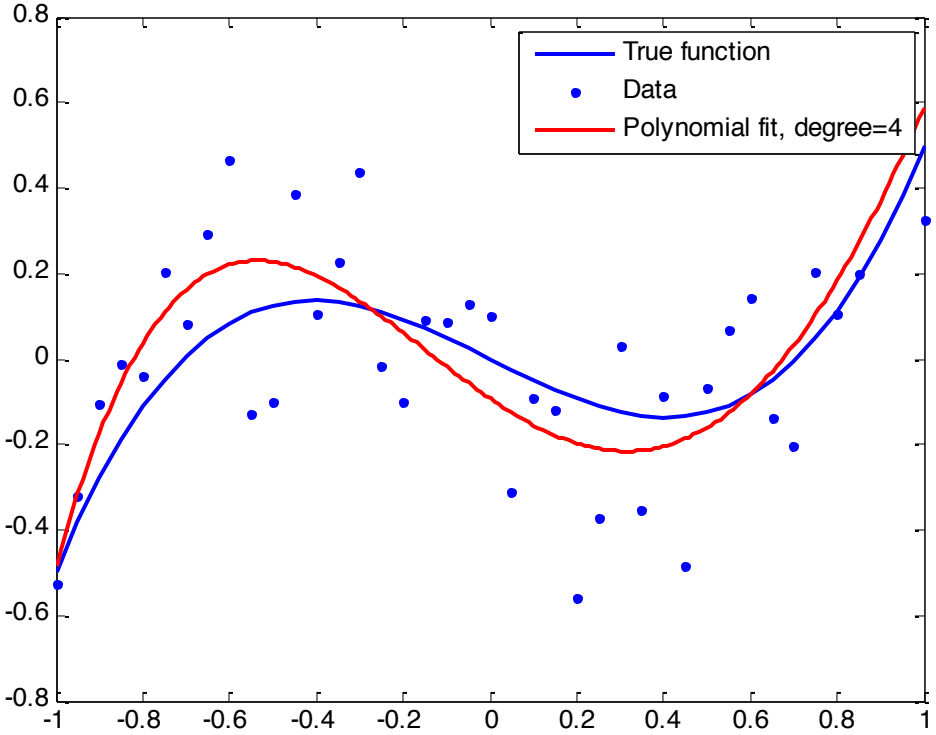
Zadanie aproksymacji funkcji

Znalezienie funkcji z zadanej klasy funkcji najlepiej dopasowanej (w sensie przyjętego kryterium) do posiadanych danych

Przykład aproksymacji

Klasa funkcji: wielomiany n-tego stopnia

Kryterium dopasowania: błąd średniokwadratowy



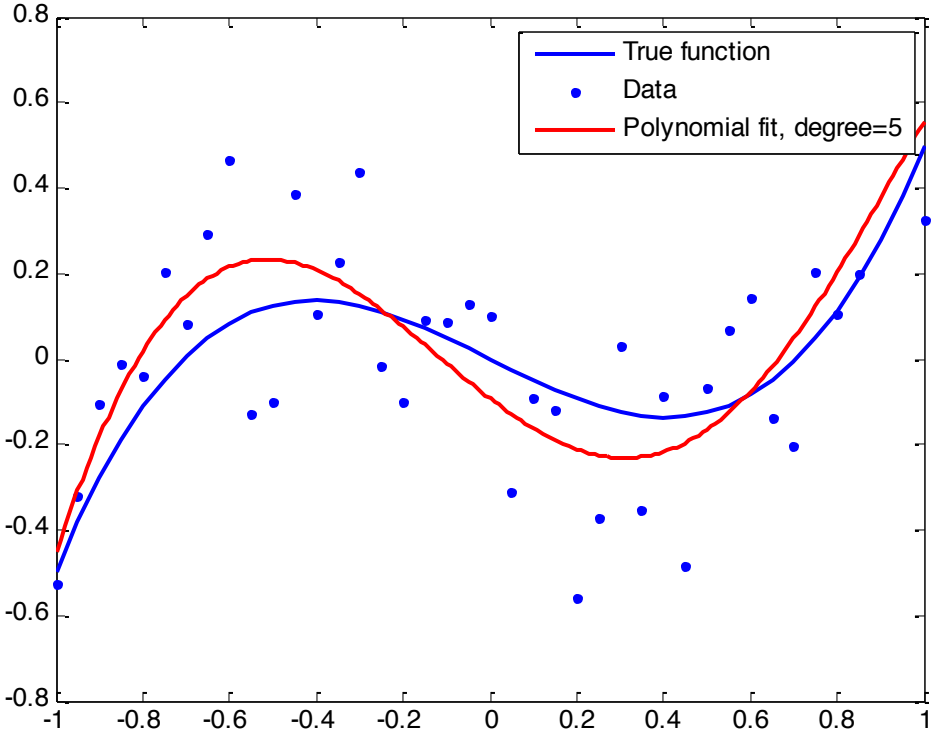
Zadanie aproksymacji funkcji

Znalezienie funkcji z zadanej klasy funkcji najlepiej dopasowanej (w sensie przyjętego kryterium) do posiadanych danych

Przykład aproksymacji

Klasa funkcji: wielomiany n-tego stopnia

Kryterium dopasowania: błąd średniokwadratowy



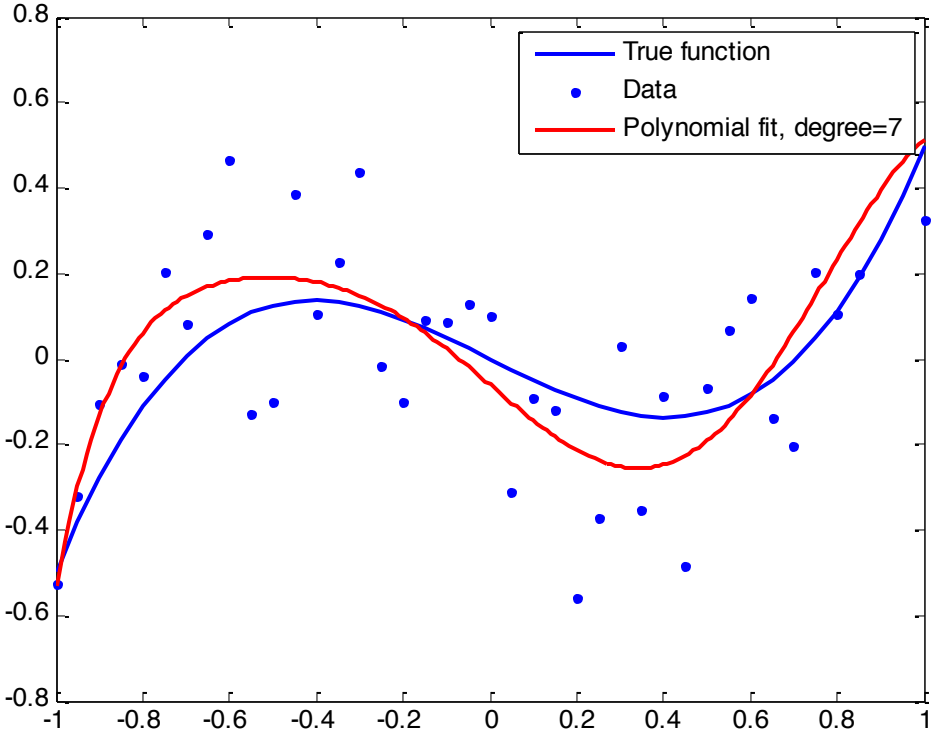
Zadanie aproksymacji funkcji

Znalezienie funkcji z zadanej klasy funkcji najlepiej dopasowanej (w sensie przyjętego kryterium) do posiadanych danych

Przykład aproksymacji

Klasa funkcji: wielomiany n-tego stopnia

Kryterium dopasowania: błąd średniokwadratowy



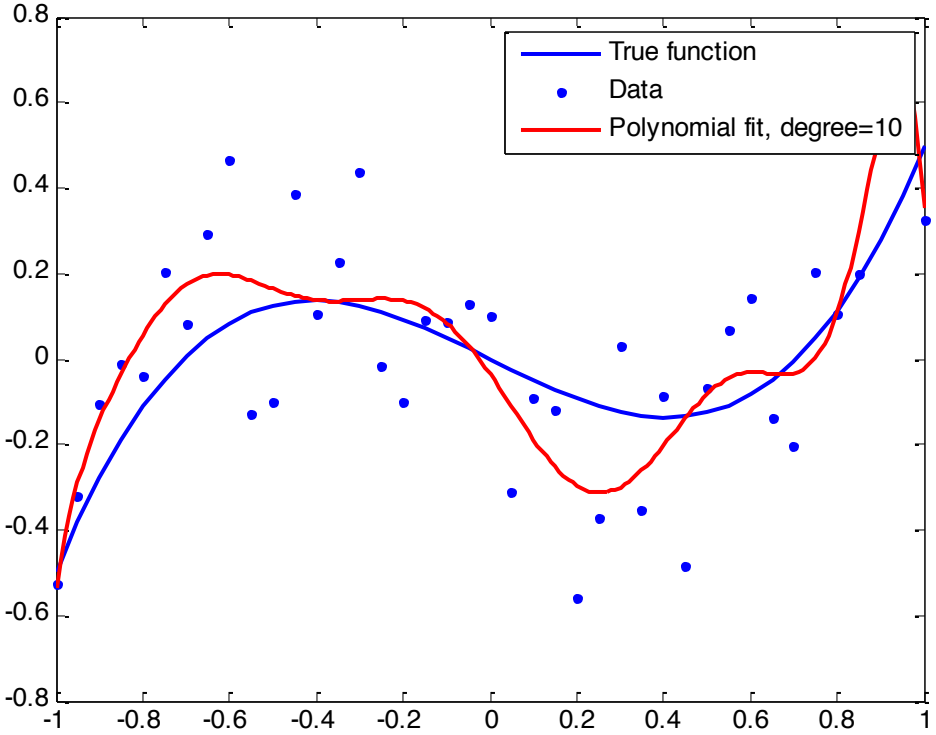
Zadanie aproksymacji funkcji

Znalezienie funkcji z zadanej klasy funkcji najlepiej dopasowanej (w sensie przyjętego kryterium) do posiadanych danych

Przykład aproksymacji

Klasa funkcji: wielomiany n-tego stopnia

Kryterium dopasowania: błąd średniokwadratowy



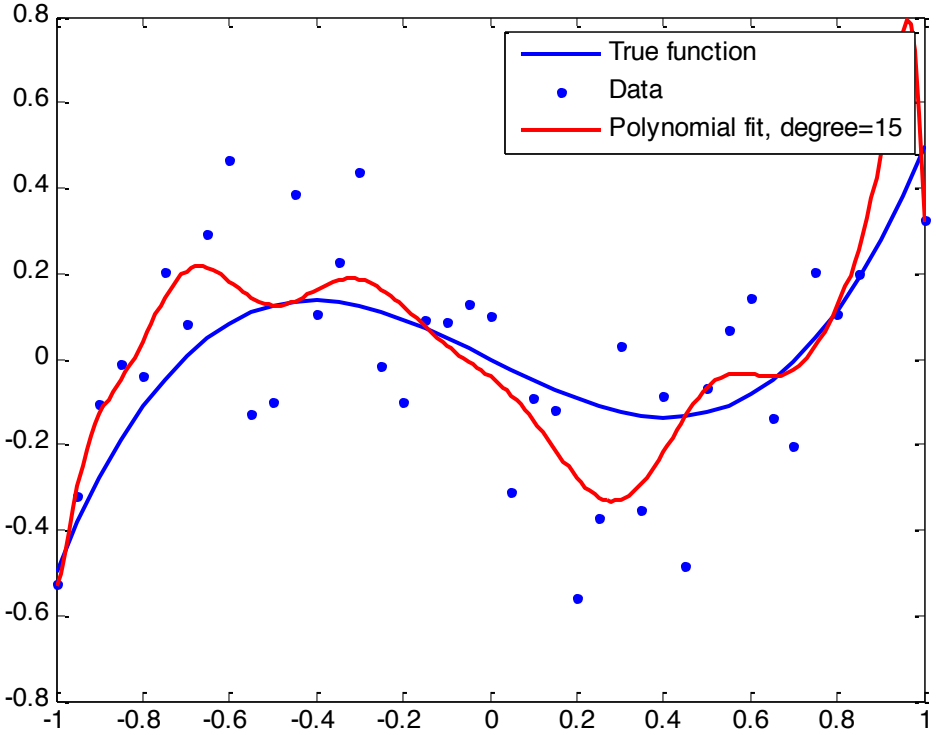
Zadanie aproksymacji funkcji

Znalezienie funkcji z zadanej klasy funkcji najlepiej dopasowanej (w sensie przyjętego kryterium) do posiadanych danych

Przykład aproksymacji

Klasa funkcji: wielomiany n-tego stopnia

Kryterium dopasowania: błąd średniokwadratowy



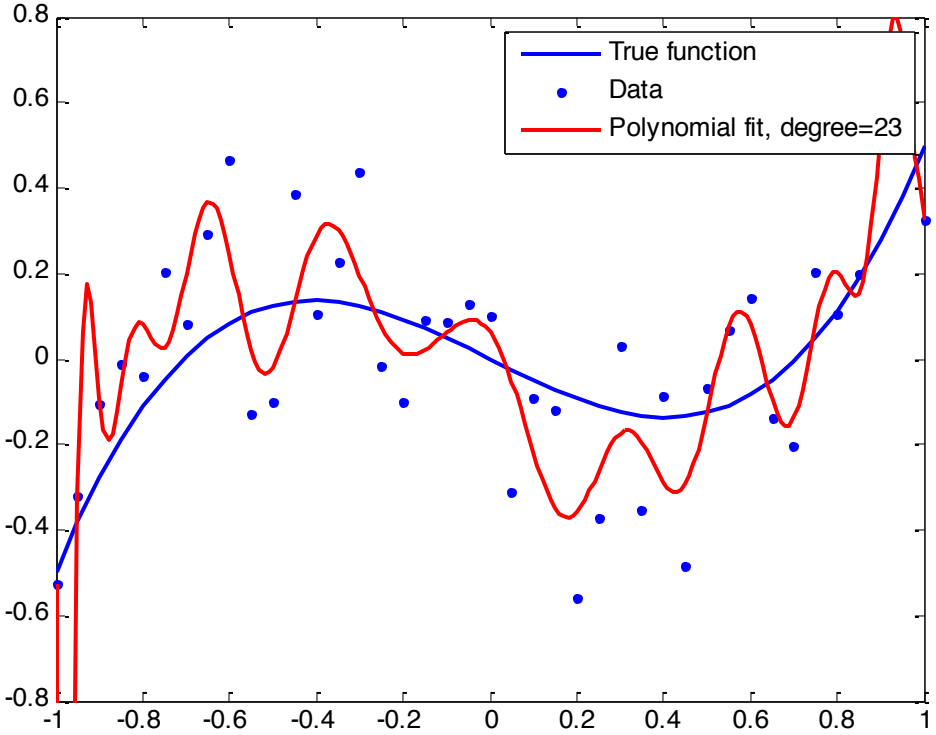
Zadanie aproksymacji funkcji

Znalezienie funkcji z zadanej klasy funkcji najlepiej dopasowanej (w sensie przyjętego kryterium) do posiadanych danych

Przykład aproksymacji

Klasa funkcji: wielomiany n-tego stopnia

Kryterium dopasowania: błąd średniokwadratowy



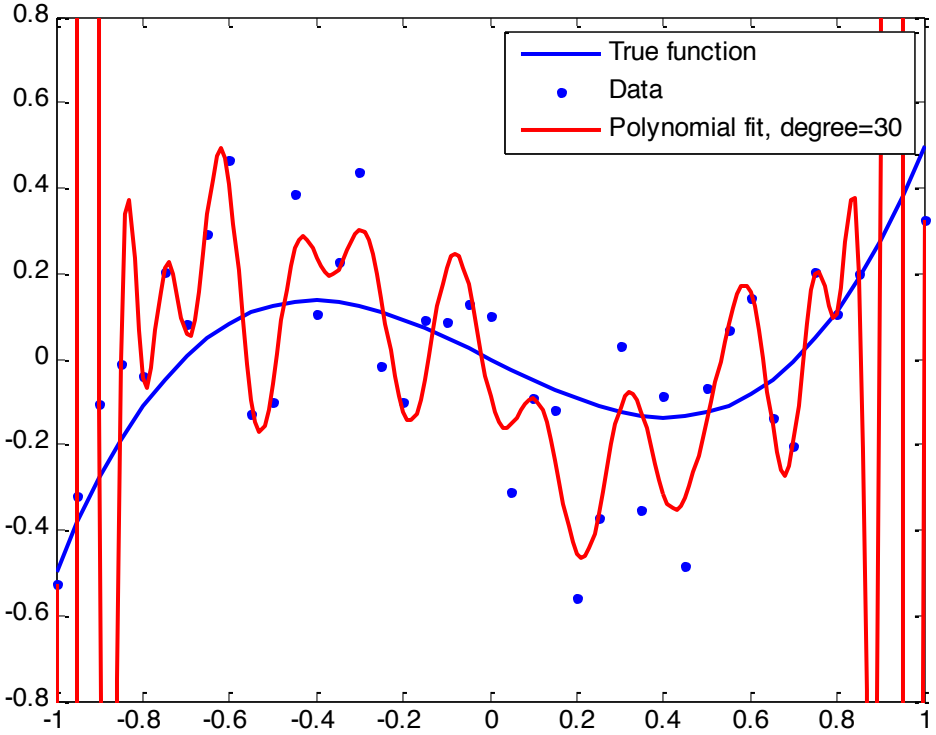
Zadanie aproksymacji funkcji

Znalezienie funkcji z zadanej klasy funkcji najlepiej dopasowanej (w sensie przyjętego kryterium) do posiadanych danych

Przykład aproksymacji

Klasa funkcji: wielomiany n-tego stopnia

Kryterium dopasowania: błąd średniokwadratowy



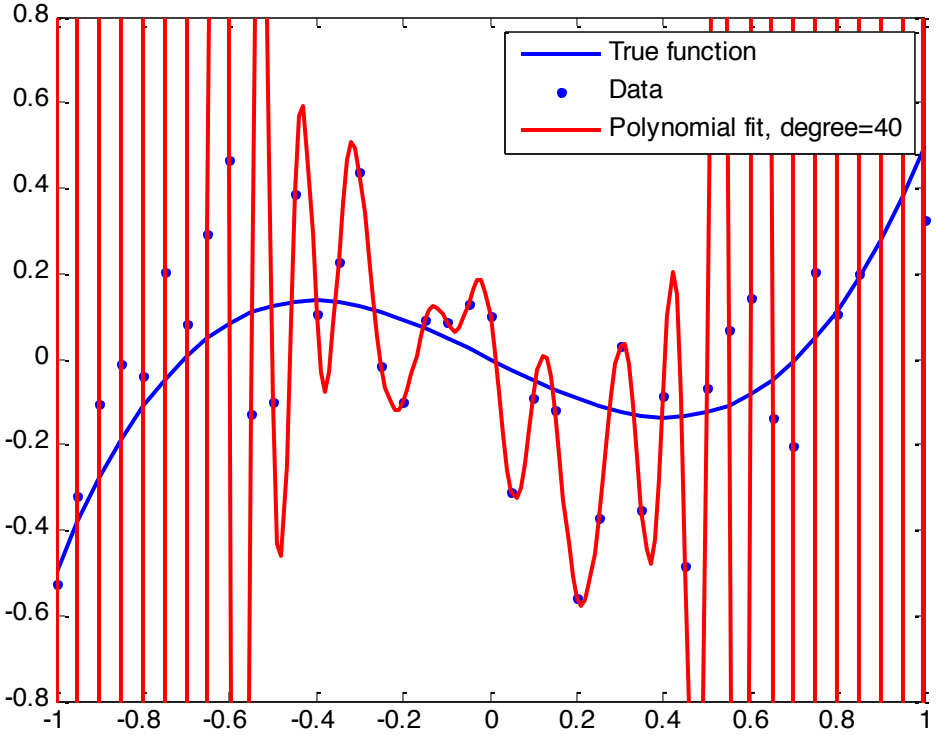
Zadanie aproksymacji funkcji

Znalezienie funkcji z zadanej klasy funkcji najlepiej dopasowanej (w sensie przyjętego kryterium) do posiadanych danych

Przykład aproksymacji

Klasa funkcji: wielomiany n-tego stopnia

Kryterium dopasowania: błąd średniokwadratowy

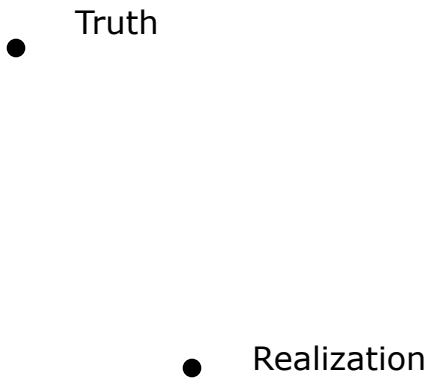


Bias-Variance tradeoff

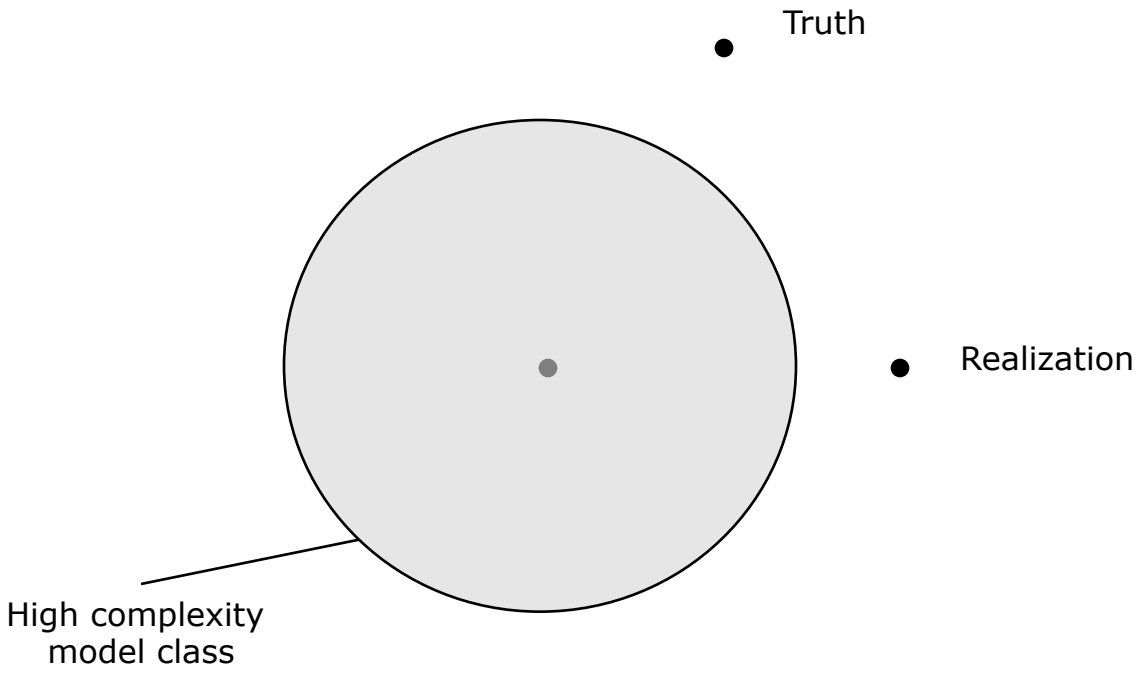
Bias-Variance tradeoff



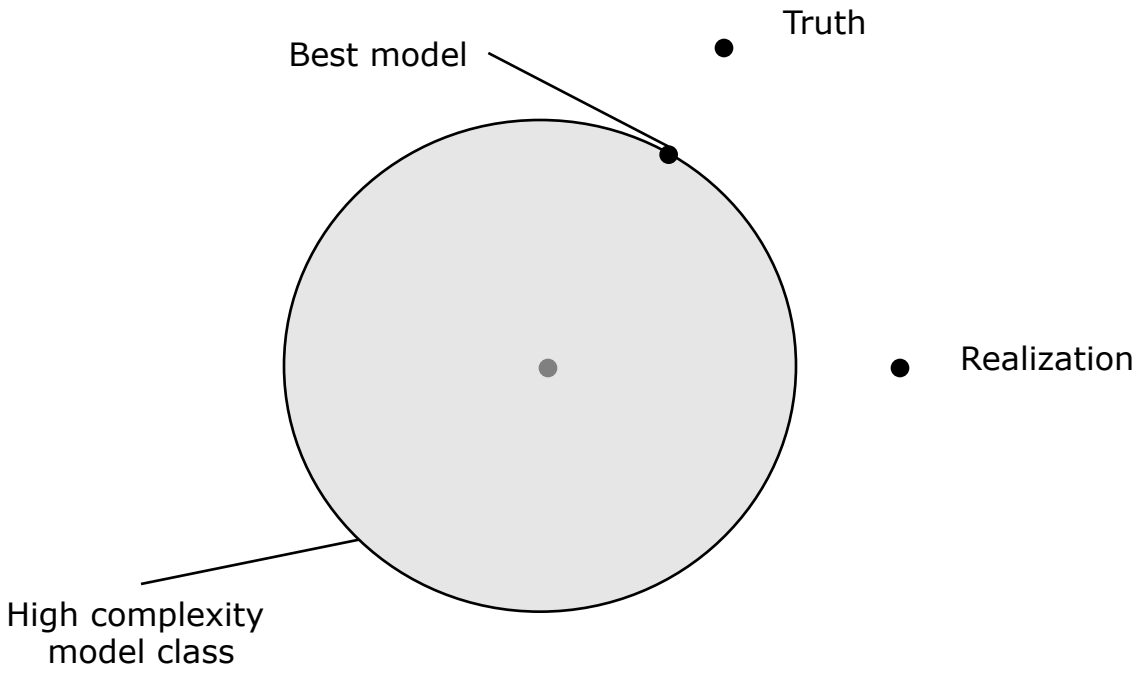
Bias-Variance tradeoff



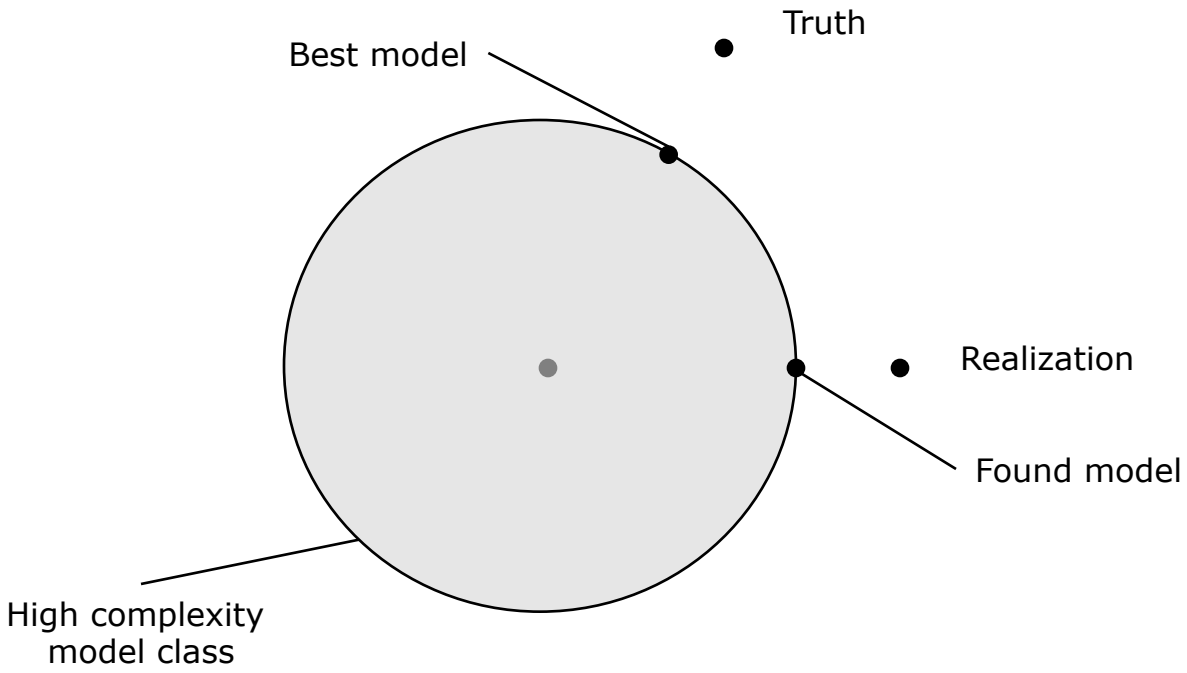
Bias-Variance tradeoff



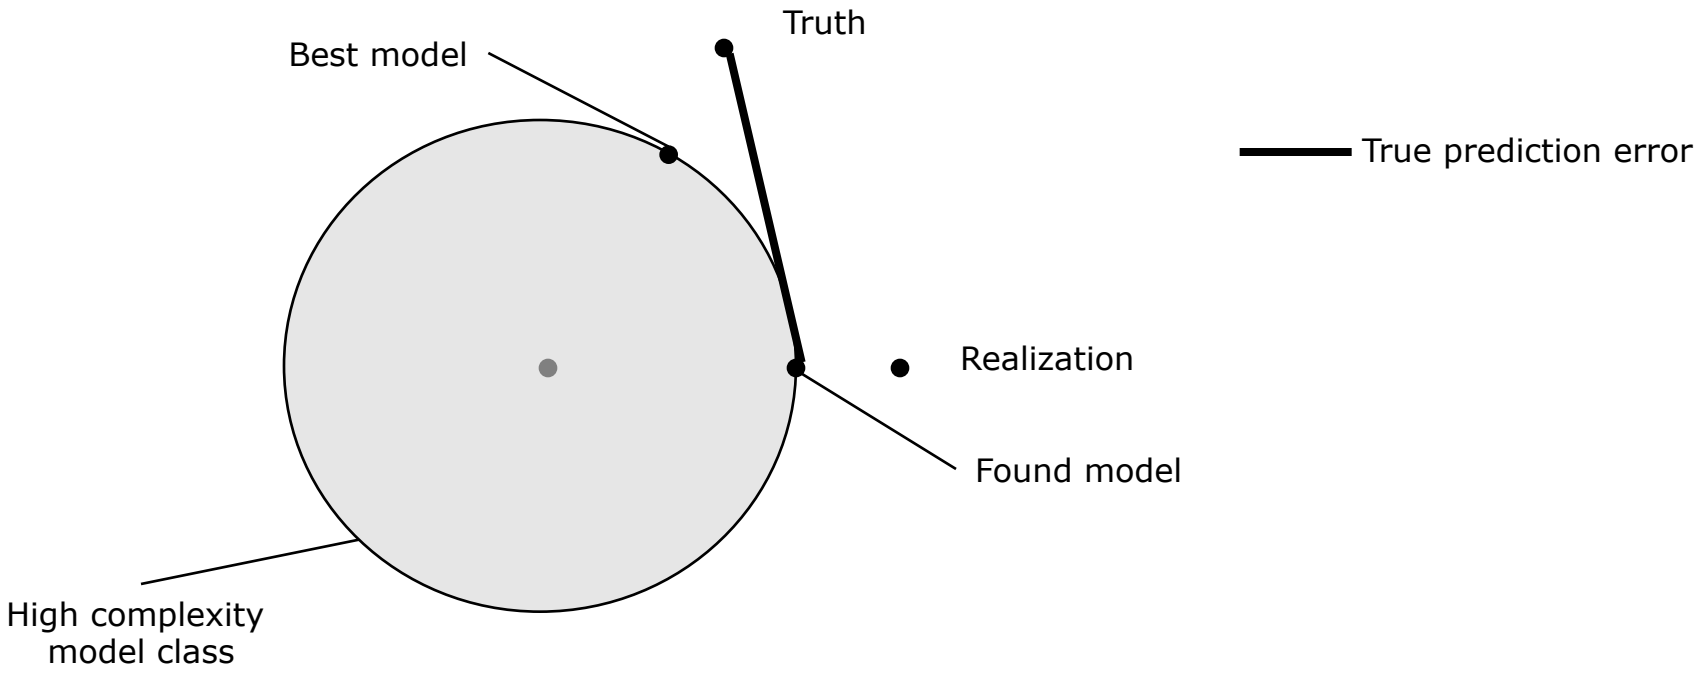
Bias-Variance tradeoff



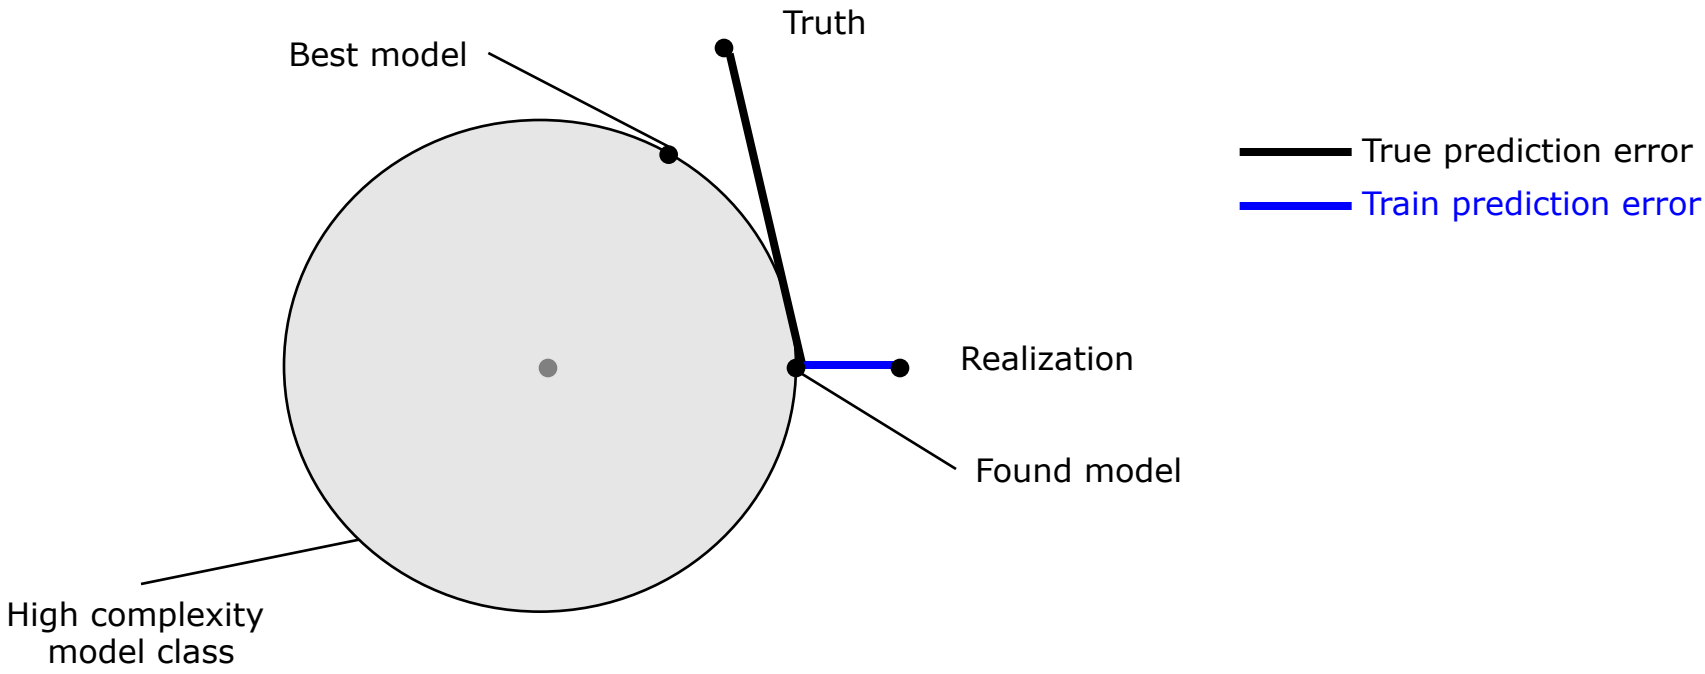
Bias-Variance tradeoff



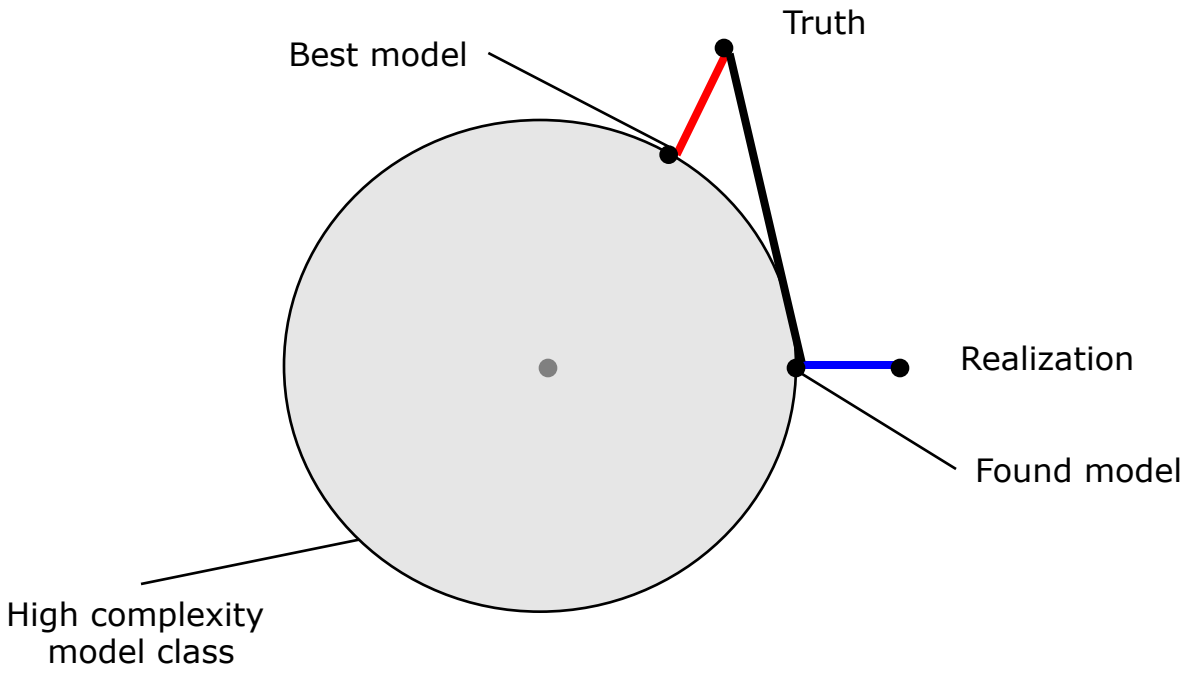
Bias-Variance tradeoff



Bias-Variance tradeoff



Bias-Variance tradeoff

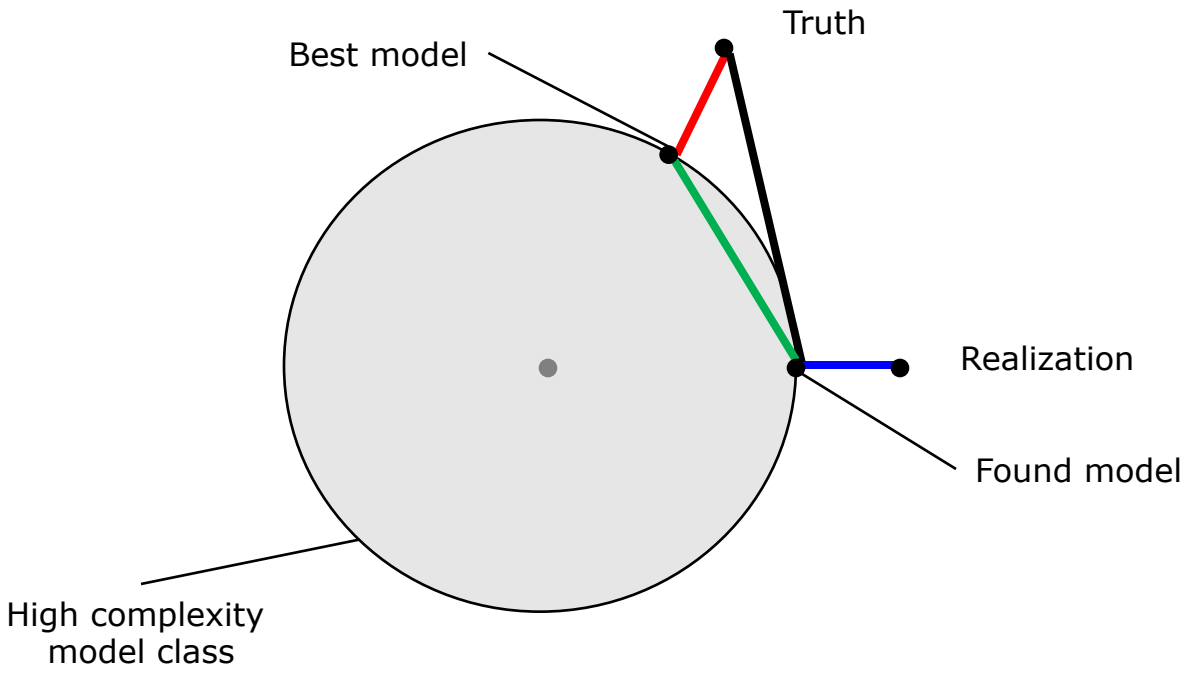


True prediction error

Train prediction error

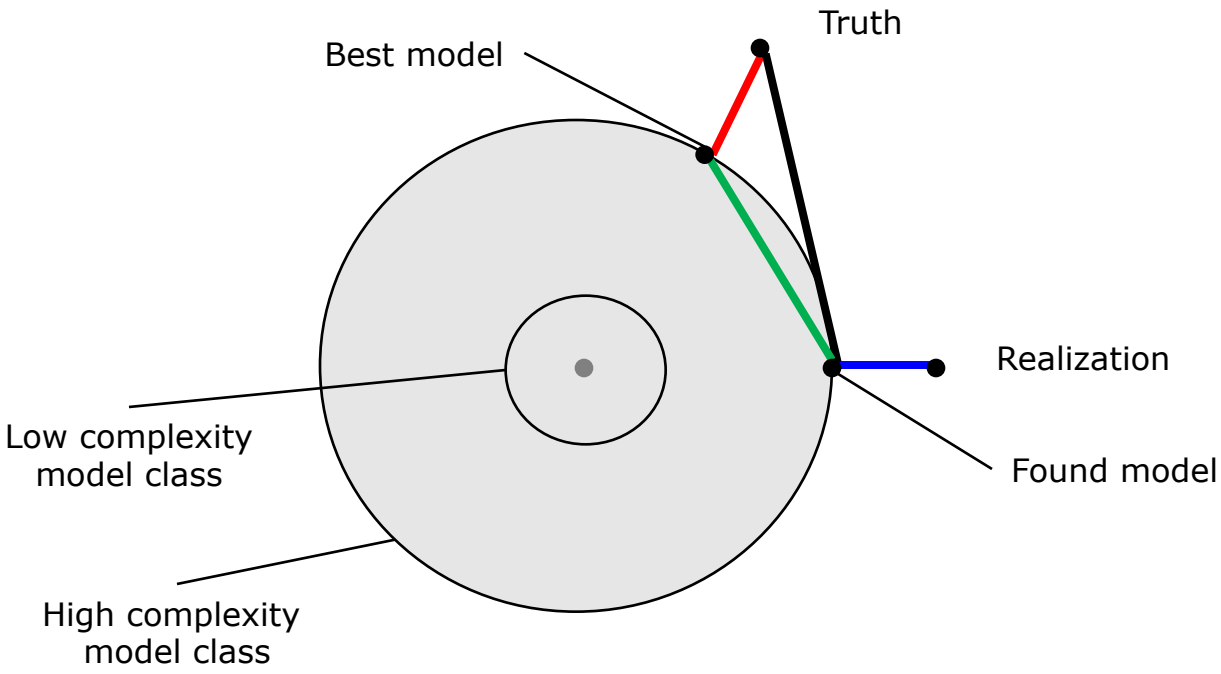
Bias

Bias-Variance tradeoff



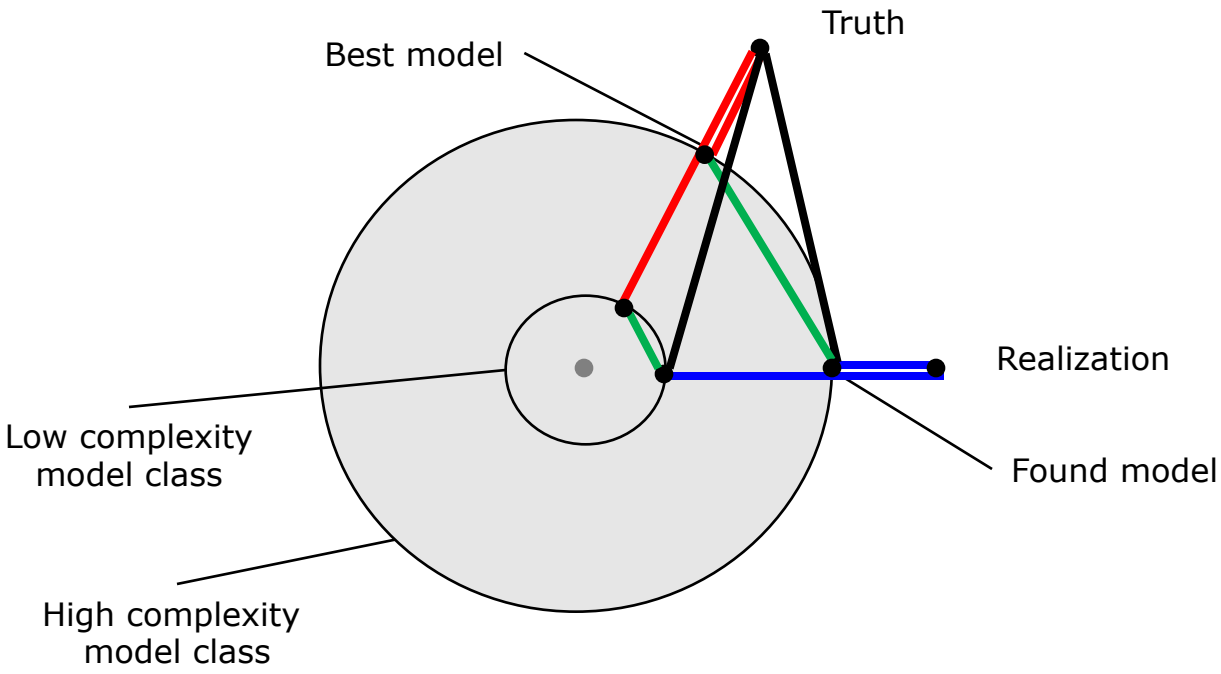
True prediction error
Train prediction error
Bias
Variance

Bias-Variance tradeoff



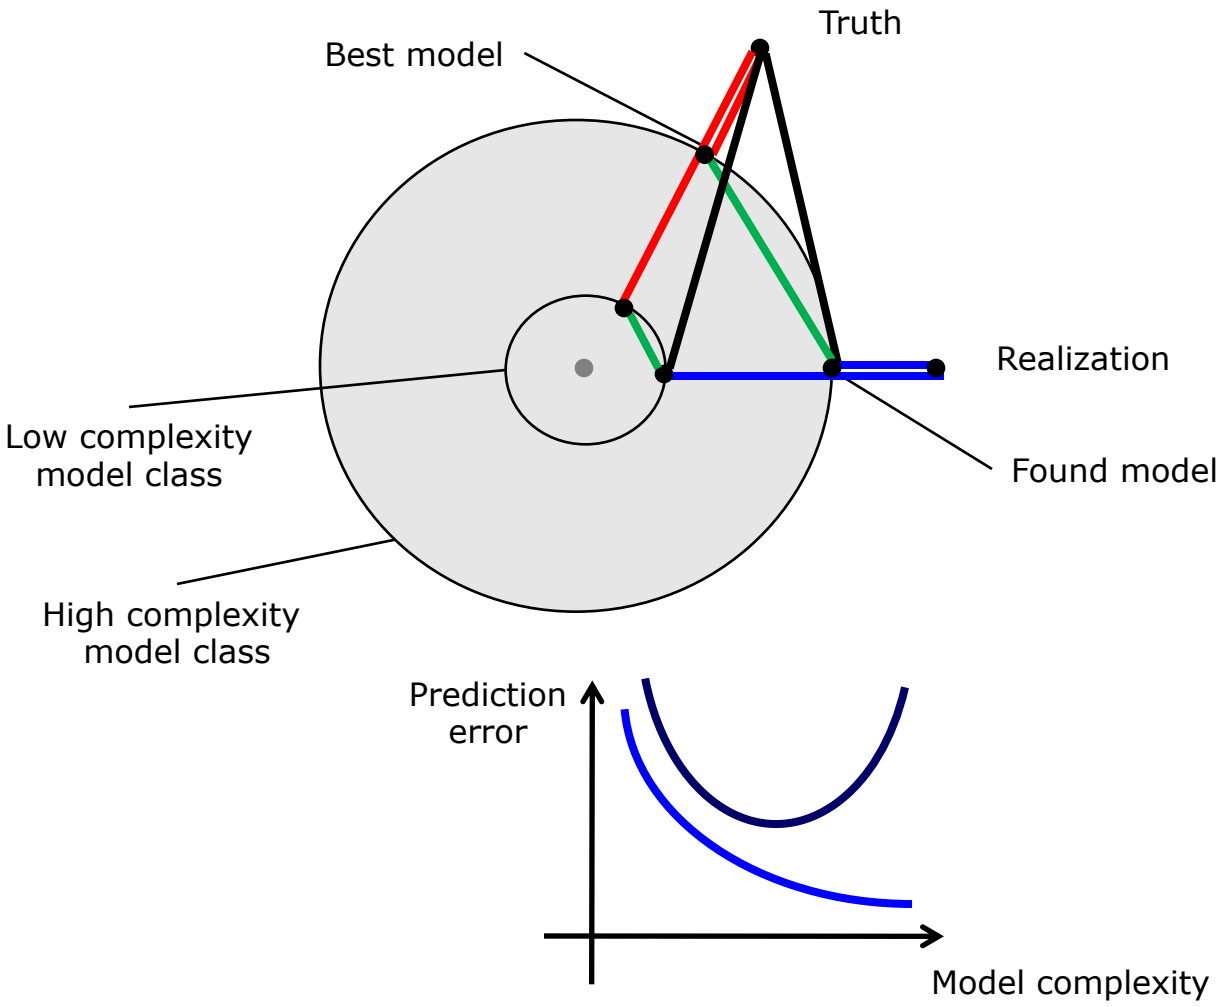
True prediction error
Train prediction error
Bias
Variance

Bias-Variance tradeoff

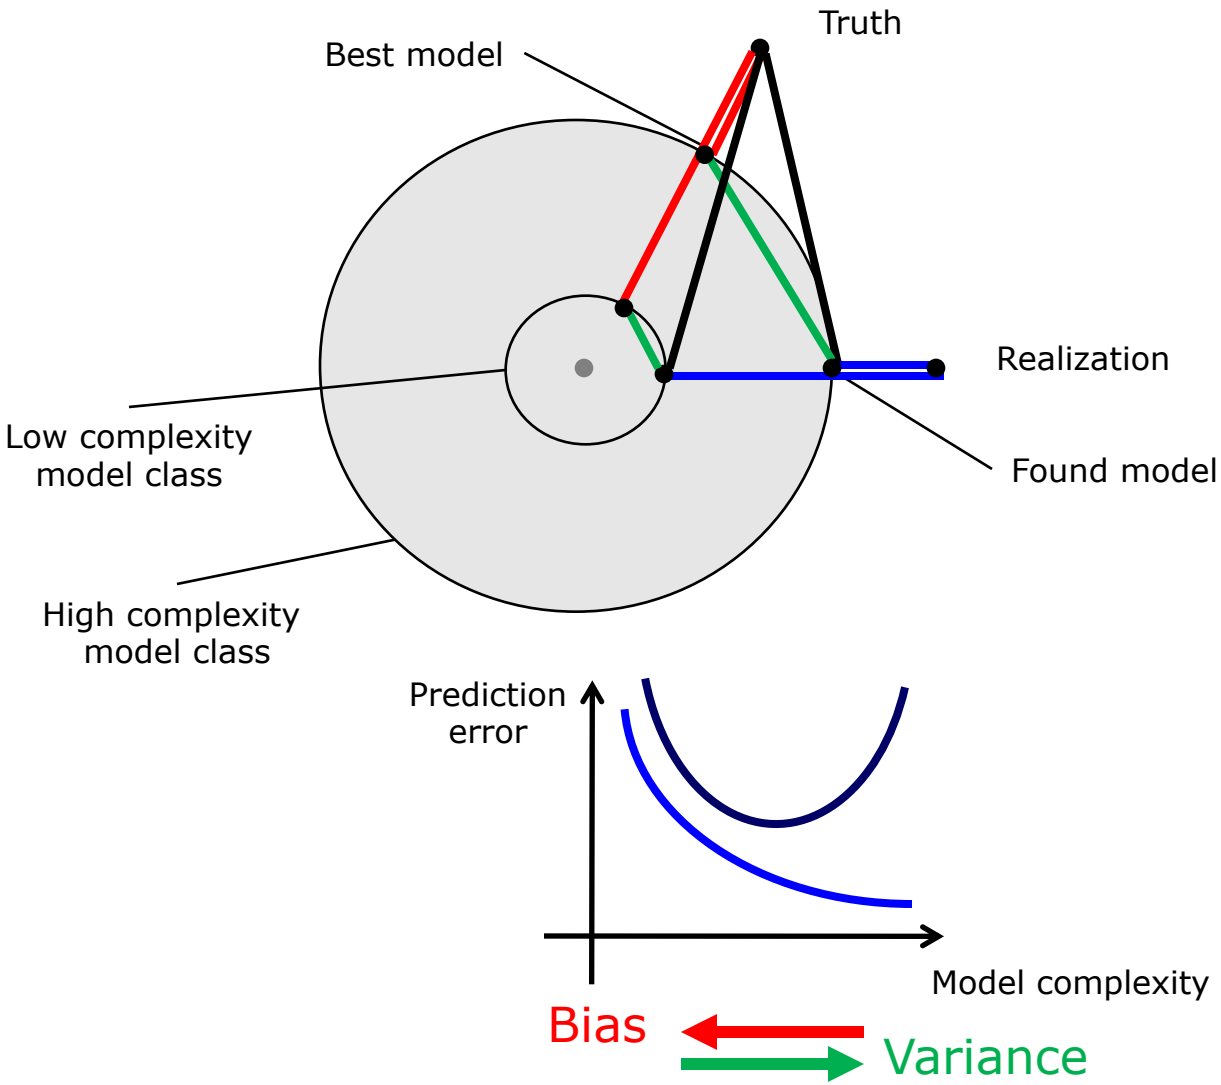


True prediction error
Train prediction error
Bias
Variance

Bias-Variance tradeoff

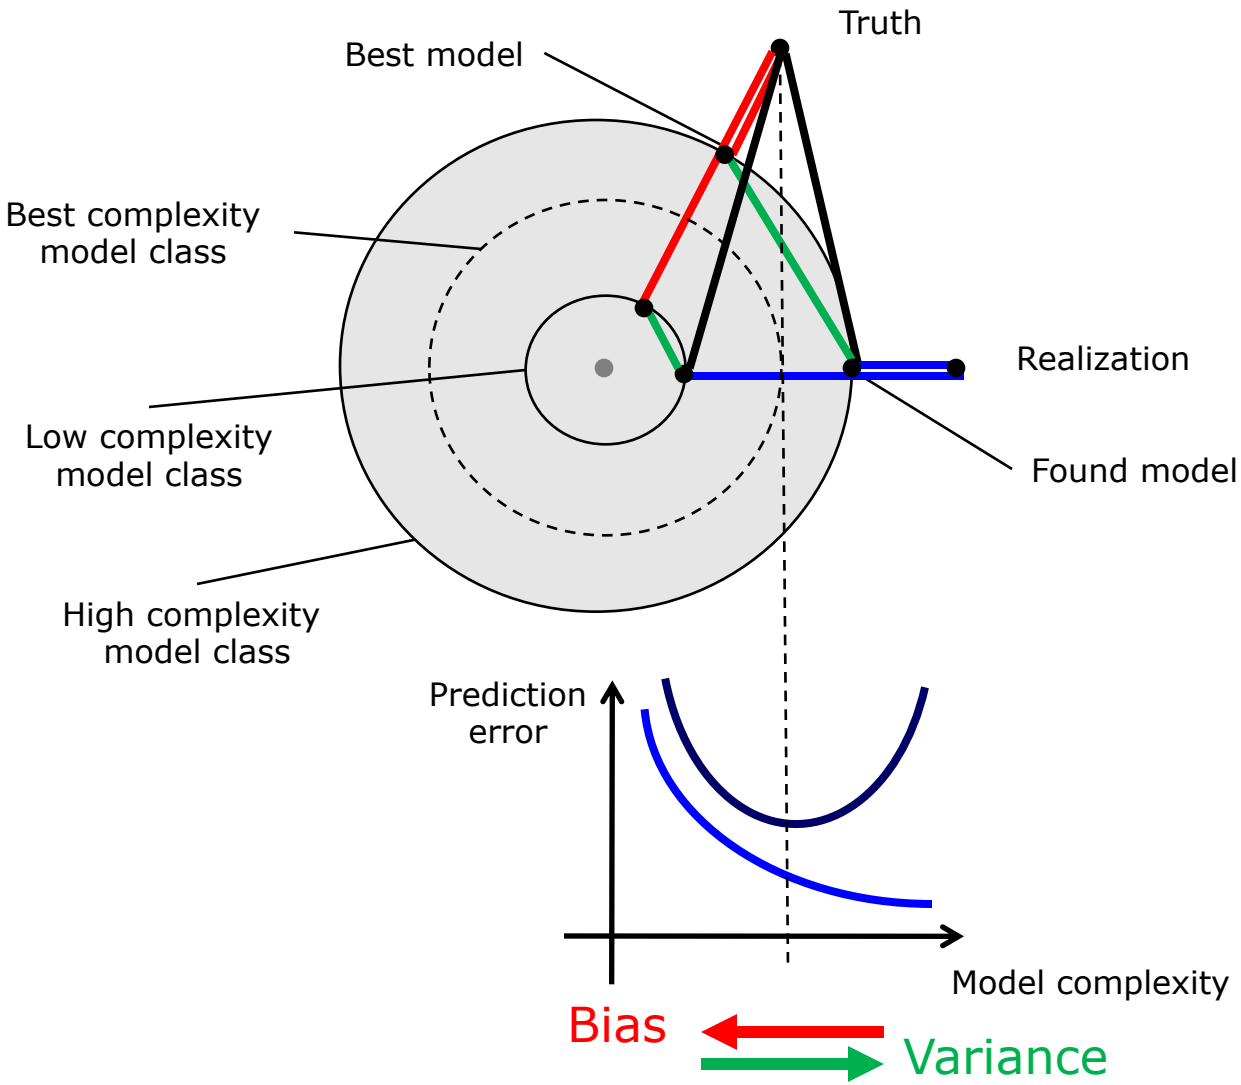


Bias-Variance tradeoff



True prediction error
Train prediction error
Bias
Variance

Bias-Variance tradeoff



Generalizacja

Zdolność modelu do właściwej predykcji wartości funkcji dla nowych (niezależnych) danych

Generalization error = True prediction error

Generalizacja

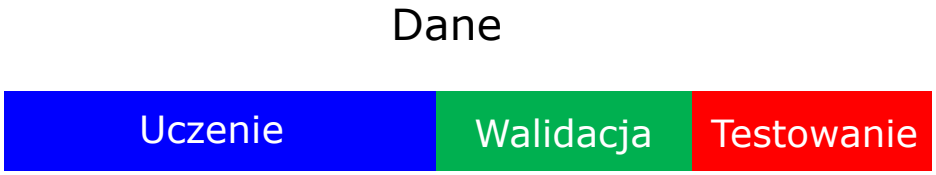
Poprawę generalizacji można osiągnąć poprzez wybór właściwej struktury modelu (o odpowiedniej złożoności)

- Odpowiedni stopień wielomianu
- Odpowiednia liczba warstw i neuronów w sieci neuronowej
- …

Generalizacja

Poprawę generalizacji można osiągnąć poprzez wybór właściwej struktury modelu (o odpowiedniej złożoności)

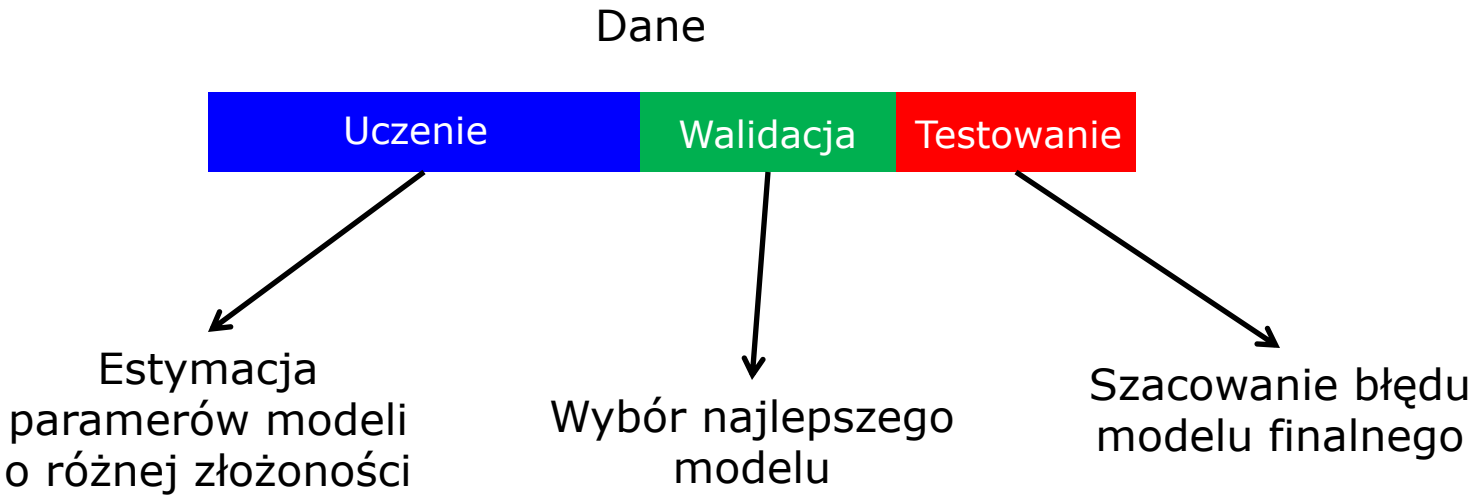
- Odpowiedni stopień wielomianu
- Odpowiednia liczba warstw i neuronów w sieci neuronowej
- …



Generalizacja

Poprawę generalizacji można osiągnąć poprzez wybór właściwej struktury modelu (o odpowiedniej złożoności)

- Odpowiedni stopień wielomianu
- Odpowiednia liczba warstw i neuronów w sieci neuronowej
- …



Regularyzacja

Poprawę generalizacji można osiągnąć również poprzez tzw. regularyzację

Regularyzacja

Poprawę generalizacji można osiągnąć również poprzez tzw. regularyzację

Polega ona na:
•Wyborze nadmiarowej struktury modelu (wysoki stopień wielomianu, dużo neuronów sieci, etc.)
•Dodanie do pierwotnej funkcji celu (błędu predykcji dla zbioru testowego) tzw. składnika regularyzacyjnego karzącego za zbyt duże wartości parametrów

Regularyzacja

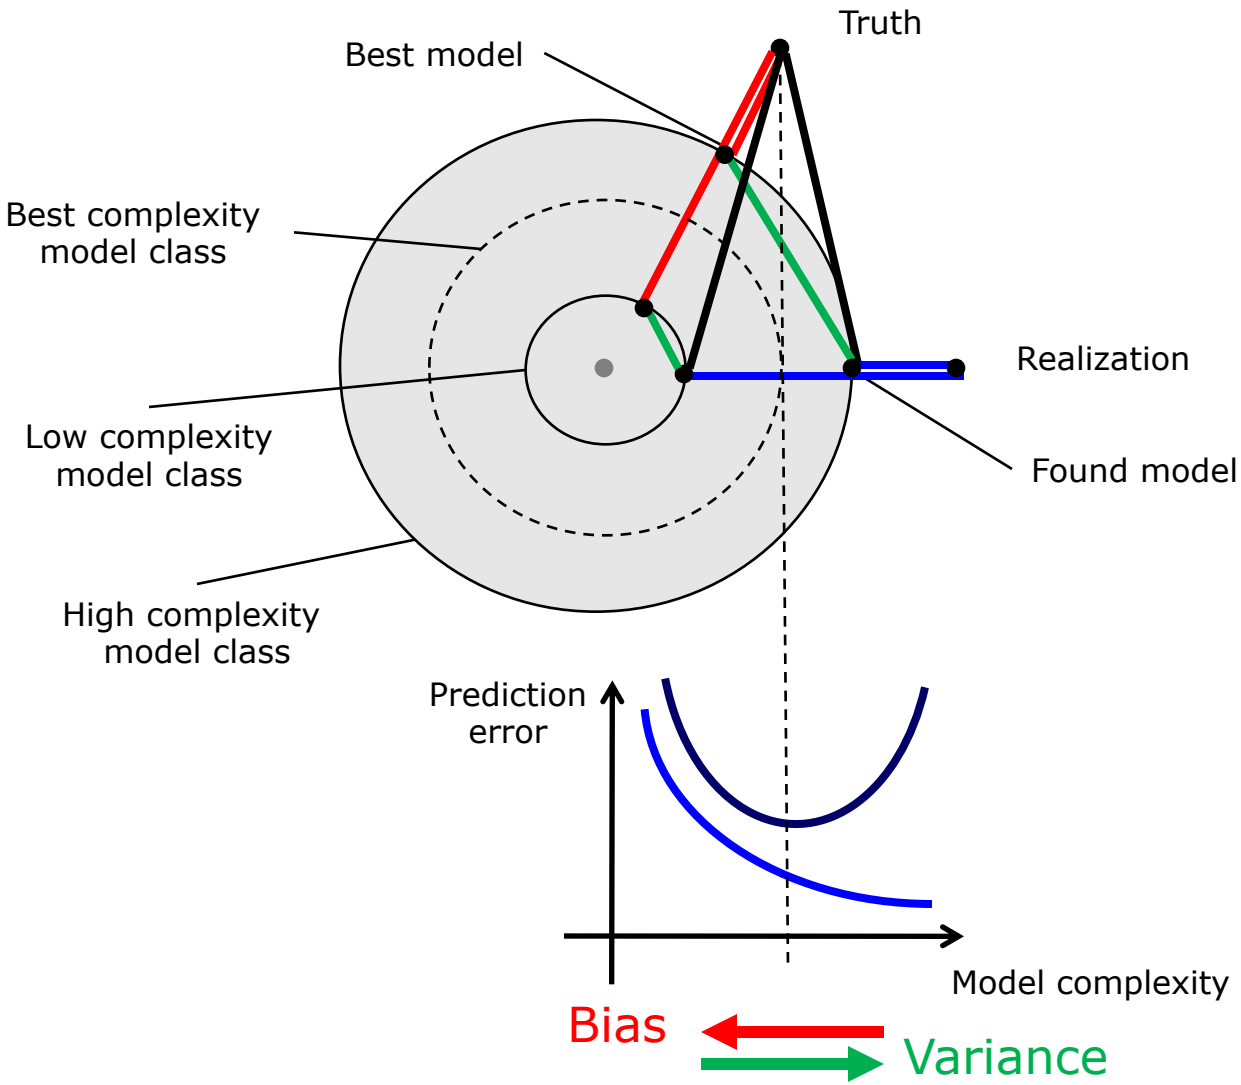
Poprawę generalizacji można osiągnąć również poprzez tzw. regularyzację

Polega ona na:
•Wyborze nadmiarowej struktury modelu (wysoki stopień wielomianu, dużo neuronów sieci, etc.)
•Dodanie do pierwotnej funkcji celu (błędu predykcji dla zbioru testowego) tzw. składnika regularyzacyjnego karzącego za zbyt duże wartości parametrów

Na przykład: $$MSE_{reg} = MSE + \lambda \sum_i p_i^2$$

p_i - parametry modelu

Regularyzacja



Regularyzacja

