Sztuczna Inteligencja

K. Fujarewicz

- Liniowa analiza dyskryminacyjna Fishera

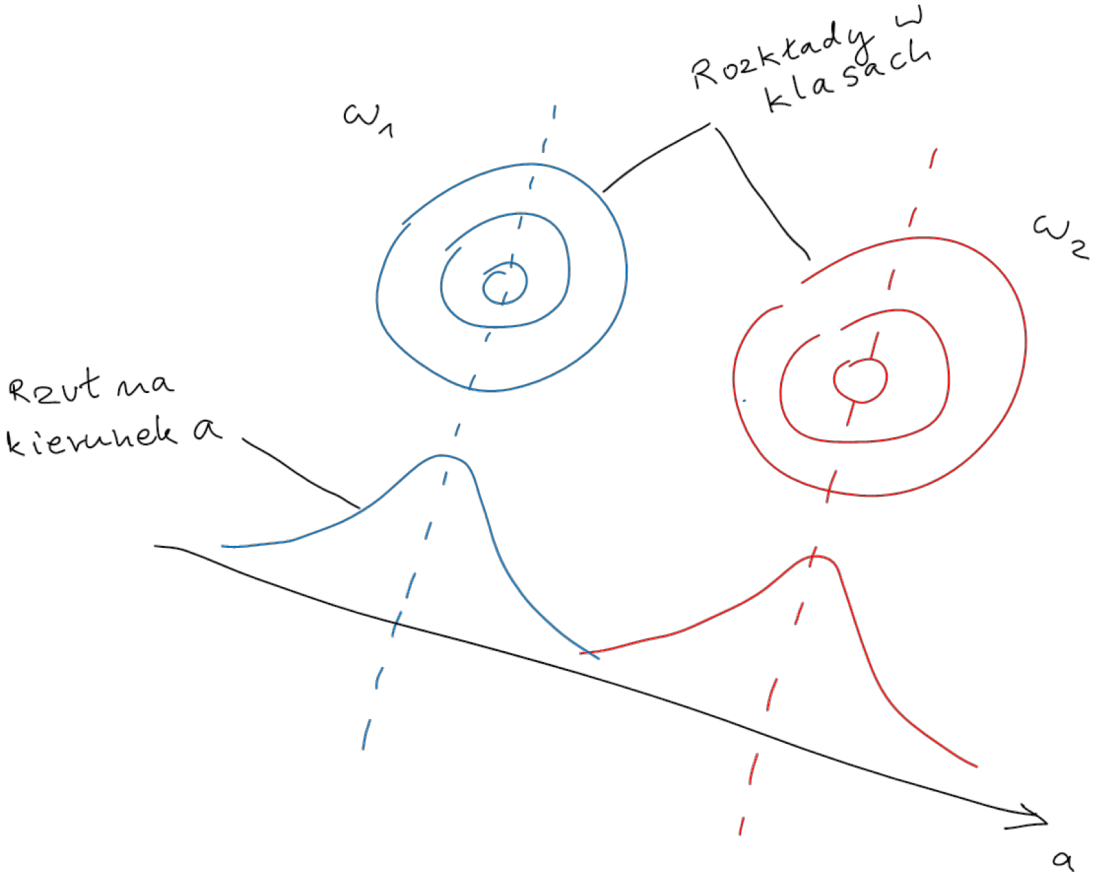
Liniowa analiza dyskryminacyjna

Zaproponowana przez Fishera w 1936 roku.
ang. Linear discriminant analysis (LDA)
Oryginalnie wyprowadzona dla dwóch klas, istnieje rozszerzenie na przypadek wielu klas.

Przestrzeń cech $X \in R^p$

Zadanie:
Znajdź kierunek *a* w *X*, który najlepiej rozdziela obie klasy (reprezentowane przez próby); przy tym konstruując miarę odległości między klasami uwzględnij zmienność wewnątrzgrupową (wewnątrz klas)

Liniowa analiza dyskryminacyjna



Liniowa analiza dyskryminacyjna

Dla rozkładów wielowymiarowych odpowiednikiem wartości oczekiwanej jest wektor wartości oczekiwanych współrzędnych (składowych) wektora losowego

$$E(x) \equiv Ex = [E(x^{(1)}), E(x^{(2)}), \ldots, E(x^{(p)})]^T$$

A odpowiednikiem wariancji jest macierz kowariancji

$$\Sigma \equiv \mathrm{Cov}(x) = E[(x - Ex)(x - Ex)^T] = (\sigma_{ij})_{i,j=1}^{p}$$

$$\sigma_{ij} = E[(x^{(i)} - Ex^{(i)})(x^{(j)} - Ex^{(j)})]$$

Macierz kowariancji jest symetryczna i nieujemnie określona

Liniowa analiza dyskryminacyjna

Próbkowym odpowiednikiem wartości oczekiwanej Ex jest wektorowa średnia próbkowa otrzymana na podstawie próby $x_1, x_2, \ldots, x_n$:

$$\bar{x} = \frac{1}{n}\sum_{l=1}^{n} x_l$$

gdzie

$$x_l = [x_l^{(1)}, x_l^{(2)}, \ldots, x_l^{(p)}]^T, \quad l = 1, 2, \ldots, n$$

Próbkowym odpowiednikiem populacyjnej macierzy kowariancji Σ jest próbkowa macierz kowariancji:

$$S = \frac{1}{n-1}\sum_{l=1}^{n}(x_l - \bar{x})(x_l - \bar{x})^T = (s_{ij})_{i,j=1}^{p}$$

$$s_{ij} = \frac{1}{n-1}\sum_{l=1}^{n}(x_l^{(i)} - \bar{x}^{(i)})(x_l^{(j)} - \bar{x}^{(j)})^T$$

Liniowa analiza dyskryminacyjna

Rzut wektora *x* na prostą o wektorze kierunkowym *a*:

$$a^T x$$

x jest wektorem losowym, zatem $a^T x$ jest (skalarną) zmienną losową o wariancji:

$$\mathrm{Var}(a^T x) = E(a^T x - E(a^T x))^2 = E[a^T (x - Ex)(x - Ex)^T a] =$$
$$= a^T \mathrm{Cov}(x) a = a^T \Sigma a$$

Liniowa analiza dyskryminacyjna

Dysponujemy n-elementową próbą uczącą

$$\{(x_1, d_1), (x_2, d_2), \ldots, (x_n, d_n)\}$$

gdzie można wyróżnić reprezentantów obu klas:

$$x_{11}, x_{12}, \ldots, x_{1n_1} \in \omega_1$$

$$x_{21}, x_{22}, \ldots, x_{2n_2} \in \omega_2$$

$$n = n_1 + n_2$$

Średnie w klasach:

$$\bar{x}_k = \frac{1}{n_k} \sum_{i=1}^{n_k} x_{ki}, \quad k = 1, 2$$

Liniowa analiza dyskryminacyjna

Zakładamy (za Fisherem), że obie klasy charakteryzują się takimi samymi macierzami kowariancji.

Macierz (próbkowa) kowariancji wewnątrzgrupowej, wspólnej dla obu klas:

$$W = \frac{1}{n-2}\sum_{k=1}^{2}(n_k - 1)S_k =$$

$$= \frac{1}{n-2}\sum_{k=1}^{2}\left[\sum_{i=1}^{n_k}(x_{ki} - \bar{x}_k)(x_{ki} - \bar{x}_k)^T\right]$$

Zatem próbkowa miara zmienności wewnątrzgrupowej wzdłuż kierunku *a* wynosi*:*

$$a^T W a$$

Powinna ona być jak najmniejsza.

Liniowa analiza dyskryminacyjna

Jednocześnie kierunek *a* powinien być tak wybrany aby maksymalnie rozseparować klasy wzdłuż niego. Jako miarę separacji przyjmiemy

$$(a^T \bar{x}_2 - a^T \bar{x}_1)^2$$

Powinna ona być jak największa.

W efekcie otrzymujemy wspólny wskaźnik, zapewniający dobrą separację przy małej zmienności wewnątrzklasowej:

$$\text{Max} \leftarrow J = \frac{(a^T \bar{x}_2 - a^T \bar{x}_1)^2}{a^T W a}$$

Można wykazać, że optymalny wektor $\hat{a}$

$$\hat{a} \propto W^{-1}(\bar{x}_2 - \bar{x}_1)$$

Liniowa analiza dyskryminacyjna

Mając optymalny kierunek $\hat{a}$ zaklasyfikuj nowy wektor obserwacji *x* do klasy ω_1 jeśli

$$\left|\hat{a}^T x - \hat{a}^T \bar{x}_1\right| < \left|\hat{a}^T x - \hat{a}^T \bar{x}_2\right|$$

a do klasy ω_2 w przeciwnym przypadku.

Reguła ta określa w przestrzeni cech *X* hiperpłaszczyznę separującą (dyskryminującą) *P* , która przechodzi przez środek odcinka łączącego $\bar{x}_1$ z $\bar{x}_2$.

Hiperpłaszczyzna separująca P dana jest równaniem:

$$(\bar{x}_1 - \bar{x}_2)^T W^{-1}[x - \frac{1}{2}(\bar{x}_1 + \bar{x}_2)] = 0$$

Liniowa analiza dyskryminacyjna

Lewa strona w poprzedniej równości może być potraktowana jako funkcja klasyfikująca *f*(*x*):

$$f(x) = (\bar{x}_1 - \bar{x}_2)^T W^{-1}[x - \frac{1}{2}(\bar{x}_1 + \bar{x}_2)]$$

określająca przynależność do klas:

$$x \in \begin{cases} \omega_1 & gdy \quad f(x) > 0 \\ \omega_2 & gdy \quad f(x) < 0 \end{cases}$$

W ogólnym przypadku nie jest prawdą, że optymalną hiperpowierzchnia separująca jest prostopadła do odcinka łączącego środki klas.

Dzieje się tak jedynie w przypadku gdy macierz W jest diagonalna i wszystkie elementy na diagonali są sobie równe.
Poziomice rozkładów są wtedy hipersferami.

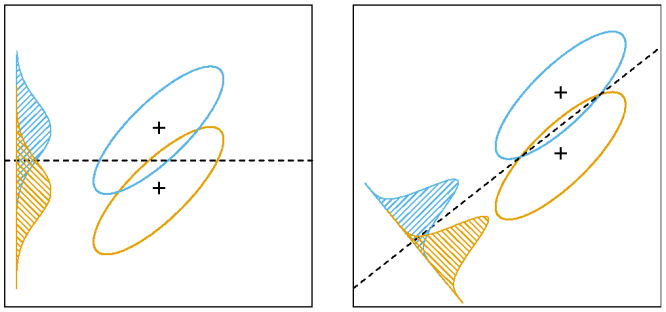


FIGURE 4.9. *Although the line joining the centroids defines the direction of greatest centroid spread, the projected data overlap because of the covariance (left panel). The discriminant direction minimizes this overlap for Gaussian data (right panel).*

Przykład 1. w Matlabie (Classification Learner) dla „Iris data”

- 3 klasy
- 4 cechy



https://www.mathworks.com/help/stats/train-discriminant-analysis-classifiers-in-classification-learner-app.html

Przykład 2. w Matlabie (Classification Learner) dla „pustych danych”

```
clear all
close all

M = 200; %liczba wzorc?w
M1 = 100; %liczba wzorc?w z 1 klasy
M2 = 100; %liczba wzorc?w z 2 klasy

%liczba cech = 3

%warto?ci cech
Feature1 = randn(M,1);
Feature2 = randn(M,1);
Feature3 = randn(M,1);

%etykiet klas
ClassLabels = cell(M,1);
for i=1:M1
    ClassLabels{i}='Positive';
end
for i=M1+1:M
    ClassLabels{i}='Negative';
end

NullTable = table(Feature1, Feature2, Feature3,
ClassLabels)
```

Kwadratowa analiza dyskryminacyjna ang. Quadratic discriminant analysis (QDA)

Założenie: Rozkłady w klasach są normalne (jak dla LDA)

Brak założenia o równości macierzy kowariancji ->

-> macierze kowariancji estymowane są osobno

Kwadratowa analiza dyskryminacyjna ang. Quadratic discriminant analysis (QDA)

Kwadratowa analiza dyskryminacyjna ang. Quadratic discriminant analysis (QDA)

Założenie: Rozkłady w klasach są normalne (jak dla LDA)

Kwadratowa analiza dyskryminacyjna ang. Quadratic discriminant analysis (QDA)

Założenie: Rozkłady w klasach są normalne (jak dla LDA)

Brak założenia o równości macierzy kowariancji ->

-> macierze kowariancji estymowane są osobno

Kwadratowa analiza dyskryminacyjna ang. Quadratic discriminant analysis (QDA)

Założenie: Rozkłady w klasach są normalne (jak dla LDA)

Brak założenia o równości macierzy kowariancji ->

-> macierze kowariancji estymowane są osobno

Prawdopodobieństwa a posteriori Bayesa:

$$P(y=k|X) = \frac{P(X|y=k)P(y=k)}{P(X)} = \frac{P(X|y=k)P(y=k)}{\sum_l P(X|y=l) \cdot P(y=l)}$$

Kwadratowa analiza dyskryminacyjna ang. Quadratic discriminant analysis (QDA)

Założenie: Rozkłady w klasach są normalne (jak dla LDA)

Brak założenia o równości macierzy kowariancji ->

-> macierze kowariancji estymowane są osobno

Prawdopodobieństwa a posteriori Bayesa:

$$P(y=k|X) = \frac{P(X|y=k)P(y=k)}{P(X)} = \frac{P(X|y=k)P(y=k)}{\sum_l P(X|y=l)\cdot P(y=l)}$$

gdzie

$$P(X|y=k) = \frac{1}{(2\pi)^{d/2}|\Sigma_k|^{1/2}} \exp\left(-\frac{1}{2}(X-\mu_k)^t \Sigma_k^{-1}(X-\mu_k)\right)$$

Kwadratowa analiza dyskryminacyjna ang. Quadratic discriminant analysis (QDA)

Funkcja klasyfikująca (logarytm stosunku prawdopodobieństw):

$$f(X) = \log\left(\frac{P(y=k|X)}{P(y=l|X)}\right) = \log\left(\frac{P(X|y=k)P(y=k)}{P(X|y=l)P(y=l)}\right)$$

Kwadratowa analiza dyskryminacyjna ang. Quadratic discriminant analysis (QDA)

Funkcja klasyfikująca (logarytm stosunku prawdopodobieństw):

$$f(X) = \log\left(\frac{P(y=k|X)}{P(y=l|X)}\right) = \log\left(\frac{P(X|y=k)P(y=k)}{P(X|y=l)P(y=l)}\right)$$

Która po przekształceniu staje się funkcją kwadratową:

$$f(X) = X^T A X + b^T X + c$$

Kwadratowa analiza dyskryminacyjna ang. Quadratic discriminant analysis (QDA)

Funkcja klasyfikująca (logarytm stosunku prawdopodobieństw):

$$f(X) = \log\left(\frac{P(y=k|X)}{P(y=l|X)}\right) = \log\left(\frac{P(X|y=k)P(y=k)}{P(X|y=l)P(y=l)}\right)$$

Która po przekształceniu staje się funkcją kwadratową:

$$f(X) = X^T A X + b^T X + c$$

Hiperpowierzchnia separująca P jest zbiorem miejsc zerowych funkcji klasyfikującej.

Klasyfikator k-najbliższych sąsiadów ang. k-nearest-neighbor (kNN)

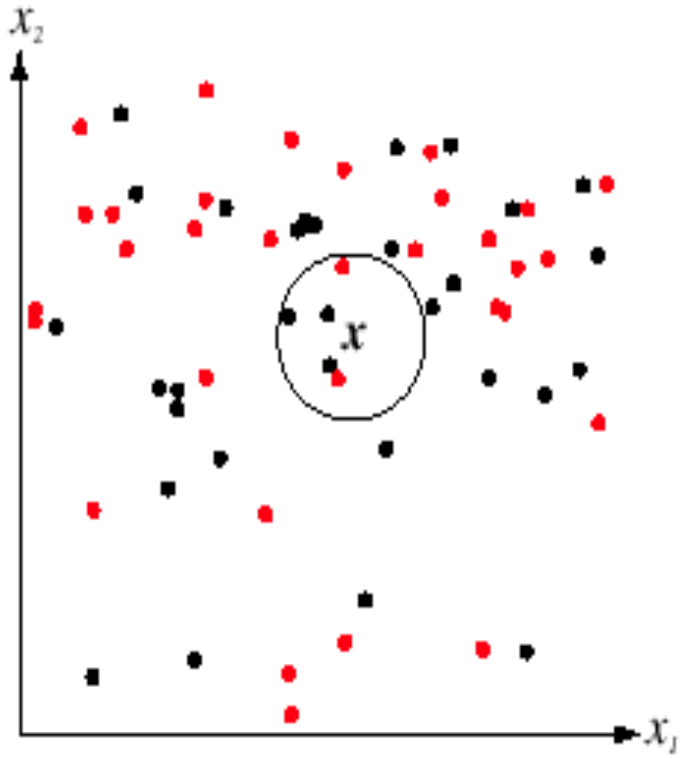


FIGURE 4.15. The k-nearest-neighbor query starts at the test point **x** and grows a spherical region until it encloses k training samples, and it labels the test point by a majority vote of these samples. In this $k = 5$ case, the test point **x** would be labeled the category of the black points. From: Richard O. Duda, Peter E. Hart, and David G. Stork, *Pattern Classification*. Copyright © 2001 by John Wiley & Sons, Inc.



FIGURE 2.1. *A classification example in two dimensions. The classes are coded as a binary variable (*BLUE $= 0$, ORANGE $= 1$*), and then fit by linear regression. The line is the decision boundary defined by* $x^T\hat{\beta} = 0.5$*. The orange shaded region denotes that part of input space classified as* ORANGE*, while the blue region is classified as* BLUE*.*

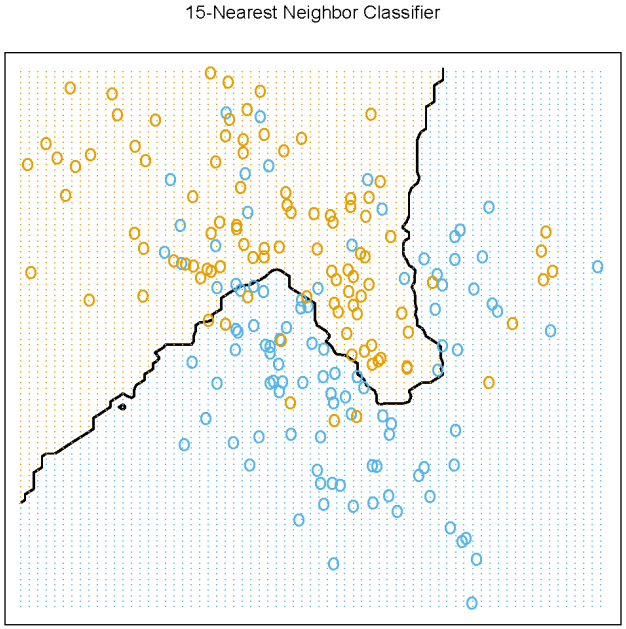


FIGURE 2.2. *The same classification example in two dimensions as in Figure 2.1. The classes are coded as a binary variable* (BLUE $= 0$, ORANGE $= 1$) *and then fit by* 15*-nearest-neighbor averaging as in (2.8). The predicted class is hence chosen by majority vote amongst the* 15*-nearest neighbors.*

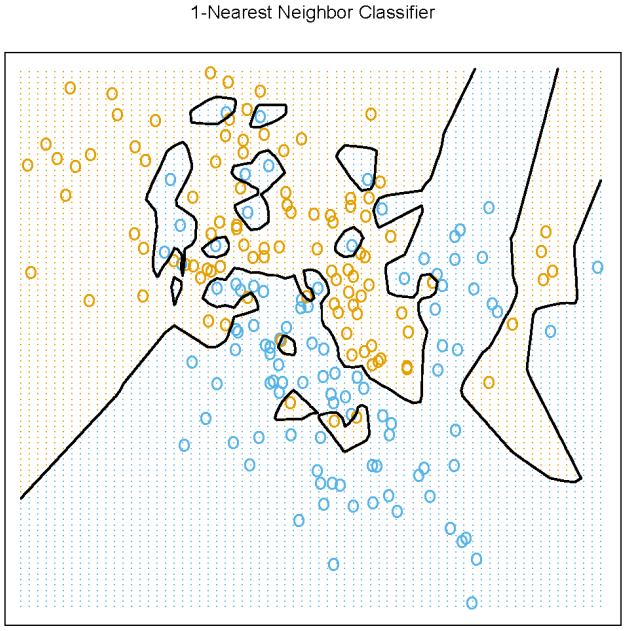


FIGURE 2.3. *The same classification example in two dimensions as in Figure 2.1. The classes are coded as a binary variable* (BLUE $= 0$, ORANGE $= 1$)*, and then predicted by* 1*-nearest-neighbor classification.*

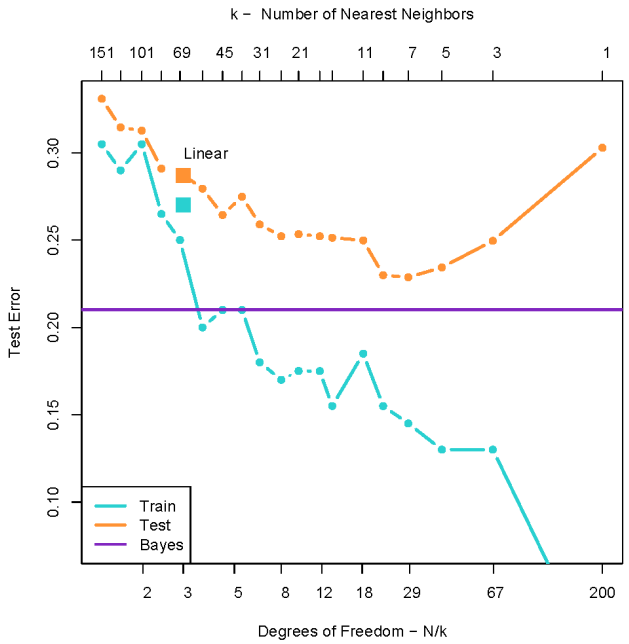


FIGURE 2.4. *Misclassification curves for the simulation example used in Figures 2.1, 2.2 and 2.3. A single training sample of size* 200 *was used, and a test sample of size* $10,000$*. The orange curves are test and the blue are training error for k-nearest-neighbor classification. The results for linear regression are the bigger orange and blue squares at three degrees of freedom. The purple line is the optimal Bayes error rate.*

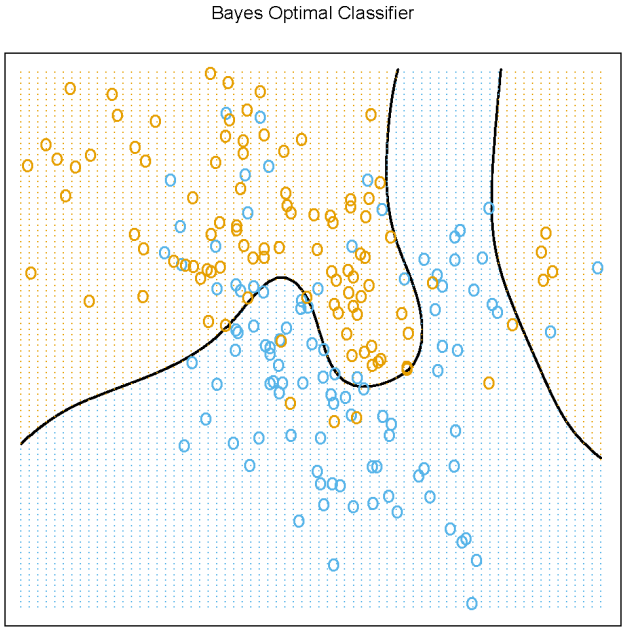


FIGURE 2.5. *The optimal Bayes decision boundary for the simulation example of Figures 2.1, 2.2 and 2.3. Since the generating density is known for each class, this boundary can be calculated exactly (Exercise 2.2).*