Instrukcja do laboratorium: Klasyfikator Bayesa

Celem laboratorium jest implementacja klasyfikatora Bayesa oraz prostego estymatora jakości klasyfikacji. Do wykonania zadania można wykorzystać dowolne środowisko programistyczne, jednak do realizacji samego algorytmu klasyfikatora nie należy wykorzystywać gotowych funkcji.
Zakłada się znajomość materiału dotyczącego badanego zagadnienia przedstawionego na wykładach.

Zadania

1) Wygenerować syntetyczny zbiór składający się z 2 cech i 200 próbek. Dane w zbiorze powinny zawierać 100 próbek z dwóch klas abstrakcji A1 i A2. Odpowiednio dane klasy A1 powinny zostać wygenerowane z rozkładu Gaussa o parametrach:

$$\mu_1 = \begin{pmatrix} 0 \\ 0 \end{pmatrix} \quad \Sigma_1 = \begin{pmatrix} 2 & -1 \\ -1 & 2 \end{pmatrix}$$

natomiast dane klasy A2 z rozkładu Gaussa o parametrach:

$$\mu_2 = \begin{pmatrix} 2 \\ 2 \end{pmatrix} \quad \Sigma_1 = \begin{pmatrix} 1 & 0 \\ 0 & 1 \end{pmatrix}$$

Otrzymane dane powinny zostać losowo podzielone na zbiór uczący i testowy (po 100 próbek w każdym zbiorze). Zbiór testowy należy wykorzystać jedynie w celu estymacji jakości klasyfikacji, nie wykorzystując go w procesie uczenia. W celu weryfikacji dane należy przedstawić na wykresie z wykorzystaniem wykresu punktowego (scatter plot).

2) Napisać funkcję klasyfikatora Bayesa dla 2-klasowego zbioru danych, oraz dowolnej liczby cech (własna implementacja)
   Do estymacji rozkładu w poszczególnych klasach należy wykorzystać dwie metody:
   a) Metoda parametryczna w oparciu o rozkład normalny
   b) Metoda nieparametryczna w oparciu o okna Parzena. Proszę zbadać wpływ parametru szerokości okna na wynik klasyfikacji.
3) W oparciu o macierz błędów dla zbioru testowego wyznaczyć jakość klasyfikacji
   TP - prawdziwie pozytywna (ang. true positive)
   TN - prawdziwie negatywna (ang. true negative)
   FP - fałszywie pozytywna (ang. false positive), błąd pierwszego rodzaju
   FN - fałszywie negatywna (ang. false negative), błąd drugiego rodzaju

$$ACC = \frac{TP + TN}{TP + FP + TN + FN}$$

4) W celu wykazania różnic pomiędzy wykorzystywanymi metodami estymacji rozkładu w klasach należy wygenerować różne zbiory danych zawierające więcej niż 5 cech (do wygenerowania danych można wykorzystywać inne rozkłady, niż opisany w punkcie pierwszym rozkład Gaussa)

SPRAWOZDANIE

Sprawozdanie powinno zawierać samodzielnie napisany program (kod programu), wraz z opisem i algorytmami, symulacje, oraz końcowe wnioski uwzględniające analizy wykonane na różnych zbiorach danych. Dodatkowo w sprawozdaniu powinna znajdować się odpowiedź na pytanie: Która z metod estymacji rozkładu w klasach i jakich przypadkach daje lepsze rezultaty klasyfikacji?

Czas na oddanie sprawozdania: dwa tygodnie od daty laboratorium.