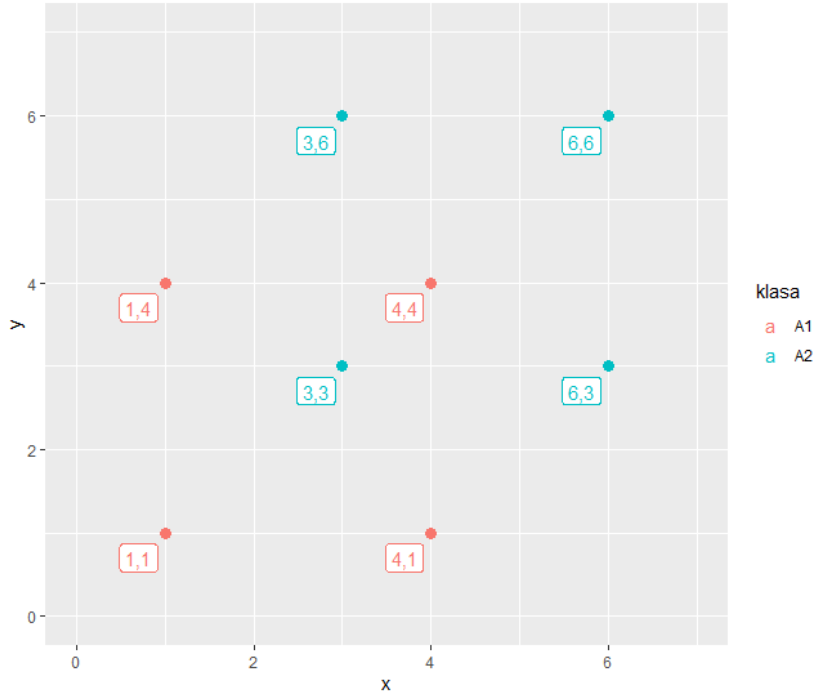
Instrukcja do laboratorium: Analiza dyskryminacyjna

Celem laboratorium jest implementacja wybranych metod analizy dyskryminacyjnej oraz ocena ich skuteczności w klasyfikacji różnych zbiorów danych.
Do wykonania zadań można wykorzystać dowolne środowisko programistyczne.

Wprowadzenie
Analiza dyskryminacyjna to zespół metod statystycznych wielowymiarowej analizy danych, blisko spokrewnionych z analizą wariancji. Do jej najczęściej stosowanych wariantów należą LDA, DLDA oraz QDA. Analiza dyskryminacyjna może służyć zarówno do redukcji wymiarowości (LDA) jak i klasyfikacji, jako metoda nadzorowana, czyli taka, w której podział na klasy jest znany *a priori*. Najlepiej sprawdza się w przypadku zmiennych ciągłych. Zakłada też, że zmienne mają rozkład normalny, więc należy ostrożnie stosować ją w przypadkach, w których podejrzewamy, że tak nie jest.

Przykład działania – klasyfikator LDA

Dane:

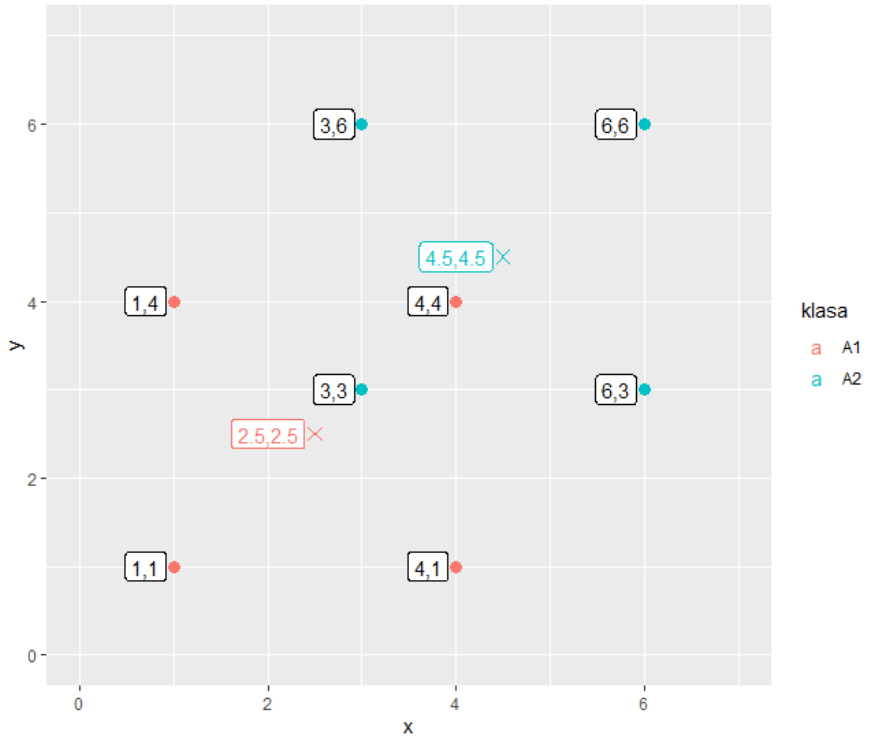


Wzór na funkcję klasyfikującą:

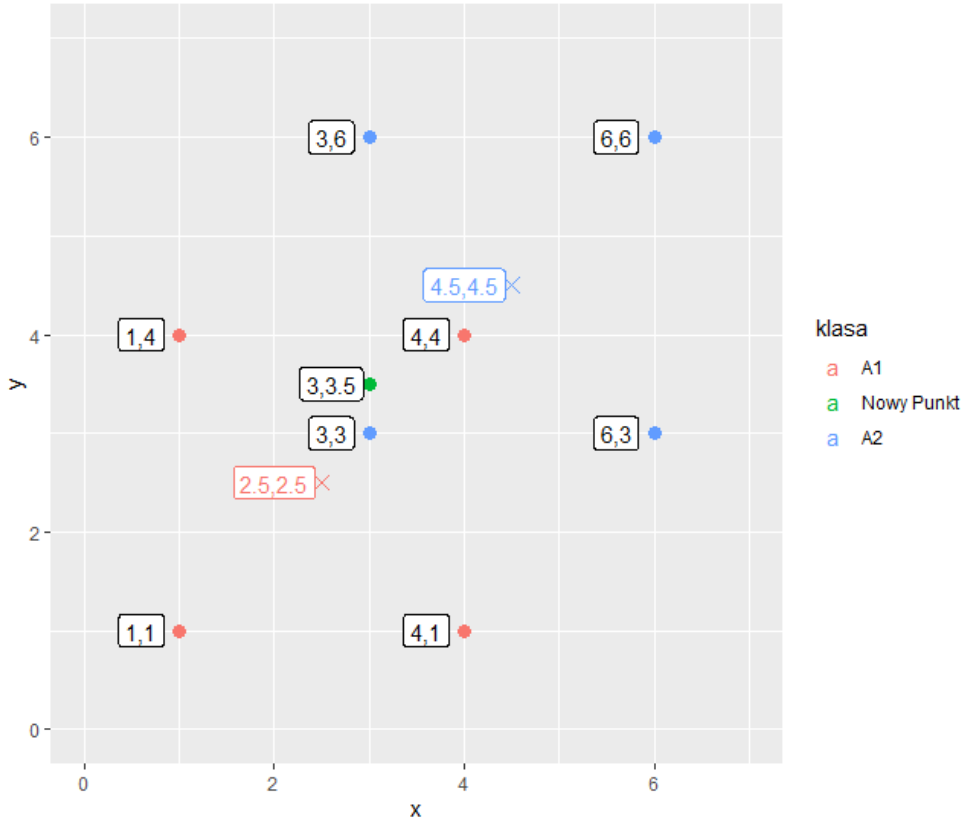
$$f(x) = (\bar{x}_1 - \bar{x}_2)^T W^{-1}[x - \frac{1}{2}(\bar{x}_1 + \bar{x}_2)]$$

Obliczamy średnie dla klas i macierze kowariancji:

$W = \begin{bmatrix} 3 & 0 \\ 0 & 3 \end{bmatrix}$, natomiast odwrotność macierzy kowariancji $W^{-1} = \begin{bmatrix} \frac{1}{3} & 0 \\ 0 & \frac{1}{3} \end{bmatrix}$



Dla nowego punktu o współrzędnych (3,3.5):



$$f(x)=[-2 \quad -2]\begin{bmatrix}\frac{1}{3} & 0\\ 0 & \frac{1}{3}\end{bmatrix}\left[\begin{bmatrix}3\\3.5\end{bmatrix}-\frac{1}{2}\begin{bmatrix}7\\7\end{bmatrix}\right]=\frac{1}{3}$$

Wartość funkcji klasyfikującej jest większa od zera, przypisujemy zatem nowy punkt do klasy A1 (czerwonej). Istotnie, punkt znajduje się po lewej stronie hiperpłaszczyzny separującej (w tym przypadku linii prostopadłej do odcinka łączącego średnie grup i przecinającej go w połowie).



Zadania

1) Porównać założenia trzech metod analizy dyskryminacyjnej: LDA (liniowa analiza dyskryminacyjna, *Linear Discriminant Analysis*), DLDA (diagonalna liniowa analiza dyskryminacyjna, *Diagonal Linear Discriminant Analysis)* oraz QDA (kwadratowa analiza dyskryminacyjna, *Quadratic Discriminant Analysis*). Która z metod jest najbardziej uniwersalna?

2) Napisać własną implementację (nie należy korzystać z gotowych funkcji) metod LDA oraz jej uproszczonego wariantu DLDA dla dwuklasowego zbioru danych o dowolnej liczbie cech. Czy algorytmy te różnią się złożonością obliczeniową? Proszę porównać czasy ich działania.

3) Wygenerować syntetyczne zbiory danych spełniające założenia metod z punktu 1 (trzy rodzaje zbiorów, po jednym rodzaju dla każdego zestawu założeń). Dane w zbiorze powinny zawierać po 100 obserwacji z dwóch klas abstrakcji A1 i A2, oraz dwie cechy o rozkładzie normalnym (parametry rozkładów dobrać tak, aby klasy nie były idealnie separowalne). Wygenerowane dane podzielić losowo na zbiór uczący oraz testowy (po 100 próbek w każdym zbiorze). Porównać dokładność klasyfikacji (*accuracy*) dla poszczególnych metod analizy dyskryminacyjnej (dla QDA można skorzystać z gotowej funkcji). Dla lepszej estymacji jakości powtórzyć symulację co najmniej 50 razy. Czy metody dobrze sprawdzają się dla zbiorów niespełniających ich założeń?

Wskazówki
Macierz kowariancji musi być symetryczna i dodatnio określona.
Przydatne funkcje:
Matlab: `mvnrand`
R: `MASS::mvrnorm`
Python: `numpy.random.multivariate_normal`

4) W rzeczywistych danych zwykle zaledwie niewielki odsetek zmiennych to cechy różnicujące. Często liczba cech przewyższa również znacznie liczbę dostępnych obserwacji. Wygenerować zbiory uczący i testowy zawierające po 50 obserwacji dla dwóch klas abstrakcji (w sumie 100 próbek w każdym ze zbiorów), w których:

- pierwsze 5 cech pochodzi z rozkładu N(0,1) dla klasy A1 oraz N(1,1) dla klasy A2,
- pozostałe 95 cech pochodzi ze standardowego rozkładu normalnego dla obu klas.

Przedstawić na wykresie dokładność klasyfikacji dla poszczególnych metod w zakresie od 1 do 30 cech. Jak dołączanie nieróżnicujących cech do klasyfikatora wpływa na jakość? Przeprowadzić klasyfikację dla pełnego zakresu cech (od 1 do 100). Czy dla klasyfikatorów diagonalnego, liniowego i kwadratowego pojawił się błąd? Jeżeli tak, na jakiej liczbie cech? Z czego to wynika?

Sprawozdanie
Sprawozdanie powinno zawierać samodzielnie napisany program(kod), wraz z opisem i algorytmami, symulacje, oraz wnioski uwzględniające analizy wykonane na różnych zbiorach danych.
Czas na oddanie sprawozdania: dwa tygodnie od daty laboratorium